

E Innovationen im Mauerwerksbau

E 1 Digitale Transformation im Bauwesen – Grundlagen zur künstlichen Intelligenz und deren Anwendung im Wohnungsbau

Michael A. Kraus und Mathias Obergrießer

Mauerwerk-Kalender 2023: Instandsetzung – Erdbeben – Lehmabau.

Herausgegeben von Detleff Schermer und Eric Brehm.

© 2023 Ernst & Sohn GmbH. Published 2023 by Ernst & Sohn GmbH.

Inhaltsverzeichnis

	Begriffsverzeichnis/Dictionary	277	5	Potenziale und Zukunftstrends von künstlicher Intelligenz im Mauerwerks- und Wohnungsbau	301
1	Einleitung und Motivation	281			
2	Digitale Transformation als Voraussetzung für den Einsatz von künstlicher Intelligenz – Status quo und aktuelle Trends im Bauwesen	282	5.1	Zukunftstrends für die Methoden der künstlichen Intelligenz	301
			5.2	Zukunftstrends für die Anwendung der künstlichen Intelligenz im Bauwesen	302
3	Einführung in die künstliche Intelligenz sowie das maschinelle und tiefe Lernen	283	6	Fazit und Ausblick	302
3.1	Grundlagen zu KI-Algorithmen, Modellen und Daten	283	6.1	Zusammenfassung	302
3.2	Machine Learning/ Maschinelles Lernen	288	6.2	Epilog	304
3.3	Deep Learning/Tiefes Lernen	290		Literatur	305
4	Anwendungsbeispiele zum Einsatz von künstlicher Intelligenz im Wohnungsbau	293			
4.1	Hintergrundinformationen zu Lebenszyklusphasen von Gebäuden	293			
4.2	Lebenszyklusphase „Entwurf“	294			
4.2.1	Konzeptioneller Entwurf (Raumprogramm und Grundrisse) mit generativer KI	294			
4.2.2	KI-basierte Ersatzmodelle zur statischen Bemessung im Wohnungsbau	295			
4.3	Lebenszyklusphase „Bau und Konstruktion“	298			
4.4	Lebenszyklusphasen „Betrieb und Instandhaltung“	300			

Begriffsverzeichnis/Dictionary

Fachbegriffe englisch	Abkürzung/Übersetzung/Definition
A	
Accuracy	dt. Genauigkeit. Im Kontext von künstlicher Intelligenz die Genauigkeit einer Prädiktion im Sinne eines Regressions- oder auch eines Klassifizierungsproblems.
Artificial Intelligence	Abk. AI, dt. künstliche Intelligenz.
Artificial Neural Network	Abk. ANN, dt. künstliches neuronales Netzwerk. Bei künstlichen neuronalen Netzen handelt es sich um Netzwerke aus künstlichen Neuronen. Ihr Forschungsgegenstand ist die Neuroinformatik und sie repräsentiert einen Teilbereich der künstlichen Intelligenz.
B	
Big Data	dt. große Datenmengen. Big Data bezeichnet Datenmengen, welche beispielsweise zu groß, zu komplex, zu schnelllebig oder zu schwach strukturiert sind, um sie mit manuellen und herkömmlichen Methoden der Datenverarbeitung auszuwerten.
Building Information Modeling	Abk. BIM. Das Building Information Modeling beschreibt eine Arbeitsmethode zur vernetzten Planung, Ausführung und Verwaltung von Gebäuden und anderen Bauwerken mithilfe von Software. Alle relevanten Gebäudedaten werden digital modelliert, kombiniert und erfasst.
C	
Clustering	Der Begriff Clusteranalyse bezeichnet ein Verfahren zur Entdeckung von Ähnlichkeitsstrukturen in Datensätzen. Die auf diese Weise gefundenen Gruppen von „ähnlichen“ Objekten werden als Cluster bezeichnet, die Gruppenzuordnung als Clustering.
Computer Vision	Computer Vision liegt im Grenzbereich zwischen Informatik und Ingenieurwissenschaften und beschäftigt sich mit der Verarbeitung und Analyse von Bildern, die von Kameras aufgenommen wurden, um deren Inhalt zu verstehen oder geometrische Informationen zu extrahieren.
Convolutional Neural Network	Abk. CNN/ConvNet, dt. Faltungsnetz. Ein Convolutional Neural Network (CNN oder ConvNet), zu Deutsch etwa „faltendes neuronales Netzwerk“, ist ein künstliches neuronales Netz. Es handelt sich um ein von biologischen Prozessen inspiriertes Konzept im Bereich des maschinellen Lernens. Convolutional Neural Networks finden Anwendung in zahlreichen Technologien der künstlichen Intelligenz, vornehmlich bei der maschinellen Verarbeitung von Bild- oder Audiodaten.
Cross Validation	Abk. CV, dt. Kreuzvalidierung. Kreuzvalidierungsverfahren sind Testverfahren der Statistik bzw. der Datenanalyse, die bspw. im Data-Mining, oder bei der Überprüfung neu entwickelter Fragebögen zum Einsatz kommen.
Curse of Dimensionality	dt. Fluch der Dimensionalität. Der von Richard Bellman eingeführte Begriff „Curse of Dimensionality“ beschreibt die schnelle Zunahme des Volumens, wenn einem mathematischen Raum weitere Dimensionen hinzugefügt werden.
D	
Data Mining	dt. Daten fördern. Unter Data Mining versteht man die systematische Anwendung statistischer Methoden auf große Datenbestände mit dem Ziel, neue Querverbindungen und Trends zu erkennen.
Deep Learning	Abk. DL, dt. tiefes Lernen. Die Bezeichnung Deep Learning bezieht sich auf eine maschinelle Lernmethode, die künstliche neuronale Netze mit zahlreichen Zwischenschichten zwischen der Eingabeschicht und der Ausgabeschicht verwendet.
Dense Layer	dt. dichte Schicht. Beim Fully Connected Layer oder Dense Layer handelt es sich um eine normale neuronale Netzstruktur, bei der alle Neuronen mit allen Inputs und allen Outputs verbunden sind. Um den Matrix-Output der Convolutional- und Pooling-Layer in einen Dense Layer speisen zu können, muss dieser zunächst ausgerollt werden (flatten).

Fachbegriffe englisch	Abkürzung/Übersetzung/Definition
Digital Twin	dt. digitaler Zwilling. Ein digitaler Zwilling ist eine digitale Repräsentanz eines materiellen oder immateriellen Objekts oder Prozesses aus der realen Welt in der digitalen Welt. Das Gegenstück des physischen Zwillings (physical twin) in der realen Welt muss nicht oder kann erst zukünftig existieren.
E	
Entropy Loss	dt. Entropieverlust. Verlustfunktion beim Training eines KI-Algorithmus.
Explainable Artificial Intelligence	Abk. XAI, dt. erklärbare künstliche Intelligenz. Der Begriff „Explainable Artificial Intelligence“ ist ein Neologismus, den die Forscher und Entwickler im Bereich des maschinellen Lernens seit etwa 2004 verwenden. XAI soll eindeutig nachvollziehbar machen, auf welche Weise dynamische und nichtlinear programmierte, auf KI basierenden Systeme funktionieren.
F	
Feature	dt. Merkmal. Beim maschinellen Lernen und der Mustererkennung ist ein Feature eine individuell messbare Eigenschaft oder ein Merkmal eines beobachteten Phänomens.
Forecasting	dt. Prognose.
G	
Generalization Error	dt. Fehler der Verallgemeinerung. In überwachten Lernanwendungen des maschinellen Lernens und der statistischen Lerntheorie ist der Generalisierungsfehler ein Maß dafür, wie genau ein Algorithmus Ergebniswerte für zuvor nicht sichtbare Daten vorhersagen kann.
Generative Design	dt. generatives Entwerfen/Gestalten. Entwurfsmethode, bei dem der Output durch einen Algorithmus (üblicherweise in Form eines Computerprogramms) erzeugt wird. Dabei entfallen wesentliche Arbeitsschritte wie die konstruktiven Bemessungen, da sie im Algorithmus enthalten sind. Auszeichnendes Element ist zudem oftmals eine Visualisierung der technischen Optimierung.
H	
Hidden Layer	dt. versteckte Schicht. Zwischenschichten in einem künstlichen neuronalen Netzwerk. Sobald mehr als zwei Hidden Layer vorliegen, spricht man von einem tiefen neuronalen Netzwerk.
I	
Industry Foundation Class	Abk. IFC. Bei den Industry Foundation Classes handelt es sich um einen offenen Standard in der Baubranche zur digitalen Beschreibung von Gebäudemodellen. Zertifiziert werden die IFC von buildingSMART e. V. International; sie sind unter ISO 16739 definiert.
Internet of Things	Abk. IoT, dt. Internet der Dinge. Unter dem Internet der Dinge versteht man einen Sammelbegriff für Technologien einer globalen Infrastruktur der Informationsgesellschaft, die die Vernetzung und Zusammenarbeit von physischen und virtuellen Objekten durch Informations- und Kommunikationstechnologien ermöglicht.
K	
Knowledge Representation	dt. Wissensrepräsentation. Im Kontext der Wissensmodellierung wird die Wissensrepräsentation verwendet, um Wissen in wissensbasierten Systemen formal darzustellen.
L	
Leave-one-out cross Validation	Abk. LOOCV. Ein Spezialfall der k-fachen Kreuzvalidierung ist die Leave-one-out-Kreuzvalidierung (LOO-CV), wobei $k = N$ (N = Anzahl der Elemente). Es werden also N Durchläufe gestartet, deren einzelne Fehlerwerte als Durchschnittswert die Gesamtfehlerrate ergeben.
M	
Machine Learning	Abk. ML, dt. Maschinelles Lernen. Der Begriff Maschinelles Lernen ist ein Oberbegriff für die „künstliche“ Erzeugung von Wissen aus Erfahrung: Ein künstliches System lernt aus Beispielen und kann diese nach Abschluss der Lernphase verallgemeinern. Die Algorithmen des maschinellen Lernens bauen dazu ein statistisches Modell auf Basis von Trainingsdaten auf.

Fachbegriffe englisch	Abkürzung/Übersetzung/Definition
N	
Natural Language Processing	Abk. NLP, dt. Textverarbeitung. Natürliche Sprachverarbeitung ist ein Spezialgebiet der Linguistik, Informatik und künstlichen Intelligenz, das die Interaktion zwischen Computern und menschlicher Sprache behandelt.
Neural Network	Abk. NN, dt. neuronales Netzwerk.
O	
Overfitting	dt. Überpassung. Übersensitives Training eines KI-Algorithmus auf Daten.
P	
Perception	dt. Wahrnehmung.
Pooling Layer	Pooling Layer verwerfen überflüssige Informationen von bspw. Bilddaten, in dem in einer $X \times Y$ Matrix von Pixeln eine Operation stattfindet, in der nur der Maximalwert an eine komprimierte Matrix weitergegeben wird.
Prediction	dt. Prädiktion.
Predictive Maintenance	dt. vorausschauende Instandhaltung. Predictive Maintenance lernt aus historischen und ggf. in Echtzeit erfassten wartungsbezogenen Daten. Hierdurch und durch die Vorhersage zukünftiger Ereignisse soll Kenntnis darüber erlangt werden, wann ein schädliches Ereignis in der Zukunft stattfindet.
Principal Components Analysis	Abk. PCA, dt. Hauptkomponentenanalyse. Das Verfahren der Hauptkomponentenanalyse ist eine Methode der multivariaten Statistik. Mit ihr werden umfangreiche Datensätze strukturiert, vereinfacht und veranschaulicht, indem eine große Anzahl von statistischen Variablen durch eine kleinere Anzahl von möglichst aussagekräftigen Linearkombinationen angenähert wird.
R	
Reasoning	dt. logisches Denken.
Recurrent Neural Network	Abk. RNN, dt. rekurrente neuronale Netze. Bei rekurrenten oder rückgekoppelten neuronalen Netzen handelt es sich um neuronale Netze, die im Gegensatz zu Feedforward-Netzen durch Verbindungen von Neuronen einer Schicht zu Neuronen der gleichen oder einer vorhergehenden Schicht gekennzeichnet sind. RNNs finden praktische Anwendung bei Problemen, die die Verarbeitung von Sequenzen erfordern. Beispielfhaft seien hier Handschrifterkennung, Spracherkennung und maschinelle Übersetzung genannt.
Reinforcement Learning/Reward	Abk. RL, dt. verstärkendes Lernen. RL ist ein Bereich des maschinellen Lernens, der sich damit beschäftigt, wie intelligente Agenten Aktionen in einer Umgebung ausführen sollten, um den Begriff der kumulativen Belohnung zu maximieren.
Rectifier/Rectified Linear Unit	Abk. ReLu, dt. Gleichrichter. Im Kontext künstlicher neuronaler Netze ist ein Rectifier eine Aktivierungsfunktion eines künstlichen Neurons, die als Positivteil seines Arguments definiert ist: $f(x) = \max(0, x)$ mit x als Eingangswert des künstlichen Neurons.
S	
Softmax	dt. normalisierte Exponentialfunktion. In der Mathematik ist die sogenannte Softmax-Funktion eine Verallgemeinerung der logistischen Funktion, die einen K-dimensionalen Vektor z mit reellen Komponenten in einen K-dimensionalen Vektor $\sigma(z)$ ebenfalls als Vektor reeller Komponenten in den Wertebereich $(0,1)$ transformiert, wobei sich die Komponenten zu 1 aufsummieren.
Structural Health Monitoring	Abk. SHM, dt. Zustandsüberwachung. Die Zustandsüberwachung SHM ist eine kontinuierliche oder periodische und automatisierte Methode zur Ermittlung und Überwachung des Zustands eines überwachten Bauobjekts.
Supervised Learning	dt. überwachtes Lernen.

Fachbegriffe englisch	Abkürzung/Übersetzung/Definition
T	
Text Mining	Verbindet Ansätze aus der Linguistik und der Statistik, um aus den Textdaten Kerninformationen zu extrahieren.
Transformers	Als Transformator bezeichnet man ein Verfahren, mit dem ein Computer eine Zeichenfolge in eine andere Zeichenfolge übersetzen kann. Dies kann bspw. verwendet werden, um Text von einer Sprache in eine andere zu übersetzen.
U	
Underfitting	dt. Unterpassung. Untersensitives Training eines KI-Algorithmus auf Daten.
Unsupervised Learning	dt. unüberwachtes Lernen.
Upsampling	Der Begriff Upsampling oder Abtastratenerhöhung beschreibt im Rahmen der digitalen Signalverarbeitung die Umsetzung eines Digitalsignals mit einer niedrigen Abtastrate auf ein Digitalsignal mit einer höheren Abtastrate, wobei die Signalinformation vollständig und unverändert erhalten bleibt.
USERMAT	Abk. UMAT. Eigens entwickeltes und im Finite-Elemente-Code ANSYS implementiertes Materialmodell.

1 Einleitung und Motivation

Hochbauobjekte des Bauwesens stellen meist Unikate aufgrund ihrer Form, Gebäudekubatur, ihren geografischen Gegebenheiten und äußerer Einflüsse dar. Da eine bauliche Struktur kaum einer anderen gleicht, ergeben sich stets neue Herausforderungen beim Entwurf, Bau und Betrieb der gebauten Umwelt. Traditionell bedeuteten die Planung und Realisierung baulicher Strukturen die Integration und quantitative Verknüpfung sich teilweise in der Wirkung widerstrebender Aspekte der Ökologie, Ökonomie, Zuverlässigkeit und Sicherheit, Baubarkeit und Effizienz. Bisher bedurfte es für die erfolgreiche und befriedigende Konzeption und Realisierung eines Bauvorhabens maßgeblich des fachtheoretischen und praktischen Erfahrungsschatzes der an diesem Prozess Beteiligten. Die aktuellen Entwicklungen zur digitalen Transformation, der vierten industriellen Revolution sowie der künstlichen Intelligenz (KI), markieren möglicherweise eine Zäsur im Bauwesen hinsichtlich der Art und Weise des Entwurfs, Planens, Bauens und Betreibens gebauter Umwelt insofern, dass bauliche Strukturen der Zukunft aus einer Symbiose von industrieller Produktion bei simultaner individueller Ausprägung auf der Grundlage datenbasierter Entscheidungen objektiv entwickelt und umgesetzt werden können.

Kernelement und Erfolgsgarant dieser Zukunftsvision der nächsten Stufe des Bauens stellen die *digitale Transformation* aller Prozesse des Bauens sowie die *Erhebung, Speicherung, Bereitstellung und Nutzung Lebenszyklusbegleitender rechenbarer Bauwerksinformationen* dar. Der Begriff *digitale Transformation* [1, 2] steht dabei dafür, dass Unternehmen auf allen Stufen der Wertschöpfungskette intensiv auf digital vernetzte Systeme treffen sowie mit Werkzeugen und Praktiken arbeiten, die auf Informations- und Kommunikationstechnologie basieren. Damit verändert sich die Rolle der digitalen Techniken. Sie sind nicht mehr rein unterstützende Werkzeuge wie die *Digitalisierung* (digitale Repräsentation eines physischen Objekts oder einer Eigenschaft [1, 2]), sondern verändern auf grundlegende Art und Weise, wie Geschäftsprozesse in allen Unternehmensbereichen abgewickelt werden.

Dieser Zukunftsvision steht der Status quo des Bauwesens gegenüber [2–4]. Aktuelle Studien der großen Wirtschaftsberatungsgesellschaften [5–9] verdeutlichen, dass momentan weniger als 6 % der Bauunternehmen digitale Planungsinstrumente nutzen, obschon über 90 % der befragten Akteure der Bauwirtschaft der These zustimmen, dass Digitalisierung künftig Geschäftsprozesse signifikant beeinflussen wird und wirtschaftliche Potenziale derzeit bei Weitem nicht ausgeschöpft sind. Offensichtlich ist dabei auch, dass die Bedürfnisse und Ansätze je nach Akteur unterschiedlich ausfallen. Somit lässt sich resümieren, dass bei den verschiedenen Akteuren der Bauwirtschaft sehr wohl das Bewusstsein für die Bedeutung des Megatrends *Digitalisierung* vorhanden ist, dessen Umsetzung in die Pra-

xis derzeit aber ungenügend ist und schwerfällig voranschreitet [2–4].

Insgesamt können vier Hebel der digitalen Transformation für die Bauwirtschaft identifiziert werden, welchen alle große Bedeutung auf allen Stufen der Wertschöpfung zuzurechnen ist: *digitale Daten*, *Automatization*, *Netzwerke* und *digitaler Zugang*. Die künstliche Intelligenz greift hier massiv auf die drei erstgenannten Hebel ein bzw. steht in Interaktion mit diesen. Die Einführung, Etablierung und Anwendung von KI stellt den nächsten logischen Schritt in den Entwurfs-, Planungs- und Bauprozessen dar, da sich diese durch Erfindungen oder Einflüsse aus anderen Disziplinen kontinuierlich im Laufe der Geschichte weiterentwickelten. Im letzten Quartal des vergangenen Jahrhunderts begann die Digitalisierung im Bauwesen und legte den Grundstein für viele Innovationen. Wissenschaftlich vollzieht sich künftig die Metamorphose des gesamten Bauvorgangs von einer Objekt- bzw. Prozesszentrierung hin zur Datenzentrierung mit Interaktion von physischer und digitaler Welt.

Dieser Beitrag setzt sich zum Ziel, den innovationsfreudigen Akteuren des Bauwesens, aber auch interessierten Fachleuten einen ersten Einblick in die Definitionen künstlicher Intelligenz (KI) sowie der Zusammenhänge von KI und Digitalisierung mit spezifischem Fokus auf verschiedene Geschäftsbereiche des Bauens mit Schwerpunkt Wohnungsbau zu ermöglichen. Wie die digitale Transformation des Bauens durch die bereits weiter fortgeschrittene Transformation im Bereich der Raumfahrt motiviert werden kann, wurde von den Autoren bereits in [2] erarbeitet und am Beispiel des Lebenszyklus einer Brücke dargestellt. Dieser Beitrag greift den Lebenszyklus von Wohnimmobilien auf und stellt den derzeitigen Umsetzungs- und Reifegrad von diversen KI-Ansätzen praxisnah dar. Das Ende des Beitrags markiert ein Resümee bezüglich der Themenfelder der digitalen Transformation sowie der KI mit Hinblick auf den Status quo sowie notwendiger künftiger Schritte zur Etablierung der KI und ihrer essenziellen Voraussetzungen im Bauwesen. Klar sein muss, dass künftige KI-Anwendungen in der Baupraxis und darüber hinaus überwiegend als kollaborative Anwendungen mit enger Verzahnung des entsprechend geschulten bzw. versierten Fachpersonals aus den Bereichen Architektur, Bauingenieurwesen und Fachhandwerk gestaltet werden sollten. Damit möchte diese Publikation einen wichtigen und zukunftsweisenden Beitrag einer frühzeitigen Indikation und Bewusstseins-schaffung für die am Bau Beteiligten bezüglich der Befassung mit den technischen Entwicklungen und deren Umsetzbarkeit entlang der gesamten Wertschöpfungskette des Bauens zur Steigerung der Produktivität und Effektivität durch den Einsatz digitaler Methoden leisten.

2 Digitale Transformation als Voraussetzung für den Einsatz von künstlicher Intelligenz – Status quo und aktuelle Trends im Bauwesen

In [2–4] wurde das Thema digitale Transformation im Bauwesen vorgestellt. Dabei wurde aufgezeigt, welche Potenziale durch die Einführung einer digital vernetzten Arbeitswelt im Bauwesen bestehen, wie diese theoretisch, aber auch praxistgerecht realisiert werden können und wie wichtig es ist, Daten, welche während des gesamten Lebenszyklus eines Bauwerks entstehen, zentral, prozess-kooordiniert und strukturiert zu sammeln, zu verwalten und zu verarbeiten. Die weltweit eingesetzte Methode des Building Information Modeling (BIM) inklusive der neutralen Schnittstelle Industry Foundation Class (IFC) nimmt dabei eine zentrale Rolle ein [10], da erst mithilfe dieser beiden Komponenten eine gemeinsame digitale und 3D-visuelle Kommunikations- und Organisationsplattform der Bauwerksdaten für den Anwender zur Verfügung steht. Eine Steigerung der Produktivität durch eine transparente, lückenlose und konsistente Informationsverteilung der erforderlichen Daten vor allem im Bereich des Planens und immer häufiger im Bereich des Bauens ist die Folge. Eine Vielzahl von international und national erfolgreich abgewickelten Bauprojekten belegen diesen Paradigmenwechsel im Bauwesen [11–13].

Allerdings besteht der Schlüssel zu einer nachhaltigen digitalen Transformation im Bausektor nicht nur darin, digitale Werkzeuge oder optimale Prozessketten zu definieren, sondern auch in der skalierbaren und zielorientierten Nutzung der mithilfe der BIM-Methode gesammelten Daten. Je häufiger die einmal generierten Daten während des Bauwerkslebenszyklus und darüber hinaus genutzt werden, desto besser wird die Wertschöpfung und somit die Wirtschaftlichkeit der digitalen Anstrengungen. Aus diesem Grund ist es sehr wichtig, bereits von Anfang an zu wissen bzw. fest zu definieren, wofür die Daten eingesetzt werden sollen, wer die Daten benötigt und wann sowie wo und wie die Daten gespeichert werden. Erst dadurch lässt sich eine effiziente Digitalisierungsstrategie mit einem optimalen Aufwand-Nutzen-Verhältnis manifestieren. Vereinfacht ausgedrückt bedeutet dies, dass die Daten eines Bauprojekts nicht nur während seines eigenen Lebenszyklus eingesetzt werden sollen, sondern diese Daten als Erfahrungsgrundlage für nachfolgende Projekte zur Verfügung stehen sollten (Bild 1).

Vom Prinzip her ist dieses Vorgehen nichts Unbekanntes, allerdings ist die Komplexität und das Volumen der Daten anders einzuordnen als bei der traditionellen Umsetzung eines Bauprojekts ohne Zuhilfenahme der BIM-Methode. Im Grundsatz des ingenieurmäßigen Handelns gibt es zwei Möglichkeiten das komplexere System zu lösen. Einerseits könnte das komplexe System in kleine einfache Teilsysteme mit geringerem Informationsvolumen und einfacheren Strukturen




Bild 1. Schematische Darstellung der Nutzung von Bestandsdaten vorhandener Bauprojekte zur KI-basierten Optimierung von nachfolgenden Projekten

unterteilt werden, andererseits könnte man eine passende Technologie einsetzen, die eine Verarbeitung der Massen an Daten erlaubt. Ruft man sich in Erinnerung, dass es das angestrebte Ziel ist, auf Basis einer Vielzahl an vorhandenen Projektdaten eine Optimierung der verschiedensten Prozessaufgaben während des Planens, Ausführens und Betreibens eines Bauwerks durchzuführen und sich dabei nicht nur auf einzelne Kriterien zu konzentrieren, sondern die Themen wie Nachhaltigkeit, Energieeffizienz oder Nutzbarkeit als einen ganzheitlichen Ansatz zu betrachten, dann ist eine lokale kleinteilige Optimierung von einzelnen Prozessinseln nicht zielführend. Aus diesem Grund ist es notwendig, eine Technologie einzusetzen, die eine Auswertung einer Vielzahl von unterschiedlichsten Informationen in Bezug auf unterschiedlichste Kriterien durchführen kann. Eine der bekanntesten Technologien hierzu stellt die künstliche Intelligenz dar, welche es erlaubt, komplexe Zusammenhänge auf Basis von Daten, Erfahrungswerten oder Regeln zu analysieren und daraus Prognosen bzw. mögliche Lösungen vorzuschlagen. In anderen Branchen wie der Konsumenten- oder Sicherheitsindustrie, aber auch im Gesundheitswesen wird diese Technologie bereits verstärkt eingesetzt. KI-spezifische Ansätze, wie sie nachfolgend erklärt werden, sind größtenteils domänen-neutral aufgebaut und lassen sich daher für eine Vielzahl an diversen Aufgabenstellungen aus unterschiedlichsten Fachrichtungen adaptieren [3]. Dies gilt auch für das Bauwesen, indem durch den Einstieg der Branche in die Digitalisierung nun endlich die Grundlagen für den Einsatz KI-basierter Ansätze vorliegen.

Um einen ersten Einblick in diese Welt zu bekommen, wird in den nachfolgenden Abschnitten auf das Thema KI im Wohnungsbau eingegangen. Hierzu werden im nächsten Abschnitt, verschiedenste theoretische Grundlagen und Formen der KI vorgestellt und der Bezug zum Bauwesen hergestellt. Nach Abschluss

Advert not available in this digital edition

Advert not available in this digital edition

der theoretischen Exkursion werden verschiedenste Anwendungsszenarien bzw. Einsatzfelder von KI im Wohnungsbau vorgestellt, bevor am Ende des Beitrags ein Resümee über die Einsatzfähigkeit von KI im Bauwesen gezogen wird.

3 Einführung in die künstliche Intelligenz sowie das maschinelle und tiefe Lernen

In [2, 3] und im vorherigen Abschnitt wurden die technologischen Grundlagen der digitalen Transformation als essenzielle Voraussetzung zur Erzeugung, Speicherung und Verarbeitung von Daten kurz beschrieben. Darauf aufbauend liefert dieser Abschnitt eine knappe Einführung in die Themen künstliche Intelligenz (engl. *Artificial Intelligence/AI*), maschinelles Lernen (engl. *Machine Learning/ML*) und tiefes Lernen (engl. *Deep Learning/DL*). Die Ausführungen basieren auf Standardliteratur zu künstlicher Intelligenz (KI) [14–18]. In [2, 19] finden sich ausführlichere Einführungen der Autoren in die Thematik der KI und des ML bzw. DL. Darüber hinaus gibt [14] insbesondere eine lehrbuchähnliche Einführung in KI-Themen mit Schwerpunkt Bauingenieurwesen.

3.1 Grundlagen zu KI-Algorithmen, Modellen und Daten

Betrachtet man Bild 2a, so erkennt man, dass KI der Oberbegriff für alle Entwicklungen im Bereich der künstlichen Intelligenz ist, die sich hauptsächlich mit der Automatisierung von intelligentem und emergentem Verhalten befasst [20]. Das Konzept der KI wurde im Jahr 1956 auf einer Konferenz an der Dartmouth Universität erstmals vorgestellt [21, 22] und entwickelte sich

später u. a. in die Zweige des ML und DL bis in die heutige Zeit weiter. Da diese beiden Zweige der KI insbesondere für die Fachleute des Bauingenieurwesens und verwandter Disziplinen künftig immer stärker in den Alltag integriert werden, werden relevante Begriffe und Inhalte nachfolgend vorgestellt.

Machine Learning/maschinelles Lernen ist eine Unterform der künstlichen Intelligenz, die es Systemen ermöglicht, aus vorgegebenen Daten zu lernen und nicht durch explizite Programmierung Handlungen, Befehle oder Entscheidungen auszuführen bzw. zu treffen. Um maschinelles Lernen anwenden zu können, bedarf es drei wesentlicher Voraussetzungen:

- (große) Menge an verfügbaren Daten,
- eine Struktur (Pattern) in den Daten,
- ein mathematisches Modell/markierte Daten sind vorhanden (Supervised Learning, dt. überwachtes Lernen) oder nicht (Unsupervised Learning, unüberwachtes Lernen).

Ziel des ML ist es, künstliches Wissen aus Erfahrungen (den Daten) zu generieren. Eine Grundannahme ist jedoch, dass die aus den Daten gewonnenen Erkenntnisse verallgemeinert und für neue Problemlösungen, für die Analyse bisher unbekannter Daten oder für die Vorhersage (Prädiktion) ungemessener Daten genutzt werden können. Eine Übersicht zum maschinellen Lernen ist in Bild 3 dargestellt.

Beim *Deep Learning/tiefen Lernen* nutzt man sog. künstliche neuronale Netze, um vor allem Muster in unstrukturierten Daten wie Bilder oder Videos zu erkennen. Ein künstliches neuronales Netz basiert auf einer Hintereinanderschaltung von verbundenen Neuronen, welche dem menschlichen Gehirn nachempfunden sind (s. Bild 4). Demzufolge empfängt ein künstliches Neuron ein Signal, verarbeitet dieses und kann dann damit verbundenen Neuronen Signale weitergeben. Aufgrund ihrer Fähigkeit, nichtlineare Prozesse zu reproduzieren und zu modellieren, haben

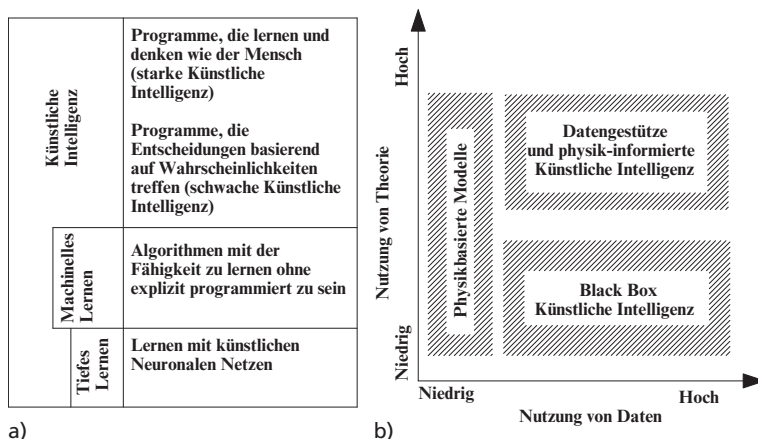


Bild 2. Schematische Zeichnung a) der Hierarchie von künstlicher Intelligenz, maschinellern und tiefem Lernen und b) der Verwendung von Daten und Theorie in verschiedenen Umgebungen, um eine physik-informierte KI zu erhalten [2]

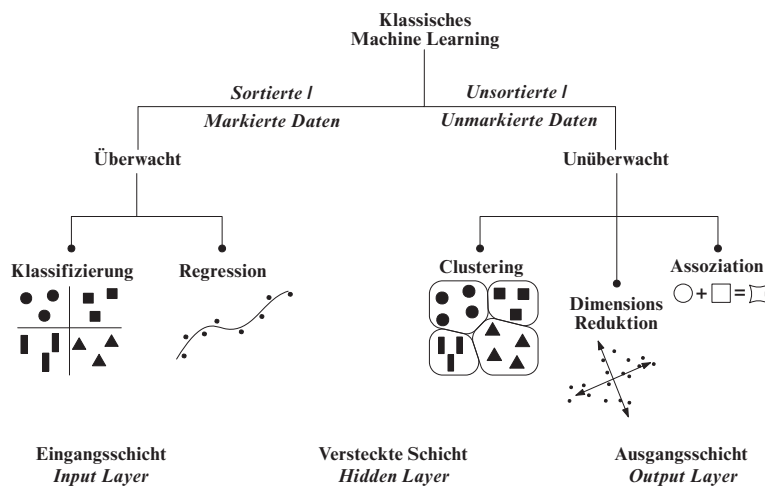


Bild 3. Übersichtsdarstellung des maschinellen Lernens und spezifische Unterscheidung zwischen supervised und unsupervised learning [2]

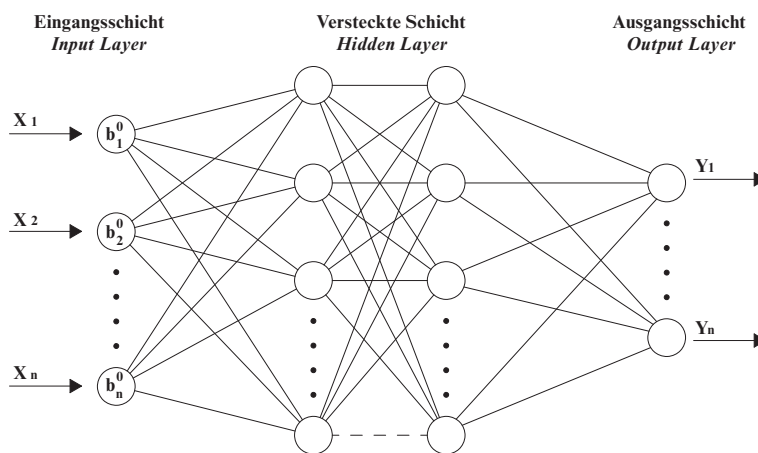


Bild 4. Darstellung eines neuronalen Netzwerks mit einem Input Layer, zwei Hidden Layer und einem Output Layer [2]

künstliche neuronale Netze in vielen Bereichen Anwendung gefunden. Einsatzgebiete sind unter anderem Systemidentifikation und -steuerung (Fahrzeugsteuerung, Prozesssteuerung), Mustererkennung (Radar-systeme, Gesichtserkennung, Signalklassifizierung, 3D-Rekonstruktion, Objekterkennung und mehr), Sequenzerkennung (Gesten-, Sprach-, Handschrift- und Texterkennung), medizinische Diagnose, Social Network Filtering und E-Mail-Spamfilterung.

Komponenten und Formulierung des Lernproblems der künstlichen Intelligenz

Algorithmen und Modelle sind wesentliche Bestandteile für die Anwendung von KI auf praktische Probleme, wobei ein Algorithmus als ein Satz eindeutiger Regeln definiert ist, die einem KI-Programm gegeben werden, damit es selbstständig lernen kann. *Mitchel* und *Frochte* [24, 25] definieren ein „lernendes“ Computerprogramm wie folgt:

„Ein Computerprogramm lernt von der Erfahrung *E* in Bezug auf eine Klasse von Aufgaben *T* und das Leistungsmaß *P*, wenn sich seine Leistung bei den Aufgaben in *T*, gemessen an *P*, mit der Erfahrung *E* verbessert.“

Bevor im Detail auf die Aufgabe *T* (z. B. bestimmte Schäden in entsprechenden Bildern erkennen) und das Leistungsmaß *P* (d. h., wie gut die KI die Aufgabe *T* erfüllt) eingegangen wird, sollen eingehender die Erfahrung *E* und die Rolle von Daten für KI, ML und DL betrachtet werden. Die Erfahrung *E* ist in diesem Zusammenhang ein beliebiger Datensatz *D*, dessen einzelne Elemente als Datenpunkte bezeichnet werden [18]. Ein Datenpunkt besteht in der Regel aus sog. Features oder Charakteristika, wobei ein Feature eine individuelle messbare Eigenschaft eines beobachteten Phänomens ist [26, 27]. Das Konzept eines Features steht in engem Zusammenhang mit der sog. unabhängigen Variablen in statistischen Verfahren wie bspw. der linearen Regression. Darüber hinaus kann die Erfahrung *E* weiter aufgespalten werden, um Ziele/Label zu trennen, wobei ein KI-Algorithmus dann verwendet wird, um Beziehungen zwischen den verbleibenden Features und dem Target des Datensatzes aufzudecken.

Abschließend ist anzumerken, dass KI-Modelle oder -Algorithmen weitere interne Parameter, sog. Hyperparameter besitzen, die inhärente, regulierbare Parameter zur Steuerung der Struktur des Algorithmus, wie bspw. die Stärke der Regularisierung oder die Tiefe

eines neuronalen Netzes, darstellen und während der Lern- oder Trainingsphase untersucht, variiert und optimiert werden müssen, um das geeignetste Modell zu trainieren und zu evaluieren [28].

Daten

Um Daten sinnvoll verarbeiten zu können, müssen sie zunächst gesammelt und gegebenenfalls aufbereitet bzw. vorverarbeitet werden [18, 24, 25, 29, 30]. Nach [25, 31] können fünf Größen zur Charakterisierung eines Datensatzes verwendet werden:

- Volumen: Datenmenge,
- Geschwindigkeit: Informationsfluss,
- Vielfalt: Format von Daten (strukturiert, halbstrukturiert oder unstrukturiert),
- Richtigkeit: Notwendigkeit von Pre-Processing,
- Wert: Relevanz der Daten für die Aufgabe T.

Während sich die ersten drei Punkte „Volumen, Geschwindigkeit und Vielfalt“ auf die Datengenerierung, den Erfassungs- und Speicherungsprozess beziehen, kennzeichnen die Aspekte „Richtigkeit“ und „Wert“ die Qualität und Zweckmäßigkeit der Daten für die betrachtete Aufgabe T und sind somit entscheidend für eine Extraktion von wertvollem Wissen aus den Daten. Wenn alle fünf Aspekte der vorgeschlagenen Liste bis zu einem gewissen Grad gegeben sind, spricht man von „Big Data“ bzw. großen Datenmengen. Aus technischer Sicht bezieht sich der Begriff große Daten auf große und komplexe Datenmengen, die „intelligente Methoden“ zu ihrer Verarbeitung erfordern.

Bezüglich der Daten sind weitere Definitionen zu präzisieren. **Strukturierte Daten** sind Informationen, die ein vordefiniertes Datenmodell haben [25, 30, 32], d. h., der Ort jedes Elements der Daten sowie der Inhalt sind genau bekannt. **Semi-strukturierte Daten** unterliegen keiner allgemeinen Datenstruktur, sondern tragen einen Teil der Strukturinformation mit sich. Insbesondere sind hier aber Markierungen enthalten, um semantische Elemente zu trennen und Hierarchien von Datensätzen und Feldern innerhalb der Daten zu finden [25, 32]. Schließlich sind unstrukturierte Daten Informationen, die entweder kein vordefiniertes Datenmodell haben oder nicht in referenzielle Tabellen eingegliedert sind [25, 32]. Typische Beispiele für strukturierte Daten sind Datenbanken oder Tabellen, während Videos oder Bilder klassische Beispiele für unstrukturierte Daten sind. In Tabelle 1 sind Beispiele für strukturierte und unstrukturierte Daten gegeben.

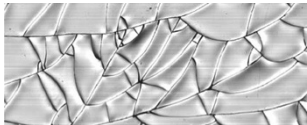
Während bei strukturierten Daten die Definition von Features aufgrund der Struktur meist sehr einfach ist [29, 33], ist die Generierung von Features (d. h. die Definition von Merkmalen) bei unstrukturierten Daten mühsam, sodass man für diesen Prozess eine eigene Bezeichnung formuliert hat, nämlich das sog. Feature Engineering [34]. Große Datenmengen können in der Regel mit modernsten KI-Algorithmen in einfacher Art und Weise verarbeitet werden, während eine große Anzahl von Features problematisch werden kann (Curse of Dimensionality) [25]. Eine der Hauptaufgaben liegt hier in der systematischen Unterscheidung in relevante und irrelevante Features [18]. Um dieser Problematik zu begegnen, können sowohl sog. Dimensionsreduktions- als auch Feature-Extraktionsverfahren durchgeführt werden, um Features entsprechend ihrer Relevanz für die Beschreibung der Aufgabe T zu reduzieren und/oder auszuwählen. Weitere Einzelheiten dazu werden im später folgenden Abschnitt 3.2 gegeben oder können in [26] nachgelesen werden.

Zusammenfassend ist festzustellen, dass für die praktische Anwendung von KI auf Probleme im Bauwesen die endgültige Wahl der Algorithmen von Fall zu Fall in Abhängigkeit von der Aufgabe T und dem Volumen, der Vielfalt und der Richtigkeit der Daten getroffen werden muss, was nur über die notwendige Erfahrung mit dem Umgang diverser Algorithmen im Kontext KI möglich ist.

Modelle und Verlustfunktionen

Eine Aufgabe T ist die Beschreibung, wie eine künstliche Intelligenz Datenpunkte verarbeiten soll. Ein Beispiel für eine Aufgabe T aus dem Bauwesen ist bspw. die Klassifizierung von Bauwerken in einen intakten oder defekten Zustand. Ähnlich zu regelmäßigen Bauwerksprüfungen, in denen Baufachleute anhand von Inspektionen (Datenakquise) Aussagen zum Zustand eines Bauwerks treffen, soll nun diese Aufgabe über eine KI gelöst werden, wobei die Eingangssignale hier keine Inspektion, sondern vielmehr bspw. Live-Messdaten aus dem Schwingverhalten des Bauwerks sind. Das Leistungsmaß P in diesem Beispiel bewertet die Fähigkeiten eines KI-Algorithmus zur Vorhersage des korrekten Labels, hier intakt oder defekt. Als Leistungsmaß P kann bspw. die Richtigkeit des Klassifikationsmodells verstanden werden, wobei die Korrektheit der Anteil der Beispiele ist, für die das Modell den korrekten Output produziert [18].

Tabelle 1. Exemplarische Darstellung von strukturierten Daten in Tabellenform sowie unstrukturierte Daten in Form eines Fotos, in dem das Bruchbild von gebrochenem Glas abgebildet ist [19]

Strukturierte Daten					Unstrukturierte Daten
	Feature 1 Height h	...	Feature M Thickness t	Target Y Strength f_{mk}	
Data Point 1					
...					
Data Point N					

Die Wahl eines geeigneten Leistungsmaßes P ist nicht trivial und objektiv, sondern hängt vom jeweiligen Problem ab und ist daher ein fester und wichtiger Bestandteil beim Aufbau eines ML-Projekts. Da sich dieser Beitrag vornehmlich mit ML- und DL-Beispielen befasst, beinhaltet die Aufgabe T immer ein mathematisches Modell M . Wenn nun ein KI-Algorithmus trainiert wird, aktualisiert der KI-Algorithmus ein mathematisches Modell so, dass für die gegebene Erfahrung E unter stetiger Anpassung der inhärenten Modellparameter bzw. Wichtungsfaktoren des Modells eine bessere Leistung P erzielt wird. Der Performance-Gewinn, also die Verbesserung der Prognosegenauigkeit des KI-Algorithmus, wird durch (numerische) Optimierung erzielt, sodass eine alternative bzw. mathematisch korrekte Nomenklatur für P benannt werden kann, nämlich die Formulierung einer Ziel-, Verlust- oder Kostenfunktion C . Übernimmt man die Notation nach [18], so bezeichnet man aus mathematischer Sicht eine Funktion, die minimiert oder maximiert werden soll, als Zielfunktion oder Kriterium. Die Verlustfunktion selbst operiert auf einem einzigen Datum, wohingegen die Kostenfunktion die Verlustfunktion über alle zur Verfügung stehenden Daten auswertet. Das mathematische Modell M eines KI-Algorithmus verfügt allgemein über zu optimierende Parameter θ und lernt aus dem Training auf dem Datensatz (oder kurz: Daten) D bzw. über die Minimierung der Kostenfunktion C die Parameter anzupassen:

$$\theta_{\text{opt}} = \arg \min_{\theta} C(\theta|D) \quad (1)$$

wobei typische Verlustfunktionen wie folgt lauten:

- Quadratic/L2 loss: $\|y - f(x|\theta)\|_2^2$ (least squares),
- Lp loss: $\|y - f(x|\theta)\|_p$,
- Entropy loss (dt. Entropieverlust),
- Accuracy (dt. Genauigkeit).

Es wird ausdrücklich betont, dass die Definition der Verlustfunktion Teil des Modellbildungsprozesses innerhalb des KI-Algorithmus ist und die Trainingsergebnisse in hohem Maße beeinflusst [25].

Datenverarbeitung/Datensplit

Nach einer etwaigen Aufbereitung und Visualisierung der Daten werden typischerweise verschiedene KI-Modelle parallel ausgewertet, um deren Performance untereinander zu prüfen. Das Hauptziel ist es, ein robustes KI-Modell mit einer guten Generalisierungsfähigkeit des extrahierten Wissens auf Daten zu erhalten, die beim Training des Modells durch den Lernalgorithmus nicht verwendet wurden [26]. Dies bedeutet, dass das finale Modell nach Abschluss des Trainingsprozesses die Trainingsdaten korrekt vorhersagen sollte, während es gleichzeitig auch in der Lage ist, eine korrekte Prognose für bisher ungesehene Daten zu treffen. Eine schlechte Generalisierung kann durch Overtraining oder Overfitting gekennzeichnet sein (vgl. Abschnitt 3.2), was den Zustand beschreibt, dass das Modell die Trainingsbeispiele nur auswendig lernt. Demzufolge ist das Modell nicht in der Lage, robuste und

allgemeingültige Prognosen zu treffen. Bezogen auf die Performance des KI-Modells bezüglich des Trainingsdatensatzes bzw. Validierungsdatensatzes ist der Fehler minimal, wohingegen der Fehler beim Testdatensatz erheblich ist.

Diese beiden entscheidenden Anforderungen (gute Vorhersage von Trainingsdaten sowie gute Verallgemeinerbarkeit auf Testdaten) sind gegensätzlich und auch als Bias- und Varianz-Dilemma bekannt [26]. Um zu beurteilen, wie gut die Performance eines ML- oder DL-Modells in Bezug auf Daten ist, gibt es verschiedene Methoden zur objektiven Evaluation (d. h. Validierung) [28]:

- Holdout Validierung,
- K-fold cross Validierung,
- Stratified K-fold cross Validierung,
- Leave-one-out cross Validierung (LOOCV).

Die einfachste Methode zur Validierung eines KI-Modells ist die sog. Holdout-Validierung, bei welcher der Datensatz über einen festen Prozentwert in Trainings- und Testdaten aufgeteilt wird [18, 25]. Die Verwendung der Holdout-Methode ist für die Modellbewertung bei der Analyse von Daten mit relativ großen Stichprobengrößen akzeptabel [28]. Dennoch kann gezeigt werden, dass insbesondere die Three-Way-Holdout-Validierung Vorteile bietet. Bei der Three-Way-Holdout-Methode werden die verfügbaren Trainingsdaten so aufgeteilt, dass ein zusätzlicher Validierungsdatensatz innerhalb des Trainingssets gebildet wird [15]. Zur genaueren Beschreibung werden die drei Datensätze wie folgt eingeteilt und verwendet:

- Trainingsdatensatz: Fit des Modells M an Trainingsdaten (70 % von D),
- Validierungsdatensatz: Unvoreingenommene Bewertung des Modells M an 20 % des Datensatzes und Fine-Tuning der Hyperparameter (20 % von D),
- Testdatensatz: Unvoreingenommene Bewertung eines finalen KI-Modells anhand der restlichen Daten (10 % von D).

Alle Daten in den drei Teildatensätzen sollten eine ähnliche Verteilung in Bezug auf den gesamten Datensatz haben, um sicherzustellen, dass die Daten aus derselben Verteilung stammen und repräsentativ sind.

Um dem Problem des sogenannten Over- und Underfitting (d. h. der schlechten Generalisierbarkeit des KI-Modells, vgl. nächster Abschnitt) zu begegnen, kann die Cross Validation (CV, dt. Kreuzvalidierung) für das Hyperparameter-Tuning und die Modellauswahl verwendet werden. CV ist eine Validierungstechnik zur Beurteilung, wie die Ergebnisse einer statistischen Analyse zu einem unabhängigen Datensatz verallgemeinert werden können [28]. Die k-fache Kreuzvalidierung hat zum Beispiel einen einzigen Parameter k , der sich auf die Anzahl der Gruppen bezieht, in die ein bestimmter Datensatz unterteilt wird. Daher wird das Verfahren oft auch als k-fache Kreuzvalidierung bezeichnet, wobei k durch die spezifische Wahl den konkreten Namen vorgibt (s. Bild 5).



Bild 5. Beispiel einer 5-fachen Kreuzvalidierung bezogen auf Trainings- und Testdaten [2]

Im Gegensatz dazu kann die Aufteilung der Daten in Gruppen durch Kriterien wie beispielsweise die Sicherstellung, dass jede Gruppe den gleichen Anteil an Beobachtungen mit einer bestimmten kategorischen Variable enthält, gesteuert werden. Dies wird als stratified k-fold cross validation bezeichnet.

Wenn jedoch ein kleiner Datensatz mit einer geringen Feature-Anzahl und weniger als 100 Dateneinträgen vorhanden ist, so hat sich herausgestellt, dass die Genauigkeit und Robustheit der KI-Modelle durch LOO-CV-Validierung zu guten Ergebnissen führt. Bei diesem Ansatz wird genau ein Datenpunkt aus den Trainingsdaten weggelassen, d. h., wenn n Datenpunkte in der ursprünglichen Stichprobe vorhanden sind, dann werden $n - 1$ Stichproben zum Trainieren des Modells und $p = 1$ Punkte als Validierungssatz verwendet. Dies wird für alle Kombinationen wiederholt, bei denen die ursprüngliche Stichprobe auf diese Weise separiert wurde. Die Anzahl der möglichen Kombinationen entspricht der Anzahl der Datenpunkte in der ursprünglichen Stichprobe n und kann daher im Falle eines großen Datensatzes rechenintensiv sein. Weiterführende Literatur zur Datenverarbeitung und hier im Speziellen zum Split der Daten ist in [28, 35] gegeben.

Over- und Under-fitting

Zwei zentrale Herausforderungen beim Trainieren eines KI-Modells durch Lernalgorithmen sind an dieser

Stelle einzuführen und näher zu erläutern: over- und under-fitting.

Ein KI-Modell ist anfällig für ein under-fitting, wenn es nicht in der Lage ist, einen ausreichend niedrigen Wert der Verlustfunktion auf dem Trainingsset zu erzielen, während ein over-fitting dann auftritt, wenn sich der Trainingsfehler signifikant vom Test- oder Validierungsfehler unterscheidet. Speziell beim over-fitting konvergiert der Trainingsfehler auf einen Wert von null, wohingegen der Validierungsfehler deutlich von null abweicht, sodass Trainings- und Validierungsfehler divergieren [18, 25].

Der Generalisierungsfehler (engl. generalization error) weist typischerweise eine U-förmige Form als Funktion der Leistungsfähigkeit des Modells auf, was in Bild 6 dargestellt ist. Bei der Wahl eines einfacheren Modells ist es wahrscheinlicher, gut zu verallgemeinern (mit einer kleinen Diskrepanz zwischen Trainings- und Generalisierungsfehler) und gleichzeitig eine ausreichend komplexe Hypothese zu wählen, um einen niedrigen Trainingsfehler zu erreichen. Trainings- und Testfehler verhalten sich während des Trainings eines KI-Modells durch einen Lernalgorithmus typischerweise unterschiedlich [25]. Bei näherer Betrachtung von Bild 6 wird am linken Ende der Grafik deutlich, dass sowohl der Trainingsfehler als auch der Fehler bei der Verallgemeinerung hoch sind. Dies kennzeichnet also das Under-fitting-Regime. Mit zunehmender Ka-




Bild 6. Schematische Darstellung für die Fehlerentwicklung bezogen auf ein Trainings- und Testdatenset sowie Darstellung der Under-fitting- und Overfitting-Zone [2]

azität des Modells nimmt der Trainingsfehler ab, während der Abstand zwischen Trainings- und Generalisierungsfehler zunimmt.

3.2 Machine Learning/Maschinelles Lernen

Maschinelles Lernen ist ein Teilbereich von KI, der sich mit Algorithmen zur Automatisierung der Lösung komplexer Probleme befasst, die mit herkömmlichen Methoden nur schwer explizit zu programmieren sind. ML-Algorithmen bauen ein mathematisches Modell M auf, um auf der Grundlage von Daten zwischen relevanten Größen (Merkmale; Zielen) zu schließen und Vorhersagen oder Entscheidungen zu treffen – ohne explizit dafür programmiert zu sein [20, 25, 36]. Grundsätzlich lassen sich für maschinelles Lernen zwei verschiedene Algorithmientypen unterscheiden: überwachtes (supervised) und unüberwachtes (unsupervised) Lernen [24]. Typischerweise existiert ein markierter Datensatz $D = (x_n, t_n)$ mit N Beobachtungen, wobei x_n die Feature-/Einflussvariable und t_n die Ziel-/Antwortvariable ist. Beide Variablen können kontinuierlich oder diskret (kategorisch) vorliegen. Während beim beaufsichtigten Lernen ein prädiktives Modell M entwickelt werden soll, das sowohl auf Features als auch auf Antwortvariablen aufbaut, wird beim unüberwachten Lernen ein Modell nur auf der Basis der Features trainiert (Clustering; Dimensionsreduktion).

Beim **überwachten Lernen (supervised learning)** wird zwischen Klassifikations- und Regressionsproblemen unterschieden. Während im ersten Fall die Antwortvariablen t_n nur diskrete Werte annehmen können, liegen die Antwortvariablen t_n bei Regressionsproblemen kontinuierlich. Das Ziel der Regression ist es, den Wert einer oder mehrerer kontinuierlicher Zielvariablen t ausgehend vom Feature-Vektor x vorherzusagen, wohingegen die Klassifizierung darauf abzielt, einen Input-Vektor x einer von K diskreten Klasse zuzuordnen, wobei $k = 1, \dots, K$ [26].

Ein Beispiel für ein Regressionsproblem aus dem Bauwesen, bei dem es um die Prädiktion des bewerteten Schalldämmmaßes (Label) für unterschiedliche Verglasungen (Feature-Raum besteht aus Glasdicken, Isoliergläser, Verbundgläser, Interlayer-Eigenschaften) geht, wurde in [37] vorgestellt. Das ML-Modell basiert auf komplexen Entscheidungsbäumen, die miteinander in einer Ensemble-Strategie verschaltet wurden. Als Eingabe muss der spezifische Glasaufbau definiert werden und als Ausgabe erhält man dann das bewertete Schalldämmmaß, hier den RW-, STC- und OITC-Wert. Das Schalldämmmaß ist ein logarithmisches Maß und beschreibt das Vermögen eines Bauteils oder Übergangs zwischen zwei schallführenden Bauteilen oder Medien, den Schall zu dämmen. Das Tool und dessen Layout als Web-App ist in Bild 7 dargestellt, wohingegen der Eingangsvektor im Sinne

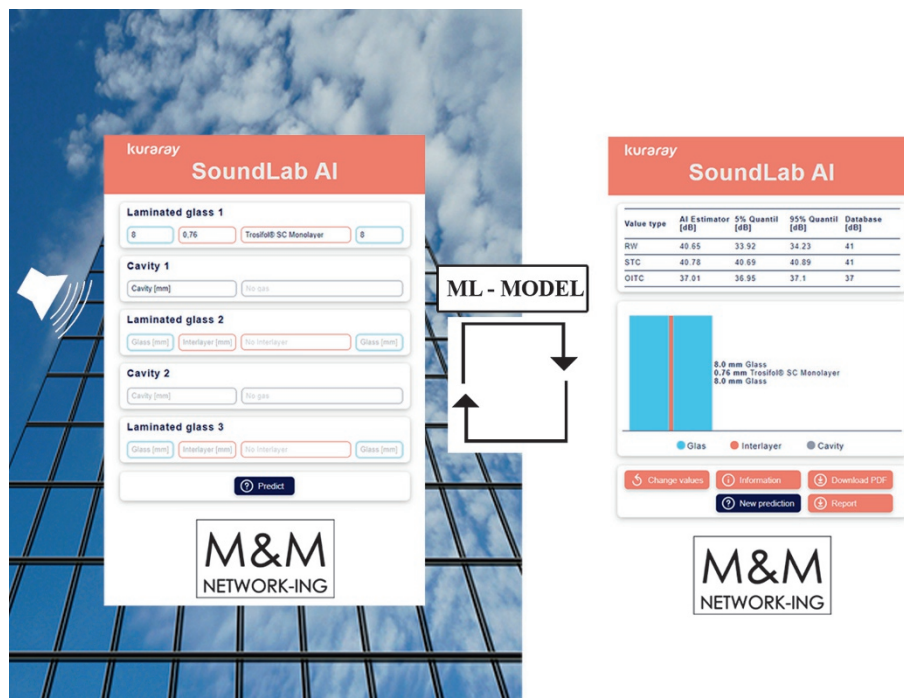


Bild 7. ML-Modell zur Vorhersage des bewerteten Schalldämmmaßes für beliebige Glasaufbauten von Verbundglas und Isolierglas (© M&M Network-Ing/Kuraray Europe GmbH)

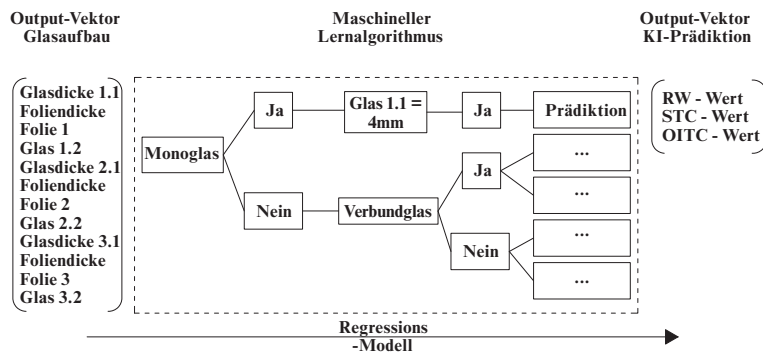


Bild 8. ML-Modell zur Vorhersage des bewerteten Schalldämmmaßes für beliebige Glasstrukturen mit Darstellung der Eingangsgrößen, des Lernalgorithmus als Entscheidungsbaum und der Ausgangsgrößen (© M&M Network-Ing/Kuraray Europe GmbH)

der Kombinationen unterschiedlicher Glasaufbauten, der Lernalgorithmus als Entscheidungsbaum-Regressor und der Output-Vektor im Sinne der bewerteten Schalldämmmaße in Bild 8 dargestellt sind.

In Bild 3 (rechts) sind die wichtigsten Typen von Algorithmen für **unüberwachtes Lernen (unsupervised learning)** dargestellt. Diese Algorithmen verwenden lediglich Inputdaten, um Struktur, Muster und Gruppen ähnlicher Objekte innerhalb der Daten zu entdecken (Clustering), die Verteilung der Daten innerhalb des Inputraums zu bestimmen (Dichteschätzung) oder die Daten aus einem hochdimensionalen Raum in niedrigere Dimensionen zu projizieren [14, 38]. Beim unüberwachten Lernen geht es also um die Inferenz einer Funktion zur Beschreibung einer verborgenen Struktur/Mustern in Daten, die vollständig unmarkiert (keine Label) sind. Diese Beschreibung kann nützlich sein, um Daten besser zu verstehen und vor allem in Bezug auf ihren hochdimensionalen Parameterraum in einen Unterraum mit wenigen Dimensionen zu transformieren. Darüber hinaus ist es manchmal sinnvoll, diese reorganisierten Daten als Input für überwachtes Lernen anstelle des ursprünglichen Inputs zu verwenden.

Cluster-Algorithmen verwenden Ähnlichkeits- oder Abstandsmaße zwischen Objekten im Feature-Raum als Verlustfunktionen, um Objekte in verschiedene Cluster zu gruppieren [39]. Im Gegensatz zum überwachten Lernen verwenden Clustering-Algorithmen nur eine Divide-and-Conquer-Strategie, um die Eingabedaten zu interpretieren und natürliche Gruppen oder Cluster im Feature-Raum zu finden [40]. Typische Clustering-Algorithmen sind „k-means“ [14, 26, 41] und die „Gaussian Mixture“ [14].

Ähnlich wie bei Clustering-Methoden zielt die Dimensionsreduktion darauf ab, inhärente, latente Muster (engl. Pattern) in Daten durch Anwendung von Algorithmen auf die wesentlichen Hauptfeatures zu reduzieren [42]. Dem praktisch tätigen Ingenieur sollte diese Methode geläufig sein in Bezug auf die Reduktion eines dreidimensionalen Spannungszustands mit neun Komponenten und deren Übertragung in die bekannt-

ten Hauptspannungen, bei denen nur noch drei Einträge im Spannungstensor vorliegen, was das Ergebnis der Dimensionsreduktion ist.

Durch die Reduktion der Eingabedimensionen (d. h. Anzahl der Features) werden weniger Parameter oder eine einfachere Struktur im ML-Modell erzielt, sodass sich die Freiheitsgrade und die zu optimierenden Parameter ebenfalls reduzieren [43]. Ein Modell mit zu vielen Freiheitsgraden führt oft zum Overfitting des Trainingsdatensatzes und kann daher neue Daten mäßig generalisieren [43]. Auf weitere Einzelheiten zu typischen Algorithmen des unüberwachten Lernens wie Principal Components Analysis (PCA), Manifold Learning oder Autoencoders wird auf die entsprechende Fachliteratur verwiesen [25, 40, 43].

Liegt eine Kombination von überwachtem und unüberwachtem Lernen vor, spricht man vom **semi-überwachten Lernen (semi-supervised learning)**. Beim halbüberwachten Lernen lernt die Maschine aus einer Mischung von markierten und nicht markierten Beispielen, um Vorhersagen zu treffen (bspw. Klassifizierung). So kann sie bspw. eine Anomalieerkennung durchführen, indem sie lernt, wie normale bzw. ungestörte Verhaltensweisen aussehen. Auf die Darstellung weiterer und speziellerer Arten des Lernens einer KI wie das **bestärkende Lernen (reinforcement learning)** oder das **aktive Lernen (active learning)** wird in diesem Beitrag mit dem Verweis auf die bereits zitierte Literatur nicht eingegangen.

Historisch gesehen verwendet ML statistische Features, die durch unüberwachte Lernmethoden gewonnen werden (bspw. Clusteranalyse, Dimensionsreduktion, Autoencoder usw.). Ein allgemein etabliertes Schema für ein erfolgreiches ML-Projekt ist in Bild 9 dargestellt.

In Schritt 1 und 2 werden vorhandene Daten zusammengestellt und in eine Form gebracht, auf die das AI/ML-Modell zugreifen kann, sodass der Lernalgorithmus in der Lage ist, das Modell auf den vorhandenen Daten zu trainieren. Dieser Schritt kann in Abhängigkeit von der Problemstellung und der Daten-




Bild 9. Schematischer Ablauf eines ML-Projekts vom Einlesen der Daten bis hin zum fertigen Prädiktionsmodell [2]

struktur der jeweiligen Umgebung Minuten bis Monate dauern. Es ist ratsam, dafür standardisierte Auswerterroutinen bzw. -protokolle und -codes in Betracht zu ziehen, um die Datenkonsistenz innerhalb eines Pre-Processing zu gewährleisten. In Schritt 3 geht es um die Feature-Definition bzw. die Extraktion von Features aus dem Input-Datensatz. Die Anzahl der Features, die aus den Daten abgeleitet werden können, ist theoretisch unbegrenzt, jedoch werden einige spezielle Techniken oft für verschiedene Arten von Daten verwendet. Beispielsweise besteht die Aufgabe der Feature-Auswahl darin, aus rohen Sensordaten bestimmte Signalmerkmale zu extrahieren, um Informationen auf höherer Ebene zu erzeugen. Feature-Extraktionstechniken in diesem Zusammenhang sind die Detektion von Peaks, die Extraktion von Frequenzinhalten durch Fourier-Transformationen, die Identifizierung von Signaltrends durch Summenstatistik (Mittelwert und Standardabweichung zu verschiedenen Versuchszeitpunkten) usw. Weitere Einzelheiten zu den einzelnen Schritten können [38, 44, 45] entnommen werden. Im Schritt 4 geht es um das Training von ML-Modellen. Die Auswahl des optimalen ML-Modells in Bezug auf dessen Hyperparameter wird in Schritt 5 definiert, wobei in diesem Schritt insbesondere Methoden der Kreuzvalidierung und der Optimierung der Hyperparameter einzelner Modelle stattfinden. Ein Hyperparameter ist im ML-Kontext ein Parameter, dessen Wert zur Steuerung des Lernprozesses verwendet wird bzw. den Lernalgorithmus direkt betrifft und nicht durch das Training angepasst wird. Ist das optimale ML-Modell gefunden, so wird in Schritt 6 das Modell auf neue Daten angewendet, um Prädiktionen zu machen.

3.3 Deep Learning/Tiefes Lernen

Tiefes Lernen ist ein Teilgebiet des ML [18], das sogenannte künstliche neuronale Netze als Modelle verwendet, um Muster und hochgradig nichtlineare Zusammenhänge in Daten zu erkennen. Ein künstliches neuronales Netz (KNN) bzw. Artificial Neural Network (ANN) basiert auf einer Ansammlung von miteinander verbundenen Knoten (Neuronen). Heute sind viele funktionale Architekturen neuronaler Netze für spezifische Aufgaben aus dem Bereich der Computer Vision (Bildererkennung, Mustererkennung), Natural Language Processing (Schrifterkennung, Spracherkennung, Semantik) sowie Zeitreihenanalyse (Wetter, Aktien, Preisentwicklungen etc.) bekannt [46].

Aufgrund ihrer Fähigkeit, nichtlineare Prozesse zu reproduzieren und zu modellieren, haben künstliche neuronale Netze in vielen Bereichen, auch im Bauwesen, Anwendung gefunden. Dazu gehören die Materialmodellierung und -entwicklung von Glas [19], Zustandsüberwachung von Brücken [47], Mustererkennung in der Produktionskontrolle bei der Herstellung von Bauprodukten wie bspw. Verbundsicherheitsglas [19] und Risserkennung in Betonbauteilen über Computer Vision [48]. Die besondere Fähigkeit von NN durch die selbst durchgeführte Feature-Extraktion der Inputdaten ermöglicht es, diese KI-Anwendungen zeitlich effizient mit sehr hohen Prädiktionsgenauigkeiten durchzuführen.

Für künstliche neuronale Netze existieren zwei wichtige Architekturen, die für den Einstieg in das Thema im Folgenden beschrieben werden. Eine ist die des sog. Feedforward Neuronalen Netzes (FNN) und die zweite ist die der für die Analyse von Bild- und Videodaten sehr effizienten gefalteten neuronalen Netze (Convolutional Neural Network) (CNN), s. Bild 10.

Das FNN ist durch Verbindungslayer aufgebaut, die aus mehreren Neuronen bestehen. Eine schematische Darstellung ist in Bild 10a gezeigt. Die erste Schicht (0) des FNN ist der Eingangslayer, die letzte Schicht (L) ist der Ausgangslayer und die dazwischen liegenden Layer werden als versteckte Layer (engl. hidden layer) (l) bezeichnet. Ein Neuron ist als Operator definiert, welcher durch folgende Gleichung beschrieben werden kann:

$$b_k^l = \sigma \left(\sum_{j=1}^{K^{l-1}} w_{kj}^l b_j^{l-1} + b_k^l \right) := \sigma \left(\hat{b}_k^l \right) \quad (2)$$

wobei $\sigma(-)$ eine monotone kontinuierliche Funktion ist und allgemein als Aktivierungsfunktion bezeichnet wird. Die Aktivierung wird als Linearkombination der Neuronen in der vorhergehenden Schicht $l-1$ unter Berücksichtigung der entsprechenden Gewichte w^l und dem Bias b^l der Schicht l berechnet. Die Wahl der schichtweisen Verbindung der Neuronen kann durch den Anwender stark unterschiedlich gewählt werden. Wenn jedes Neuron mit allen Neuronen in seinen Nachbarschichten verbunden ist, wird das FNN als dicht oder dicht verbunden bezeichnet. Zusammengefasst stellen FNN eine spezifische Familie von parametrisierten Abbildungen dar, die surjektiv sind, wenn der Ausgabelayer eine lineare Aktivierungsfunktion besitzt, welche ausgedrückt werden kann als

$$y = f_n \cdot \dots \cdot f_1(x) \quad (3)$$

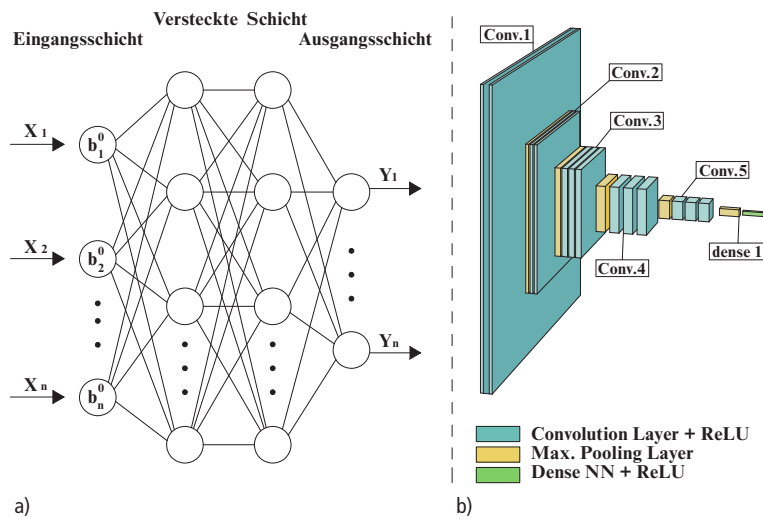


Bild 10. Schematische Darstellung von unterschiedlichen Netzwerkarchitekturen; a) Feedforward neuronales Netzwerk und b) Faltungsnetzwerk [2]

wobei $f_n = \sigma(w \cdot x + b)$ die Datentransformation in einer Schicht l darstellt.

Ein Neuron ist mit dieser Definition eine nichtlineare, parametrisierbare Funktion von Eingangsgrößen (Eingangsneuronen; links in Bild 10). Ein neuronales Netz ist folglich eine mathematische Zusammensetzung nichtlinearer Funktionen von zwei oder mehr Neuronen über eine Aktivierungsfunktion. Diese besondere Natur von NNs ist daher in der Lage, nichtlineare Eigenschaften, Prozesse und Verhaltensweisen zu identifizieren und zu modellieren, die möglicherweise durch klassische ML-Methoden wie Regressions-techniken oder PCA nicht oder nur ungenügend erfasst werden. Trotz der biologischen Inspiration des Begriffs neuronales Netz ist ein NN im maschinellen Lernen ein rein mathematisches Konstrukt. Wenn es mehr als drei verborgene Layer (engl. hidden layer) gibt, wird dieses NN als tiefes NN bezeichnet. Die Entwicklung der „richtigen“ Architektur für ein NN oder tiefes NN ist problemabhängig und muss individuell vorgenommen werden. Hilfestellungen für den Aufbau spezieller NN-Architekturen werden in [25, 49] gegeben. Gefaltete (neuronale) Netzwerke (CNN) stellen eine spezielle Art von NN dar für die Verarbeitung von Daten mit einer sog. gitterartigen Topologie [16, 18]. Beispiele sind Zeitreihendaten (1D-Gitter, das in regelmäßigen Zeitintervallen Stichproben entnimmt) und Bilddaten (2D-Pixelgitter). Im Gegensatz zu FNN verwenden die CNN die mathematische Operation der Faltung (engl. Convolution), die eine spezielle Art der allgemeinen Matrix-Multiplikation in mindestens einem ihrer Layer ist. Zusätzlich zur Faltung wird auf die Daten zwischen den Schichten eine Pooling-Operation angewendet, durch die überflüssige Informationen verworfen werden.

Eine insbesondere für ingenieurwissenschaftlich interessante Fragestellungen geeignete Architektur des tiefen Lernens stellen sog. **Generative Adversarial Net-**

works (GANs) (etwa: erzeugende gegnerische Netzwerke) dar. Diese sind neuartige generative Modellierungssysteme, welche bisher hauptsächlich genutzt wurden, um realistisch aussehende Bilder und Videos oder Texte aus vorliegenden Datensätzen zu erzeugen. Die Idee des Lernens von GANs besteht darin, dass zwei verschiedene KI-Systeme gegeneinander antreten, s. Bild 11. Das eine System (der Generator) versucht, realistisch aussehende Daten x^* (z. B. Bilder) zu erzeugen (s. Bild 11 unten), wobei das gegnerische KI-System (der Diskriminator) versucht zu erkennen, welche Daten gefälscht (x^*) und welche echt (x) sind (s. Bild 11 oben), somit liegt beim Diskriminator ein Klassifizierungsproblem nach Abschnitt 3.2 vor [50–52]. Typischerweise bildet der Generator aus einem Vektor von latenten Variablen z (s. Bild 11) auf den gewünschten Ergebnisraum ab, sodass die erzeugten Daten x^* einer bestimmten statistischen Verteilung folgen. Die Zielfunktion des Generators ist, Daten x^* so zu erzeugen, dass diese der Diskriminator nicht von echten Daten x unterscheiden kann. Bekannte GAN-Varianten wie Pix2Pix, Cycle-GAN, progressive GANs, DeepFake etc. ermöglichten bereits viele neue Anwendungen des maschinellen Lernens in der Medizin und anderen Bereichen.

Eine insbesondere für die Planungsphasen im Bauwesen interessante Variante des GAN stellt die des bedingten GANs (conditional GAN/cGAN) dar. Hier werden dem Trainingsprozess von Generator und Diskriminator nach Bild 11 die zusätzlichen Informationen aus den geforderten Bedingungen (z. B. eine gewünschte Farbe eines generierten Objekts) zur Verfügung gestellt, s. Bild 12.

Einige der vorbeschriebenen Varianten von GANs werden im Abschnitt 4.2.1 verwendet, um unter gegebenen Randbedingungen in der Bauwerkslebenszyklusphase des Entwurfs einerseits realistische Wohnungsgrundrisse zu generieren oder im Zuge der sta-

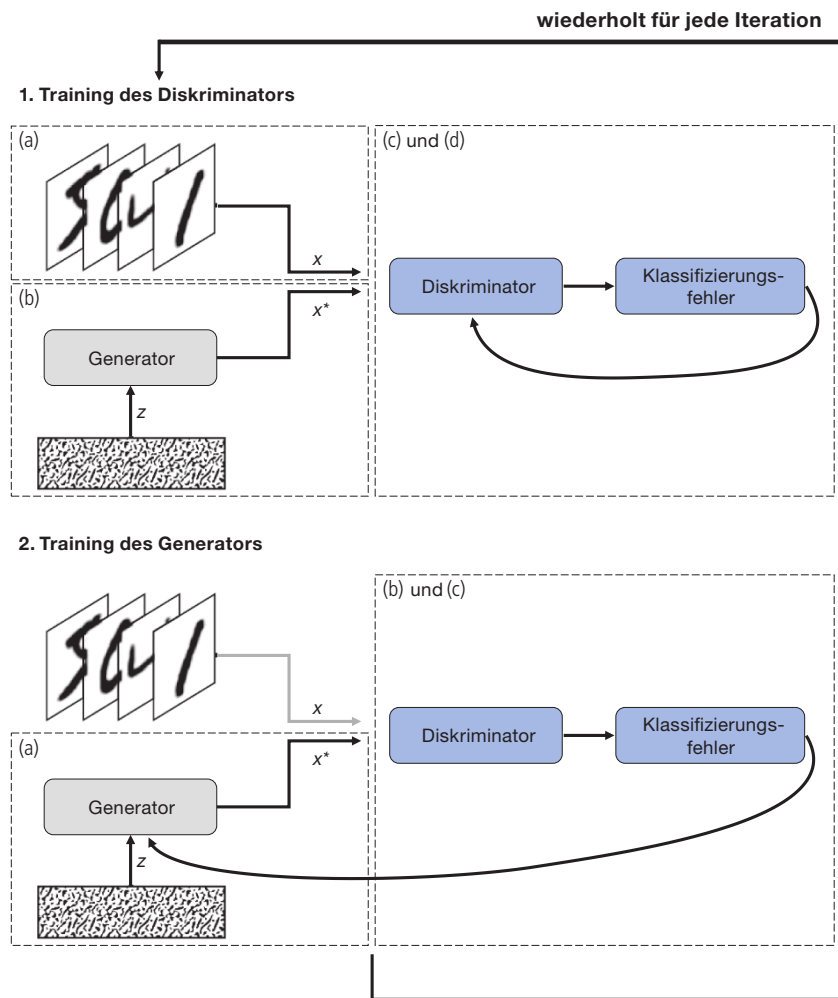


Bild 11. Schematische Darstellung des Trainings eines GANs; (oben) Training des Diskriminator-Netzwerks, (unten) Training des Generator-Netzwerks

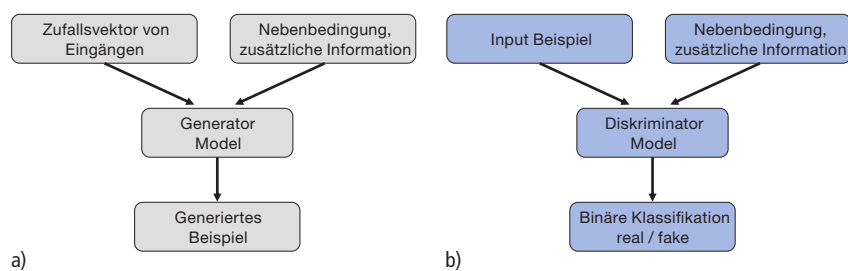


Bild 12. Schematische Architektur eines bedingten GANs (cGAN); a) Generator-Netzwerk, b) Diskriminator-Netzwerk

tischen Berechnung statisch zulässige Mauerwerksaufbauten von einer KI vorgeschlagen zu bekommen. Weitere bekannte NN sind Recurrent Neural Networks (RNN, dt. rekurrende Neuronale Netze) zur Verarbeitung sequenzieller Daten [18, 53], Autoencoder zur Dimensionsreduktion oder zur Feature-Extraktion [18, 54] und Transformers, die für die Verarbeitung sequenzieller Daten, wie bspw. natürliche Sprache, für Aufgaben wie Übersetzung und Textverdichtung ausgelegt sind. Auf Anwendungen der KI im Bereich der Sprachverarbeitung (Natural Language Processing), Textanalyse (Text Mining) sowie Wissensrepräsentation und Schlussfolgerung (Knowledge Representation and Reasoning) wird an dieser Stelle mit dem Verweis auf [2] verzichtet.

4 Anwendungsbeispiele zum Einsatz von künstlicher Intelligenz im Wohnungsbau

4.1 Hintergrundinformationen zu Lebenszyklusphasen von Gebäuden

Immobilien gehören zu den wichtigsten Gütern einer Gesellschaft und tragen maßgeblich zu einer leistungsfähigen und voll funktionsfähigen Infrastruktur einer Volkswirtschaft bei. Diese sind in Form von Wohnraum für Privatperson zur Sicherung der Lebensqualität unersetzlich, stellen für Unternehmen eine maßgebliche Raum- und Flächenressource dar und besitzen für die Öffentlichkeit kulturelle Bedeutung. Die Bereitstellung, Bewirtschaftung und Wiederverwertung dieser Immobilien ist deshalb ein bedeutender Wirtschaftszweig, weshalb politische oder ökonomische Beeinträchtigungen signifikante volkswirtschaftlich negative Folgen nach sich ziehen. Der sich derzeit in vielen westlichen Ländern abzeichnende gesellschaftliche Wandel hin zu einer schrumpfenden und immer älteren Generationenstruktur impliziert auch einen Wandel zu Lebens- und Wohnvorstellungen, welche Planende und Ausführende berücksichtigen müssen. Während das Zusammenleben ab den 1950er-Jahren für Familien mit standardisierten Wohnraumangeboten von drei Zimmern, Küche und Bad in Gesetze, Richtlinien und Förderinstrumente gefasst wurde, verändert sich die Haushaltsstruktur seit ca. den 1970er-Jahren im Zuge der Individualisierung zu einer größeren Zahl von Einpersonenhaushalten. Zentrales Kriterium für den künftigen Planungs- und Bauprozess von Wohnraum ist daher die Integration von Kreativität mit einer wachsenden Zahl an zu beachtenden Rahmenbedingungen bei gleichzeitiger Aufrechterhaltung der Qualität einzelner Komponenten. Nur dann können funktional und ökonomisch nachhaltige Gebäude entstehen, die sich langfristig den sich kontinuierlich verändernden Bedingungen und Einflussfaktoren anpassen können.

In [55, 56] werden wichtige Aspekte der Kooperation in interdisziplinären Expertenteams anhand einiger erfolgreich durchgeführter Infrastrukturprojekte der jüngeren Vergangenheit herausgearbeitet. Demnach liegt ein Erfolgsfaktor in der interdisziplinären Zusammensetzung des Teams der am Entwurf Beteiligten. Moderne Entwurfsaufgaben im Wohnungsbau umfassen neben den klassischen ingenieurtechnischen Themen wie Statik, Bauphysik und Wirtschaftlichkeit auch die funktionale Architektur bis hin zur individuellen Ästhetik. Diese Multi-Kriterien-Aufgabe kann somit nur in erfolgreicher Zusammenarbeit gemeistert werden, wenn alle Teammitglieder ein hohes Maß an fachlicher Kompetenz und die Bereitschaft zu gegenseitigem professionellen Austausch, insbesondere verbunden mit der Offenheit gegenüber den Ideen der anderen Teammitglieder, mitbringen. Ein zweites Schlüsselement ist die Teamstruktur im konzeptuellen Entwurfsprozess selbst: Bei Aufgaben der Kreativität sollte auf eine Hierarchie verzichtet werden, wohingegen bei organisatorischen Angelegenheiten wie Fristen oder Ergebnisse zur Garantie einer gewissen Effizienz und Verantwortungsallokation diese etabliert werden sollte. Das dritte Schlüsselement liegt in der fachlichen Kompetenz, aber auch Erfahrung der beteiligten Akteure unter Nutzung entsprechender Technologien wie Fachsoftware und BIM sowie künftig möglicherweise immer stärker auch künstlicher Intelligenz.

Bei der voranschreitenden Digitalisierung aller Bereiche des täglichen privaten und beruflichen Lebens (vgl. Abschnitt 2) kommt der effizienten Erfassung, Aus- und Bewertung von Daten eine immer größere Rolle zu. Grundsätzlich verspricht die digitale Transformation (DT) über die aktuell in der Praxis ankommende BIM-Methode bis hin zur künftig eingesetzten KI eine signifikante Verschiebung und Reduktion des Planungsaufwands gegenüber dem Status quo in die frühen Phasen eines Bauprojekts. Somit ergeben sich Kosteneinsparungen bei gleichzeitiger Steigerung der Effizienz und Entscheidungssicherheit durch Daten (s. Bild 13).

Der Wohnungsbau bietet zahlreiche Anwendungs- und Einsatzmöglichkeiten für KI über die verschiedenen Aufgaben der jeweiligen Stadien des Immobilienlebenszyklus und den jeweilig vorhandenen rechenbaren Bauwerksinformationen im Wohnungsbau. Im Rahmen dieses Abschnitts wird herausgearbeitet, in welchem Maße KI bereits heute in der entsprechenden Bauphase eingesetzt wird, welche Voraussetzungen dafür notwendig sind und welche Vor- und Nachteile und Potenziale sich durch die KI ergeben. Aus mehreren Gründen haben sich (übergreifende) KI-Systeme bisher kaum in der Baupraxis durchgesetzt, insbesondere weil sich die Forschung dazu bisher oft auf enge und spezialisierte Teilaufgaben konzentrierte, nicht aber auf realmaßstäbliche und integrierte Probleme. Das in [57] vorgeschlagene Konzept der *Digital Twin Construction* (DTC) ist ein neuer Arbeitsmodus im Bauwesen zur Verschränkung von BIM, des Lean-




Bild 13. Effekte von BIM und KI auf die Verschiebung des Planungsaufwands gegenüber dem Status quo in verschiedenen Bauphasephasen [4]

Construction-Gedankens, des Digitaler-Zwilling-Konzepts und der KI. Im weiteren Verlauf wird der Einsatz des DTC anhand von Beispielen aus dem Wohnungsbau dargestellt.

4.2 Lebenszyklusphase „Entwurf“

4.2.1 Konzeptioneller Entwurf (Raumprogramm und Grundrisse) mit generativer KI

Der Entwurf eines Wohngebäudes ist aufgrund der Problemstellung sowie Integration einer Vielzahl an Randbedingungen und Zielen ein zeitaufwendiger, iterativer Prozess mit nichtlinearen Ausarbeitungszyklen. Dem Prozess des Status quo folgend, liefern Architekturschaffende auf der Basis der qualitativen und quantitativen Wünsche der Bauherrschaft einen Entwurf, welcher dann gemeinsam bewertet wird. Daran schließt sich eine Vielzahl von Anpassungs- und Verfeinerungszyklen an, bis schließlich innerhalb eines bestimmten Zeit- und Planungsbudgets eine Lösung gefunden wurde, welche in der Regel pareto-optimal bleibt. Der Entwurf eines Raumprogramms zusammen mit entsprechenden Grundrissen kann heutzutage vornehmlich nur von professionellen Architekturbüros in effizienter Weise aufgrund deren Erfahrung und Ausstattung gestaltet werden, andererseits leisten sich nur ca. 10 bis 15% aller Bauherren aus Kostengründen eine professionelle Planung mit individuellen Gestaltungsmöglichkeiten. Ein KI-augmentierter Planungsprozess zur automatischen Erstellung von alternativen Wohnungsgrundrissen hat enorme Auswirkungen auf die Art und Weise, wie künftig erste Planungsphasen zwischen den verschiedenen Beteiligten eines Wohnungsbauprojekts ablaufen und insbesondere beschleunigt wird. Dieser Abschnitt behandelt daher die sich mithilfe der KI ergebenden neuen Möglichkeiten für die ganzheitliche ästhetisch-technische Gestaltung und Optimierung von Wohnimmobilien bereits in frühen Projektphasen.

Die Erstellung von Wohnungsgrundrissen geschieht aktuell als Abwägung der Kriterien der Bauherrschaft und entweder (i) der „menschlichen Intelligenz“

der Planenden aufgrund des Erfahrungsschatzes oder (ii) als iterative numerische Optimierung unter Verwendung entsprechender Spezialsoftware [58, 59]. Aktuelle Forschung in diesem Bereich nutzt hingegen dafür tiefe neuronale Netze und insbesondere Generative Adversarial Networks (GANs) bzw. bedingte GANs (cGANs), vgl. Abschnitt 3.3. Im Folgenden wird der in [60, 61] vorgestellte Ansatz „House-GAN++“ (s. Bild 14) zur automatisierten Generierung von Wohnungsgrundrissen unter Verwendung von cGANs vorgestellt, damit können innerhalb von Sekundenbruchteilen realistische Grundrissentwürfe erzeugt und zusammen mit dem menschlichen Planenden iterativ verfeinert werden. Aufgrund der Kürze dieses Beitrags wird auf die Darstellung der weitergehenden theoretischen Hintergründe mit dem Hinweis auf [60, 61] und Abschnitt 3.3 verzichtet.

Der Ansatz von „House-GAN++“ besteht darin, dass zunächst das von der Bauherrschaft gewünschte Raumprogramm topologisch als Blasendiagramm zum Aufzeigen von Entitäten (wie z. B. Anzahl der Bäder, Schlafzimmer etc.) und deren Relationen (z. B. mit welchen Zimmern ein Bad verbunden sein soll) dargestellt wird (s. Bild 14, links). Im nächsten Schritt wird daraus ein relationaler Graph erstellt, dieser kodiert (i) die Räume mit ihren Raumtypen als Graphknoten und (ii) die räumliche Nachbarschaft (Adjazenzen) als Graphkanten. Die spezielle Architektur von „House-GAN++“ erzeugt dann realistische und zu den Adjazenzbeschränkungen kompatible Wohnungslayouts und stellt diese als Menge achsenausgerichteter, rechteckiger Räume dar (s. Bild 14, mittig und rechts). Die Möglichkeiten und Arbeitsweisen mit „House-GAN++“ können geneigte Lesende unter dem Link <http://www.houseganpp.com> selbst in Augenschein nehmen und elaborieren. Dieser Prototyp einer den Entwurfsprozess begleitenden generativen KI stellt eine methodische Weiterentwicklung der seit wenigen Jahren in kommerzieller Planungssoftware verfügbaren Werkzeuge des generativen Designs [62, 63] dar. Die Verwendung von neuronalen Netzen für generatives Design von Brückenbauwerken wurde in [2] dargestellt.

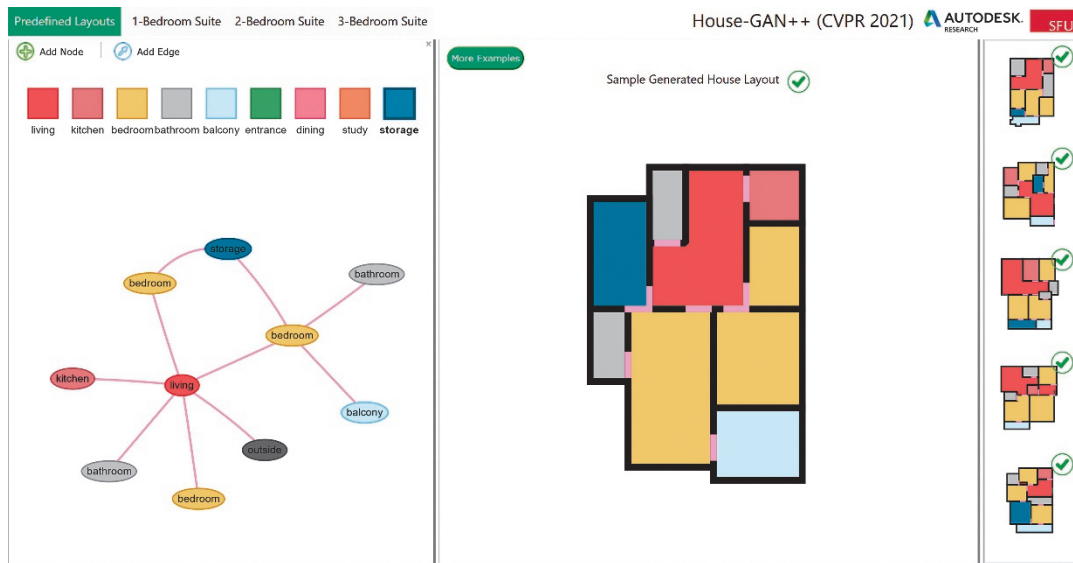


Bild 14. Beispielrealisierungen von Wohnungsgrundrissen mit „House-GAN++“; (links) Topologie des Raumprogramms, (Mitte) Instanz eines Wohnungsgrundrisses, (rechts) alternative Instanzen von Wohnungsgrundrissen, Quelle: houseganpp.com

4.2.2 KI-basierte Ersatzmodelle zur statischen Bemessung im Wohnungsbau

Im Zuge der statischen Bemessung von Immobilien kommen im Status quo zwar numerische Werkzeuge wie Nachweissoftware oder gar Finite-Elemente-Programme zum Einsatz. Die Nutzung numerischer Optimierungsalgorithmen zur Reduzierung von Konstruktionskosten oder der Diskussion möglicher Tragwerksalternativen im Bauwerksentwurf und -nachweis hingegen ist wenig verbreitet. Dabei versprechen numerische Algorithmen aber eine signifikante Hilfe bei der Suche nach optimalen Lösungen unter Berücksichtigung vorgegebener Ziele und Randbedingungen des Entwurfs. Vielfach liegt hier jedoch eine multikriterielle Optimierung vor, da neben der Statik auch andere Disziplinen wie die Bauphysik oder Bauausführung berücksichtigt werden müssen.

Die wiederholte Durchführung von statischen Berechnungen im Rahmen des Entwurfs ist zeitaufwendig, insbesondere können bei der Bauteiloptimierung ggf. mehrere Hundert Evaluierungen des Berechnungsmodells nötig werden. Die Anwendung von KI-Algorithmen ist hierbei insbesondere geeignet, den erwähnten Rechenaufwand über die Approximation des über das Berechnungsmodell hergestellten funktionalen Zusammenhangs zwischen Modelleingängen und -ausgängen deutlich zu reduzieren. Seit mehreren Jahren ist in der Forschung der Einsatz von KI-Algorithmen mit der Verwendung von Regressionsmodellen, Kriging-Modellen oder neuronalen Netzen zum Lösen der Curve-Fitting-Aufgaben, für die gemessene oder simulierte Daten verwendet werden oder als Beleg zur Erstellung eines Vorhersagemodells für die Verwendung in Pla-

nung und Ausführung eingesetzt werden kann [2, 19, 64, 65].

Die KI-basierten Ersatzmodelle approximieren den funktionellen Zusammenhang zwischen den Eingangs- und Ausgangsgrößen des statischen Berechnungsmodells durch entsprechende Algorithmen. In Bild 15 ist eine schematische Darstellung der KI-basierten Funktionalapproximatoren des Mauerwerkswandbemessungsproblems im Grenzzustand der Tragfähigkeit nach dem vereinfachten Nachweisverfahren auf der Basis von numerischen Simulationsdaten gegeben.

Der für die Kalibrierung der verschiedenen KI-Algorithmen genutzte Datensatz besteht ausschließlich aus synthetischen Daten einer Mauerwerkswandbemessung in Form eines semi-probabilistischen Spannungsnachweises für zentrische Druckbeanspruchung im Grenzzustand der Tragfähigkeit nach dem vereinfachten Nachweisverfahren, welche automatisiert mittels eines Python-basierten Skripts erzeugt wurden. Die Eingangsparameter (Features) und Zielgrößen der Untersuchung waren dabei sowohl geometrische als auch Materialparameter neben den Abminderungsfaktoren für die Ausmitte sowie Knicken, wie sie in der statischen Berechnung einer Mauerwerkswand verwendet werden (vgl. Tabelle 2).

Da die Trainingsdatenmenge im Gegensatz zu einem reinen Modellanpassungsproblem eine Physikkonsistenz sichert, bewegt sich diese Anwendung im Bereich der „physik-informierten“ künstlichen Intelligenz. Für diese Studie wurden verschiedene Algorithmen des überwachten ML und DL an insgesamt $N_S = 19\,115$ zur Verfügung stehenden Datensätzen trainiert, getestet und validiert. Die Liste der untersuchten Al-




Bild 15. Schematische Darstellung der Funktionalapproximation der statischen Wandbemessung im Grenzzustand der Tragfähigkeit durch ML/DL-Algorithmen

Tabelle 2. Zusammenfassung der Ein- und Ausgangsgrößen für die KI-Ersatzmodelle zur spannungsbasierten Mauerwerkswandbemessung im Grenzzustand der Tragfähigkeit

Eingangsgrößen (Features)	Ausgangsgrößen (Targets)
Bemessungswandkopflast N_{Ed} [kN/m]	Spannungsausnutzung $\eta_W = \sigma_{Ed}/f_d$ [-]
Wandhöhe h_s [m]	Abminderungsfaktor Φ_1 (Ausmitte) [-]
Wanddicke t [mm]	Abminderungsfaktor Φ_2 (Knicken) [-]
Wandbreite b [m]	
Charakteristische Mauerwerksfestigkeit f_k [MPa]	




Bild 16. Heatmap der Korrelationen der Features untereinander sowie mit den Zielgrößen

gorithmen (s. Bild 15) umfasst: (1) lineare Regression/Baseline Modell; (2) Entscheidungsbaum; (3) XG-Boost; (4) Feedforward Neuronales Netz; (5) Random Forrest; (6) Ensemble-Modell aus den Algorithmen (2)–(5). Es werden zwei KI-basierte Ersatzmodelle trainiert. Einmal für die Vorhersage der Spannungsausnutzung η_W und einmal für die Vorhersage des Abminderungsfaktors für Knicken Φ_2 . Als Leistungsmaß P (vgl. Abschnitt 3.1) wird in beiden Fällen die Wurzel des mittleren quadratischen Abstands (root mean squared error RMSE) zwischen wahrem Zielwert und KI-Vorhersage verwendet.

zung η_W und einmal für die Vorhersage des Abminderungsfaktors für Knicken Φ_2 . Als Leistungsmaß P (vgl. Abschnitt 3.1) wird in beiden Fällen die Wurzel des mittleren quadratischen Abstands (root mean squared error RMSE) zwischen wahrem Zielwert und KI-Vorhersage verwendet.

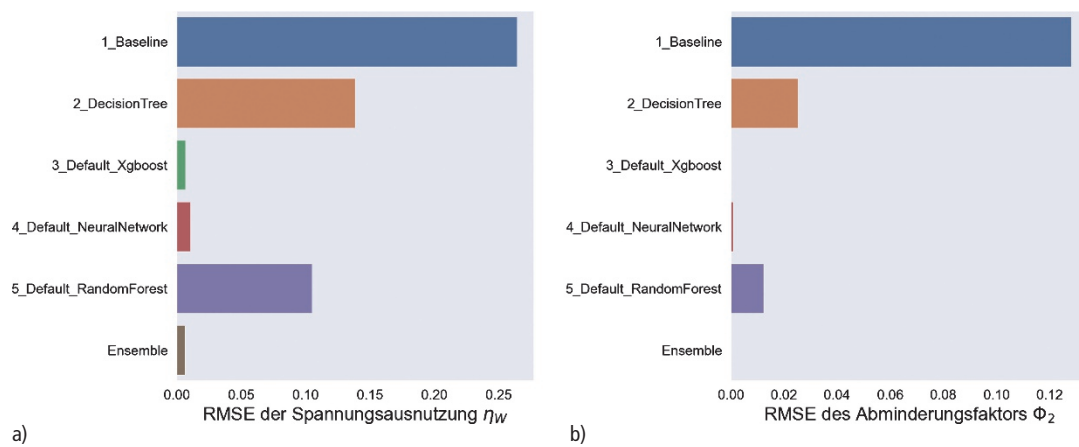


Bild 17. Ergebnisse der KI-Ersatzmodell-Kalibrierung: RMSE-Fehler der sechs trainierten KI-Ersatzmodelle für a) die Spannungsausnutzung η_W , b) den Abminderungsfaktor für Knicken Φ_2

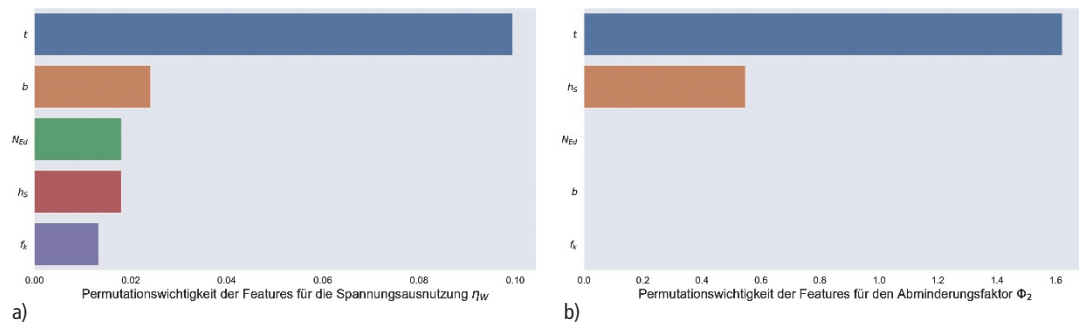


Bild 18. Ergebnisse der KI-Ersatzmodell-Kalibrierung: Permutationswichtigkeit der Features für a) die Spannungsausnutzung η_W , b) den Abminderungsfaktor für Knicken Φ_2

Dem standardisierten Ablauf einer KI-Modellkalibrierung laut Bild 9 folgend, werden zunächst Korrelationen im Datensatz untersucht, s. Bild 16. Aus den vorliegenden Korrelationen kann geschlossen werden, dass alle Features unabhängig voneinander sind (und somit keine Multikollinearität vorliegt) und als Eingang für die KI-Algorithmen verwendet werden können. Eine Plausibilitätsüberlegung zur Tendenz (positiv und negativ) und dem relativen Verhältnis der Korrelationen der Features zu den Zielgrößen bestätigt die Verwendbarkeit des gesamten Datensatzes.

Mithilfe eines Skripts zur automatisierten Kalibrierung mehrerer KI-Algorithmen mit standardisierter Nachlaufauswertung für einen gegebenen Datensatz werden die vorgenannten KI-Algorithmen trainiert. Dabei wird der Datensatz in ein Trainings- und Validierungsdatensatz im Verhältnis 75 % zu 25 % aufgeteilt und das Skript je Zielgröße ausgeführt. Die RMSE-Fehler für die untersuchten ML- bzw. DL-Algorithmen sind in Bild 17 dargestellt. Die performantesten Algorithmen stellen demnach Modelle aus den Familien XGBoost, Neuronale Netze und ein Ensemble

dar. Der signifikante Unterschied im RMSE zwischen den KI-Algorithmen und dem Regressionsmodell (Baseline) unterstreicht den Nutzen der KI-Ersatzmodelle gegenüber herkömmlichen statistischen Verfahren.

Wie aus Bild 17 ersichtlich, schneiden die XGBoost-Algorithmen [66] aus der Familie des Maschinellen Lernens für die Prädiktion der Druckspannungsausnutzung sowie des Knickabminderungsfaktors neben den Ensemblemodellen am besten ab. Daher beschränkt sich die weitere Diskussion ausschließlich auf die XGBoost-Modelle.

Zunächst können die relativen Sensitivitäten (Wichtigkeiten) der Features auf die jeweilige Zielgröße im entsprechenden XGBoost-Modell ermittelt werden, s. Bild 18. Für beide Zielgrößen, Spannungsausnutzung σ_W und Knickabminderungsfaktor Φ_2 , ist die dominierende Eingangsgröße die Wanddicke t . Da im vorliegenden (einfachen) Beispiel die analytischen Zusammenhänge sogar bekannt sind, können die Sensitivitäten unabhängig geprüft werden, wohingegen diese Auswertungen verständliche Konsistenzprüfungen

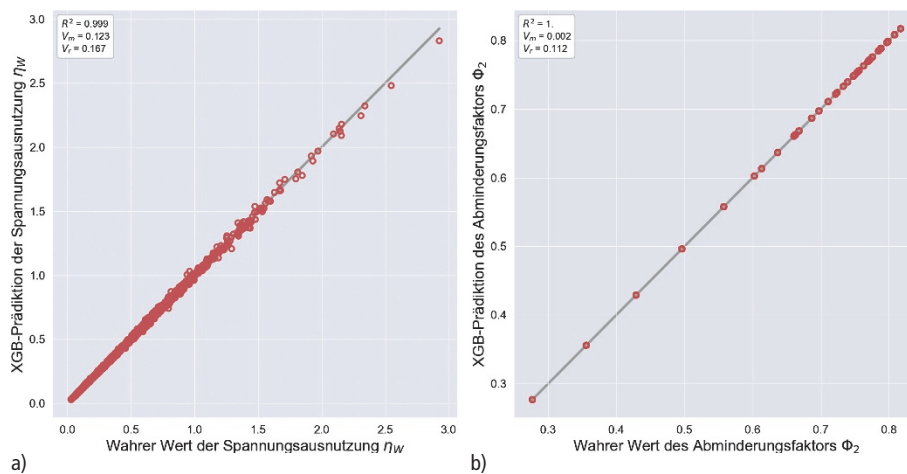


Bild 19. Ergebnisse der KI-Ersatzmodell-Kalibrierung: Diagnoseplot zum Vergleich von XGBoost-Prädiktion und Trainingsdaten für a) die statische Spannungsausnutzung η_w , b) den Abminderungsfaktor für Knicken Φ_2

gen und Modelleinsichten bei unbekannten komplexeren funktionalen Zusammenhängen zwischen Ein- und Ausgangsgrößen (wie z. B. bei Datensätzen aus Finite-Elemente-Berechnungen) erlauben. Insbesondere konnte das XGBoost-Modell die Unabhängigkeit des Knickabminderungsfaktors Φ_2 von sämtlichen Features außer der Wanddicke t und der Knicklänge h_s erlernen, s. Bild 18b.

Ein Vergleich der jeweiligen wahren Datenwerte mit den Vorhersagen der zutreffenden XGBoost-Modelle ist grafisch in Bild 19 dargestellt. Ein $R^2 \approx 1$ Wert bestätigt, dass die beiden trainierten und validierten XGBoost-Prädiktions-Modelle die Referenzwerte im Mittel realitätsnah abbilden können. Das Bestimmtheitsmaß ist in den Grenzen $0 \leq R^2 \leq 1$ definiert, sodass ein $R^2 \approx 1$ ein sehr gutes Ergebnis darstellt. Eine weitergehende statistische Analyse der Vorhersagen der XGBoost-Modelle hinsichtlich der Abweichungen von Vorhersage- zu Referenzwerten liefert Variationskoeffizienten von 0,17 für die Spannungsausnutzung und 0,11 für den Knickabminderungsfaktor. Mit diesen statistischen Kennwerten könnte nun ein Teilsicherheitsbeiwert für diese KI-basierten Ersatzmodelle mittels der im EC0 definierten zuverlässigkeitstheoretischen Methoden kalibriert werden, sodass eine baurechtliche Verwendung möglich ist.

Die hier dokumentierten Befunde zu den Datenanalyse- und Approximationsmöglichkeiten mit KI-Algorithmen bestätigen einerseits die Grundidee der Eignung von ML bzw. DL zur alternativen Modellierung der Funktionale zwischen Ein- und Ausgangsgrößen, weisen aber auch darauf hin, dass stets mehrere DL/ML-Algorithmen auf ihre Approximationsmöglichkeiten zu untersuchen sind. Ein Weitertraining der hier gezeigten KI-Modelle kann zu einer weiteren Verringerung der Abweichungen zwischen Referenz- und Prädiktionswerten führen, was eine Äquivalenz der KI-basierten Ersatzmodelle mit den Simulati-

onsmodellen rechtfertigt und sich für den Praxiseinsatz ohne Einbußen der Genauigkeit bei Steigerung der numerischen Effizienz darstellt.

Ein fortgeschrittenes Beispiel zur Kombination von Algorithmen des maschinellen und tiefen Lernens mit nichtlinearen Betonmaterialmodellen zu KI-FEM-Hybriden, welche sowohl in Bezug auf die erforderliche Rechenleistung als auch die Zuverlässigkeit der Vorhersage des Tragverhaltens wesentlich effizienter sind als etablierte numerische Analysemethoden zur Bemessung von Stahlbetontragwerken, ist in [2, 67] dargestellt. In [23, 68, 69] wurde unter Mitarbeit des Erstautors basierend auf einer Trainingsdatenmenge ein physik-informiertes DNN zur Prädiktion der Stabilitätsversagenslasten von quadratischen und rechteckigen Hohlprofilen erfolgreich kalibriert und mit zuverlässigkeitstheoretischen Methoden untersucht, sodass hier zum ersten Mal im Bauwesen ein Teilsicherheitsbeiwert für eine Methode der künstlichen Intelligenz im Rahmen einer Bemessung bestimmt wurde.

4.3 Lebenszyklusphase „Bau und Konstruktion“

Das Anwendungspotenzial von künstliche Intelligenz in der Lebenszyklusphase „Bau und Konstruktion“ ist enorm. Über die zeitliche Abfolge der Bauausführung, welche symbolisch mit der Grundsteinlegung startet, mit der Abnahme des Bauwerks durch den Bauherrn oder dessen Bauleitung [70] endet, finden derzeit die meisten Informationsanfragen und -austauschvorgänge zwischen den Akteuren statt. Während heutzutage die Bauausführung noch in den überwiegenden Fällen allgemein auf der Baustelle stattfindet, erlebt gerade die Vorfertigung infolge der voranschreitenden digitalen Transformation der Planungsprozesse sowie der Einbindung robotischer Fertigungstechniken eine Renaissance.

Wie in der Presse der jüngsten Vergangenheit ausreichend belegt, überschreiten die meisten Infrastrukturprojekte ein vorher gesetztes zeitliches oder monetäres Budget teilweise um ein Vielfaches, obwohl spezialisierte Projektteams und Steuerungsinstanzen eingesetzt werden. Hier können insbesondere künstliche neuronale Netze verwendet werden, um bei Projekten Zeit- und Kostenüberschreitungen auf der Grundlage von Faktoren wie Projektgröße, Vertragsart und Kompetenzniveau der Projektmanagenden vorherzusagen [71]. Historische Daten wie geplante Start- und Endtermine werden von Prognosemodellen verwendet, um realistische Zeitpläne für künftige Projekte zu erstellen. Dies ist besonders für den Wohnungsbau interessant, da hier die größte Datenbasis aufgrund der überwiegenden Anzahl an realisierten und dokumentierten Projekten im Vergleich zu anderen Infrastrukturprojekten wie Brücken oder Tunnel vorliegt. Weiterhin ist der Einsatz von KI in diesem Analyseszenario für größere Planungs- und Projektsteuerungsunternehmen sowie ausführende Baufirmen interessant, da diese i. d. R. über die notwendigen Datengrundlagen ad hoc verfügen. Damit lassen sich einerseits firmeninterne Erkenntnisse zu mangelhaften Prozessen über eine KI-Analyse der historischen Bauausführungsdaten zur Erarbeitung geeigneter Schulungsmaßnahmen für Mitarbeitende ableiten. Andererseits verspricht der Einsatz von KI zusammen mit den immer häufiger für Wohnungsbauprojekte vorliegenden BIM-Modellen oder digitalen Zwillingen eine beschleunigte Projektabwicklung.

Ein weiterer Einsatz von KI in der Bauausführung liegt in der Baufortschrittsüberwachung bzw. der Baufortschrittsanzeige. Während der Bauausführung hat die Bauleitung sehr unterschiedliche Aufgaben, dazu zählt auch die Baudokumentation aller Arbeitsphasen auf der Baustelle. Beispielsweise gehört in Deutschland nach der HOAI das Führen eines Bautagebuchs zu den Grundleistungen des Architekten in der Leistungsphase 8 „Objektüberwachung – Bauüberwachung und Dokumentation“. In der aktuellen Fassung der HOAI ist diese Anforderung beschrieben mit „Dokumentation des Bauablaufs (bspw. Bautagebuch)“ [72]. Das Ziel der Dokumentation liegt darin, den tatsächlichen Bauverlauf mithilfe der Aufzeichnungen zu rekonstruieren, festzustellen und mit dem geplanten Baufortschritt zu vergleichen (Soll-Ist-Vergleich). Als konkretes Beispiel wird hier die Baufortschrittsanzeige der Betonage eines Brückenpfeilers vorgestellt. Ziel ist es, mithilfe von KI und Computer Vision den aktuellen Baufortschritt mit dem geplanten Baufortschritt ohne menschliches Zutun zu vergleichen. Die Schwierigkeit besteht darin, eine adäquate Datengrundlage für die individuellen und zeitlich veränderlichen Bauvorhaben zu schaffen, um mit einer KI den Baufortschritt zu erlernen. Um dem small data Problem entgegenzutreten, ist es notwendig, Trainings- und Validierungsdaten in einer virtuellen Umgebung für das Individualbauwerk zu erzeugen. Abhilfe kann nur geschaffen werden, indem

ein digitaler Zwilling des Bauvorhabens, hier des zu bauenden Wohnobjekts, erstellt wird, welcher über die Zeit (Baufortschritt) wächst. Somit kann zusammen mit dem digitalen Zwilling der Baustelle, welche den gesamten Baufortschritt über die Zeit modelliert und als Video oder Bildabfolge exportiert, die notwendige Datengrundlage für eine entsprechende KI bereitgestellt werden. Die aus den Renderings des digitalen Zwillings trainierte KI ist dann anhand von Bilddaten der Baustelle in der Lage, aus zuvor definierten Positionen den Baufortschritt zu erkennen. Ein mögliches KI-Modell ist ein multivariater Zeitreihen-Klassifizierer basierend auf Bilddaten, der den Baufortschritt lernt und richtig mit Realbilddaten klassifiziert.

Schließlich soll eine (nicht abschließende) Anwendung von künstlicher Intelligenz auf der Baustelle, welche ebenfalls im Bereich der Computer Vision liegt, benannt werden: die Bauüberwachung und das Überprüfen des Einhaltens sicherheitsrelevanter Maßgaben. Die Problemstellung aus der Sicht der künstlichen Intelligenz besteht darin, anhand von Bildmaterial von Sicherheitskameras auf der Baustelle Objekte wie Schutzhelme, Warnwesten und Sicherheitsschuhe korrekt zu identifizieren. Erkennt die KI Arbeiter ohne Schutzausrüstung auf der Baustelle, so kann diese Information an den zuständigen Bauleitenden weitergegeben werden, um Abhilfe zu schaffen und die Arbeitssicherheit auf der Baustelle zu verbessern. Die KI verwendet dazu geeignete neuronale Netze aus der Objektdetektion [73]. Beispielsweise wurde die Residual Network (ResNet) Architektur zunächst an dem frei zugänglichen „ImageNet“ Datensatz verwendet und nachtrainiert, um die Objektdetektion auf der Baustelle durchzuführen [74]. Hierzu werden also gelabelte Bilder von der Baustelle in das vortrainierte neuronale Netz eingeladen und die letzten Layer dann auf die spezifische Aufgabenstellung der Objektdetektion auf der Baustelle angepasst. Dieser Ansatz ist effektiv, weil das neuronale Netzwerk auf dem großen Bestand von Bilddaten des „ImageNet“ trainiert wurde und das Modell Vorhersagen für eine relativ große Anzahl von Klassen treffen muss, was wiederum voraussetzt, dass das Modell effizient gelernt hat, Merkmale aus Bilddaten zu extrahieren, um bei dem Problem gut abzuschneiden. Wissenschaftler der Stanford University betonen jedoch die Wichtigkeit, sorgfältig auszuwählen, wie viel des vortrainierten Modells in das neue Modell übertragen werden soll. Dies liegt daran, dass die Merkmale von Faltungsnetzen in den frühen Schichten allgemeiner und in den späteren Schichten spezifischer für den Originaldatensatz sind, sodass man unter Umständen einen Bias im neuronalen Netz erhält. Exemplarisch ist der Ablauf der Objekterkennung auf der Baustelle in Bild 20 dargestellt.

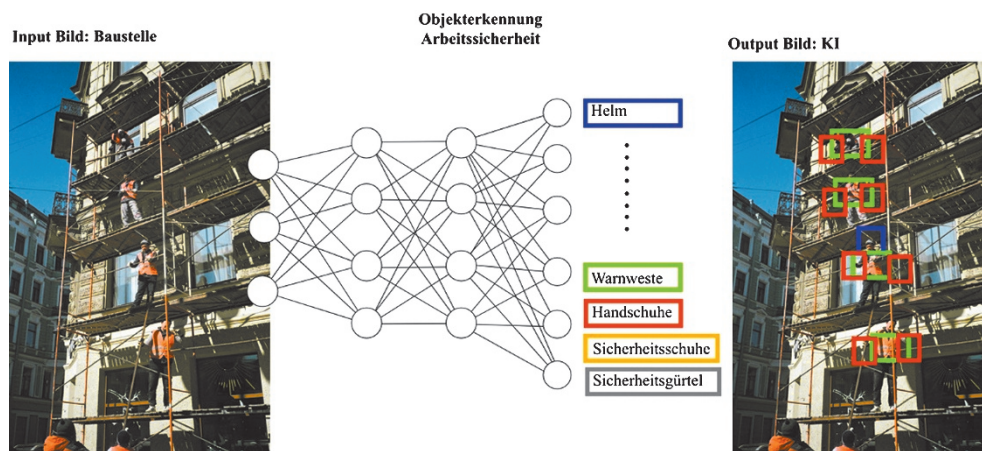


Bild 20. Darstellung der Objekterkennung auf der Baustelle mit Bezug auf Arbeitssicherheit und dem durch KI Erkennen von Schutzausrüstung [2]

4.4 Lebenszyklusphasen „Betrieb und Instandhaltung“

In der Lebenszyklusphase des Betriebs und der Instandhaltung eines Bauwerks geht es um die Sicherstellung eines reibungslosen Betriebs des Bauwerks zur Generierung eines Nutzens für Dritte sowie die Erzielung wirtschaftlicher Einnahmen durch die Nutzung des Bauwerks zur Amortisierung der Baukosten. Hierbei steht insbesondere die Vermeidung von unnötigen Kosten durch Schäden im Fokus, welche typischerweise in geplanten Inspektionsintervallen im Rahmen

von Revisionen und Bauwerksprüfungen durchgeführt werden [75]. Werden dabei Schäden festgestellt, muss in Abhängigkeit der Schwere der angetroffenen Schäden entweder eine Reparatur ausgelöst werden oder im Falle gravierender Mängel ein Sanierungs- und Instandhaltungskonzept erarbeitet und umgesetzt werden. Betrachtet man die Lebenszykluskosten von Bauwerken, so machen die Nutzungskosten und der Betrieb ca. 70 bis 85 % der Gesamtkosten eines Immobilienobjekts aus. Gerade die Kosten der Betriebsphase können bei lebenszyklusoptimierter Planung deutlich reduziert werden, s. Bild 21.




Bild 21. Schematische Darstellung der kumulierten Kosten über die Zeit [76]

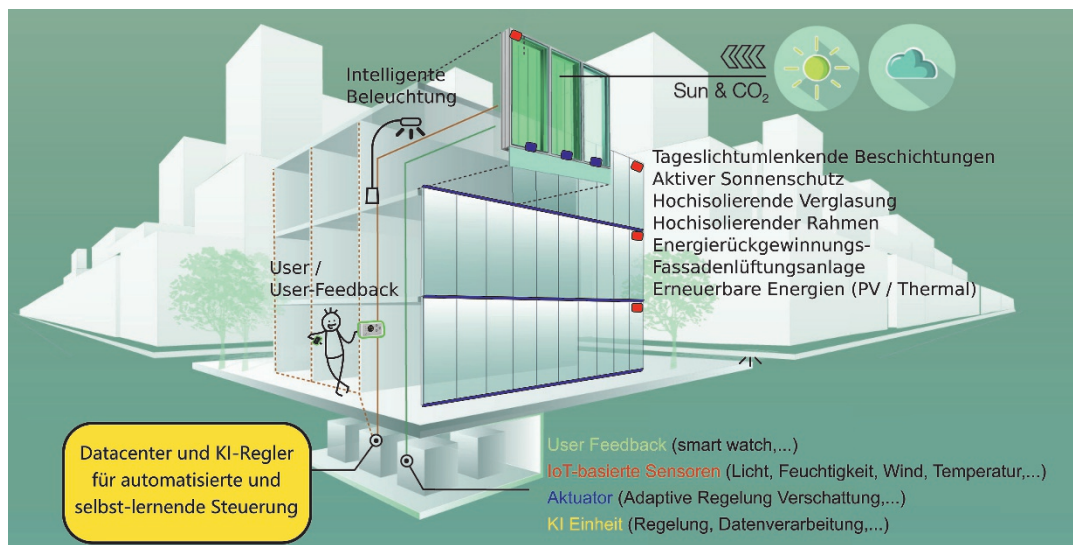


Bild 22. Schematische Darstellung einer cyber-physikalischen Fassade mit Interaktion von Nutzer und KI-Kontrollzentrum [90]

Eine lebenszyklusoptimierte Planung beinhaltet klassischerweise die o. g. Intervall-Inspektionen, um lange Nutzungsausfälle des Bauwerks vorzubeugen. Die derzeit durchgeführten Inspektions- und Wartungspraktiken für Immobilien sind jedoch nach wie vor wenig effizient und führen zu einer erheblichen Energieverschwendung. Die derzeit immer häufigere Digitalisierung der Gebäudetechnik im Rahmen des Internet of Things (IoT), wie es auch immer häufiger im Bereich von Wohn- und Gewerbeimmobilien anzutreffen ist, bietet Möglichkeiten zur zentralen Erfassung, Verarbeitung und Steuerung von Daten und Handlungen. Moderne Verfahren, gerade auch aus der Luft- und Raumfahrt, verwenden jedoch keine periodischen Instandhaltungsmaßnahmen, wie sie üblich im Bauwesen sind, sondern greifen auf das Predictive Maintenance Konzept zurück. Die vorausschauende Instandhaltung lernt aus historischen wartungsbezogenen Daten und leitet daraus präventive Maßnahmen mit ggf. Echtzeit-Feedback an die Nutzer ab. Durch das Training geeigneter KI-Algorithmen des maschinellen und tiefen Lernens kann dann Kenntnis darüber erlangt werden, wann ein unerwünschtes oder schadhafte Ereignis in der Zukunft stattfindet oder wie Ausfällen vorgebeugt werden kann. Die Vorteile eines Predictive Maintenance Konzepts liegen in der Verhinderung ungeplanter Stillstände, der rechtzeitigen Vorhersage von Wartungszeitpunkten und führen damit zu einer Verbesserung der Planbarkeit, was sich direkt in den kumulierten Bauwerkskosten widerspiegelt. Im Bauwesen sind Predictive Maintenance Konzepte aktuell Gegenstand der Forschung [52] und insbesondere für Wohn- und Gewerbeimmobilien höchst aktuell [77, 78]. Ein besonders nutzerzentrierter Aspekt des Einsatzes von KI in der Lebenszyklusphase „Betrieb“ liefert das

Anwendungsbeispiel des Glas- und Fassadenbaus. In Zukunft werden beim Fassadenentwurf neben den Anforderungen an die Funktion als thermohygrische Barriere, dem Sonnenschutz und einem ansprechend ästhetischen Design weitere Punkte zum Nutzerkomfort oder der Interaktion mit der Fassade im Fokus stehen. In [90] ist eine innovative adaptive Steuerung der Fassade unter Verwendung von künstlicher Intelligenz zur Mehrziel-Pareto-Optimierung beschrieben, indem Modelle der KI mit dem digitalen Zwilling der Fassade zu einem cyber-physikalischen Regelkreis mit Benutzer-Feedback verbunden werden (s. Bild 22).

5 Potenziale und Zukunftstrends von künstlicher Intelligenz im Mauerwerks- und Wohnungsbau

5.1 Zukunftstrends für die Methoden der künstlichen Intelligenz

Aktuell befindet man sich in der dritten großen Welle der künstlichen Intelligenz [99], was deutlich im Gartner Hype-Cycle [100] für emergente Technologien erkennbar ist, in dem sich etwa ein Drittel der relevanten Themen für 2021 mit KI beschäftigt (s. Bild 23). Aktuell nähern sich Generative KI-Algorithmen [101] wie die in diesem Beitrag vorgestellten GANs dem Peak der Erwartungen. Besonders interessant ist das Auftreten neuer Themen und Gebiete wie z. B. physik-informierte KI [102–104] oder KI-augmentiertes Design [67, 105–107].




Bild 23. Gartner Hype-Cycle 2021 zu emergenten Technologien mit Fokus auf KI-Entwicklungen [100]

5.2 Zukunftstrends für die Anwendung der künstlichen Intelligenz im Bauwesen

In den vorangegangenen Abschnitten dieses Beitrags wurden bereits erfolgreich umgesetzte Beispiele zur Anwendung der künstlichen Intelligenz im Mauerwerks- und Wohnungsbau dargestellt. In diesem Abschnitt werden weitere ökonomisch, ökologisch und methodisch interessante Potenziale zur künftigen Anwendung der künstlichen Intelligenz im Bereich des Mauerwerks- und Wohnungsbaus sowie benachbarter Gebiete aufgezeigt, s. Tabelle 3. Zur qualitativen Einordnung des Aufwands für die Baupraxis oder Forschung wird in dieser Tabelle insbesondere herausgestellt, welche Art von Daten in welchem Umfang für das jeweilige Zukunftspotenzial benötigt werden.

Wie bereits in den Abschnitten zuvor anhand konkreter Beispiele dargestellt wurde, eignen sich die Teildisziplinen des maschinellen und tiefen Lernens zur Behandlung von Entwurfs-, Berechnungs- und Bemessungsproblemen des Bauingenieurwesens und insbesondere des Stahlbaus, wobei aufgrund des jungen Alters dieser Disziplin noch erheblicher Forschungsbedarf hinsichtlich der weiteren Methodenentwicklung besteht. Bei den Zukunftspotenzialen sollen hier drei Themenblöcke angeschnitten werden:

1. Adaptivität und Individualisierung von Bauteilen/Bauwerken,
2. verbesserte Entwurfs-, Berechnungs- und Nachweismöglichkeiten durch/mit KI,
3. KI-unterstützte Prüfung und Überwachung von Prozessen.

Zu allen drei genannten Punkten existieren erste Publikationen zur Anwendung von KI oder einer Unterform. Eine Diskussion von Potenzialen zum Einsatz von KI und eine Sammlung spezifischerer Details zu den drei genannten Bereichen ist für Glasbau in [19], für Stahlbau in [69] und für Massiv- und Brückenbau in [2] zu finden. Insgesamt ist festzustellen, dass die heute existierenden Ansätze erst mittelfristig großflächig in den Planer- und Baualltag einziehen werden, da weitere Forschung und Zusammenarbeit zwischen den verschiedenen Disziplinen und insbesondere der Praxis und Wissenschaft benötigt wird, um die benötigte Zuverlässigkeit und Qualität für einen gewinnbringenden Einsatz zu erreichen. Zudem ist die handhabbare Umsetzung in bedienerfreundliche Software, welche insbesondere eine Interaktion mit den Nutzenden erlaubt, zu bewältigen.

6 Fazit und Ausblick

6.1 Zusammenfassung

In diesem Beitrag wurden zunächst Hintergründe und Definitionen zur digitalen Transformation und der künstlichen Intelligenz rekapituliert und in einen für das Bauingenieurwesen relevanten Kontext gesetzt. Um erkennen zu können, welche Möglichkeiten aktuell und in Zukunft bestehen, wurden hierzu die Potenziale und Gründe für die Umsetzung einer digitalen Transformation nebst deren Methoden wie BIM, digitale

Tabelle 3. Zukunftspotenziale zum Einsatz von künstlicher Intelligenz im Wohnungsbau und benachbarter Gebiete

Potenzial	Beschreibung	Datenformat	Datenmenge ¹⁾	Erfolgschance ²⁾	Einschätzung
Adaptive Bauwerke/-teile	Bauwerke stellen sich auf die Beanspruchung adaptiv und intelligent durch die Steuerung mittels KI ein	strukturiert unstrukturiert	+++	0/✓	Konzepte existieren; derzeit offene methodische Fragen
Nutzerzentrierte Gebäude	Design und Betrieb nutzerzentrierter Gebäude mit maximierter Nachhaltigkeit und Behaglichkeit	strukturiert	+++	0	Konzepte existieren; derzeit offene methodische Fragen
KI-unterstützte Produktentwicklung	Entwicklung neuer Materialien, Bauteile und Fertigungsweisen durch den Einsatz von KI	strukturiert unstrukturiert	+++	✓	möglich und teilweise praktisch umgesetzt
KI-unterstützte Überwachung von Produktion bzw. Bauten	ML/DL-basierte Überwachung der Herstellung von Bauprodukten oder Bauwerken über ihren Lebenszyklus	strukturiert unstrukturiert	+++	✓	möglich und teilweise praktisch umgesetzt
PINNs/KI-basierte Berechnung von Systemen und Materialien	ML/DL-basierte Berechnung von Materialien oder Systemen unter Nutzung physik-informierter Trainingsfunktionen	strukturiert	+	✓	möglich und teilweise praktisch umgesetzt
KI-basierter Bauwerksentwurf	KI-unterstütztes (generatives) Design von Bauwerken durch Interaktion mit den Planenden und Stakeholdern	strukturiert unstrukturiert	++	0	Konzepte existieren; derzeit offene methodische Fragen
KI-basierte statische Bemessung und Prüfung	KI-unterstützte Bemessung und/oder Prüfung von Nachweisen in Interaktion mit Planenden, Aufstellenden, und Prüfenden	strukturiert unstrukturiert	++	0/✓	teilweise umgesetzt; Konzepte existieren; derzeit offene methodische und rechtliche Fragen

1) Menge an Trainingsdaten: + klein; ++ moderat; +++ groß

2) Erfolgsaussicht mit KI: 0 nicht umgesetzt; ✓ vielversprechender Pilot

Zwillinge und Robotik angeführt. Der sich daran anschließende Abschnitt 3 vermittelt eine erste weitergehende Einführung in die künstliche Intelligenz, welche dann in Abschnitt 4 anhand von Beispielen im Lebenszyklus von Wohninfrastrukturprojekten baunah dargestellt bzw. deren Zukunftspotenziale in Abschnitt 5 aufgezeigt wurde.

Anhand der in den vorangegangenen Abschnitten 2 bis 5 beschriebenen Methoden und Beispiele kristallisiert sich heraus, dass die KI momentan in der Forschungs- und Baupraxis vor allem eingesetzt wird, um die Effizienz von Prozessen zu verbessern, ressourcenintensive Aufgaben zu automatisieren und Prognosen auf der Basis objektiver Fakten, Daten und Kriterien statt auf Basis subjektiver Intuition zu fällen. Digitale Technologien und insbesondere der Einsatz von KI werden im Bauwesen in verschiedenen Bereichen

bzw. Lebenszyklusphasen eines Projekts immer häufiger auftreten, insbesondere dann, wenn es um Einblicke in das Verhalten von Objekten geht oder darum, auf Basis von Daten Empfehlungen auszusprechen:

- Suche in Daten und Optimierung dieser Suche, um die relevantesten Ergebnisse zu erhalten (vgl. Design-Optimierung; Monitoring),
- Logik-Ketten für Wenn-dann-Schlussfolgerungen, die zur Ausführung einer Reihe von Befehlen auf der Grundlage von Parametern angewendet werden können,
- Mustererkennung zur Identifizierung signifikanter Zusammenhänge in Datensätzen,
- Anwendung (probabilistischer) Modelle zur Vorhersage zukünftiger Ergebnisse.

Tabelle 4. Zusammenstellung von Vor- und Nachteilen zum Einsatz künstlicher Intelligenz im Bauwesen

Vorteile	Nachteile
Reduzierung menschlicher Fehler	(derzeitig) signifikante Entwicklungskosten, geringe Datenlage
ständige Verfügbarkeit	(derzeitiger) Mangel an KI-Fachkräften
digitale Unterstützung	Mangel an praktischen KI-Produkten
signifikante Effizienzsteigerung bei sich wiederholenden Arbeiten	fehlende Standards bzgl. der KI-Software-Entwicklung
schnellere Entscheidungen	Potenzial von Missbrauch der KI oder fehlerhafte Ergebnisse, die schwer prüfbar sind
rationale Entscheidungen auf der Basis von Daten/Reduktion des menschlichen Bias	Schaffung einer starken Abhängigkeit von Maschinen
verbesserte Sicherheit technischer Systeme	benötigt (derzeit) menschliche Supervision
effizientere Kommunikation	eingeschränkte Möglichkeiten zur Generierung genuiner, kreativer Lösungen

Damit lassen sich die in der Tabelle 4 erarbeiteten Vor- und Nachteile zum Einsatz von KI im Bauwesen ableiten.

Ausgehend von den bisher dargestellten Inhalten lassen sich für die künftige Forschung bezüglich der digitalen Transformation und insbesondere der KI im Wesentlichen sechs Schwerpunktbereiche herausarbeiten:

- Ethik und Einbeziehung des Menschen,
- domänenspezifische Entwicklung der KI-Technologie mit Überprüfbarkeit der Ergebnisse und Qualitätssicherung sowie Zertifizierung,
- Entwicklung und Ausbildung von Fähigkeiten und Fachwissen,
- Rolle der Daten,
- rechtlicher Kontext,
- Begleitung der Technologieadaption in der Praxis.

Die künftige Verknüpfung von Theorie und Praxis ist dabei insbesondere zur Einbeziehung der menschlichen Akteure des Bauprozesses im Zuge der Datenlabelung und der Dateninterpretationsanforderungen essenziell.

6.2 Epilog

Für das Bauen im Status quo lässt sich zusammenfassend feststellen, dass der Erfolg und die Qualität von Bauprojekten signifikant von humanen Faktoren bezüglich der Aspekte der fachlichen, aber auch sozialen Kompetenz determiniert wird. Der flächendeckende Einsatz von KI vermag hier einen Beitrag zur Objektivierung des gesamten Planungs- und Realisierungsprozesses zu leisten, da einerseits fachliche Kompetenz in der Intelligenz des KI-Systems erlernt und dauerhaft über eine Vielzahl von Experten kultiviert und verbessert werden kann. Andererseits werden sozial bestimmte Risiken aus Projektteams durch die Kollaboration mithilfe der KI reduziert. Somit lässt sich folgender Gedanke formulieren:

In Essenz unterstützt die KI zukünftig den Planungs- und Bauprozess in einer kollaborativen Form in einer dem vormodernen Baumeister ähnlichen Rolle, welcher die Aufgaben von Architekt, Ingenieur und Bauhandwerker wieder vereint betrachtet und mithilfe rechenbarer Bauwerksinformationen einen effizienten und optimierten ganzheitlich-lebenszyklusorientierten Bauentwurf liefern kann.

Die digitale Transformation zusammen mit der künstlichen Intelligenz stellt alle am Prozess des Planens und Bauens Beteiligten vor zwei wesentliche Herausforderungen: (i) technische Anpassung zur Nutzung neuer Technologien und (ii) adaptive Anpassungen zur Implementierung neuer Arbeitsprozesse (im Büro und auf der Baustelle). Die Hochschullandschaft muss hier entsprechende Anpassungen der Curricula und Lehrformen für Studium, aber auch Weiterbildung anbieten, sodass komplexe Forschungsergebnisse so verständlich wie möglich in die Praxis transportiert werden. Im Gegensatz dazu erfordern der Umgang und die Umsetzung von Maßnahmen für die adaptiven Herausforderungen kreative betriebsspezifische Ansätze, da derzeit keine methodischen Lösungsansätze aus der Forschung dafür zur Verfügung stehen. Von beiden Seiten bedarf es eines Mentalitätswandels hin zur digitalen Arbeitsweise gepaart mit dem Verständnis für das Potenzial der digitalen Transformation und seiner Methoden wie BIM, Robotik und KI als wichtige und sinnvolle Grundlage bei der evidenz- und faktenbasierten Entscheidungsfindung durch Daten und -analyse innerhalb der Entwicklung einer baulichen Struktur zusammen mit den menschlichen Entscheidern.

Literatur

- [1] Talin, B. (2021) *Digitalisierung vs. Digitale Transformation – Wo liegt der Unterschied?* MoreThanDigital, Feb. 2021, [Online]. Available: <https://morethandigital.info/digitalisierung-vs-digitale-transformation-wo-liegt-der-unterschied>
- [2] Kraus, M.A.; Drass, M.; Hörsch, B.; Schneider, J.; Kaufmann, W. (2022) *Künstliche Intelligenz – multiskale und cross-domäne Synergien von Raumfahrt und Bauwesen*, in: Bergmeister, K.; Fingerloos, F.; Wörner, J.-D. [Hrsg.] *Beton-Kalender 2022*, Berlin: Ernst & Sohn, S. 607–690.
- [3] Obergrießer, M.; Kraus, M. (2022) *Digitale Transformation im Bauwesen – Von der Theorie zur Anwendung*, in: Schermer, D.; Brehm, E. [Hrsg.] *Mauerwerk-Kalender 2022*. Berlin: Ernst & Sohn, S. 499–520.
- [4] Kraus, M.A.; Lammel, L.; Obergrießer, M. (2022) *Digitale Transformation und Künstliche Intelligenz – Herausforderungen und Lösungsansätze bei der Kombination von Theorie und Praxis*, in: *Ingenieurbaukunst 2022*. Berlin: Ernst & Sohn, S. 168–173.
- [5] Schober, K.-S. (2020) *Artificial intelligence in the construction industry*. Roland Berger GmbH, Feb. 2020, [Online]. Available: <https://www.rolandberger.com/en/Point-of-View/Artificial-intelligence-in-the-construction-industry.html>
- [6] Schober K.-S. et al. (2017) *Turning point for the construction industry The disruptive impact of Building Information Modeling (BIM)*. Roland Berger Focus, no. September, 2017.
- [7] Lecat, A.; Schober, K.-S. (2018) *Hot trends in construction: A new era of opportunities*.
- [8] Barbosa, F. et al. (2017) *Reinventing construction: a route to higher productivity*. McKinsey Glob. Inst.
- [9] Chui, M.; Manyika, J.; Miremadi, M. (2018) *What AI can and can't do (yet) for your business*. McKinsey Q.
- [10] Günthner, W.; Borrmann, A. (2011) *Digitale Baustelle – innovativer Planen, effizienter Ausführen – Werkzeuge und Methoden für das Bauen im 21. Jahrhundert*. Berlin Heidelberg: Springer-Verlag.
- [11] Borrmann, A.; König, M.; Koch, C.; Beetz, J. [Eds.] (2021) *Building Information Modeling: Technologische Grundlagen und industrielle Praxis*. VDI-Buch. Wiesbaden: Springer Vieweg.
- [12] Sacks, R.; Eastman, C.; Lee, G.; Teicholz, P. (2018) *BIM Handbook: A Guide to Building Information Modeling for Owners, Designers, Engineers, Contractors, and Facility Managers*. 3rd Edition, Wiley.
- [13] Fischer, M.; Ashcraft, H.W.; Reed, D.; Khanzode, A. (2017) *Integrating Project Delivery*. Wiley.
- [14] Goulet, J.-A. (2020) *Probabilistic Machine Learning for Civil Engineers*. MIT Press.
- [15] Russell, S.J., Norvig, P. (2018) *Artificial intelligence: A modern approach*. Noida, India: Pearson India Education Services Pvt. Ltd.
- [16] Lecun, Y.; Bengio, Y.; Hinton, G. (2015) *Deep learning*, vol. 521, no. 7553. Nature Publishing Group, pp. 436–444.
- [17] Binkhonain, M.; Zhao, L. (2019) *A review of machine learning algorithms for identification and classification of non-functional requirements*, Expert Syst. with Appl. X, vol. 1, p. 100001, <https://doi.org/10.1016/j.eswax.2019.100001>
- [18] Goodfellow, I.; Bengio, Y.; Courville, A. (2016) *Deep Learning*. MIT Press.
- [19] Kraus, M.A.; Drass, M. (2020) *Artificial intelligence for structural glass engineering applications – overview, case studies and future potentials*, Glas. Struct. Eng., vol. 5, no. 3, pp. 247–285, <https://doi.org/10.1007/s40940-020-00132-8>
- [20] Chowdhary, K.R. (2020) *Introducing Artificial Intelligence*, in: *Fundamentals of Artificial Intelligence*. Springer, pp. 1–23.
- [21] McCarthy, J.; Minsky, M.L.; Rochester, N.; Shannon, C.E. (2006) *A proposal for the dartmouth summer research project on artificial intelligence, August 31, 1955*. AI Mag., vol. 27, no. 4, p. 12.
- [22] McCarthy, J.; Minsky, M.L.; Rochester, N. (1956) *The Dartmouth summer research project on artificial intelligence*, Artif. Intell. past, Present. Futur.
- [23] Kraus, M.; Drass, M. (2020) *Künstliche Intelligenz im Bauingenieurwesen – Hintergründe, Status Quo und Potentiale*. Bauingenieur, H. 10.
- [24] Mitchell, T.M. (1997) *Machine Learning*, 1st ed. McGraw-Hill.
- [25] Frochte, J. (2019) *Maschinelles Lernen – Grundlagen und Algorithmen in Python*. Carl Hanser Verlag GmbH Co. KG.
- [26] Bishop, C.M. (2006) *Pattern Recognition and Machine Learning*. Springer.
- [27] Kuhn, M.; Johnson, K. (2013) *Applied Predictive Modeling*, vol. 26. Springer.
- [28] Raschka, S. (2018) *Model evaluation, model selection, and algorithm selection in machine learning*. arXiv Prepr. arXiv1811.12808.
- [29] Brownlee, J. (2016) *Machine Learning Mastery With Python: Understand Your Data, Create Accurate Models, and Work Projects End-to-End*. Machine Learning Mastery.
- [30] O'Leary, D.E. (2013) *Artificial intelligence and big data*. IEEE Intell. Syst., vol. 28, no. 2, pp. 96–99.
- [31] Garcia, S.; Ramirez-Gallego, S.; Luengo, J.; Benítez, J.M.; Herrera, F. (2016) *Big data preprocessing: methods and prospects*. Big Data Anal., vol. 1, no. 1, p. 9.

- [32] Rusu, O. et al. (2013) *Converting unstructured and semi-structured data into knowledge*. In: 2013 11th RoEdu-Net International Conference, pp. 1–4.
- [33] Turner, C.R.; Fuggetta, A.; Lavazza, L.; Wolf, A.L. (1999) *A conceptual basis for feature engineering*. J. Syst. Softw., vol. 49, no. 1, pp. 3–15.
- [34] Ozdemir, S.; Susarla, D. (2018) *Feature Engineering Made Easy: Identify unique features from your dataset in order to build powerful machine learning systems*. Packt Publishing Ltd.
- [35] Reitermanova, Z. (2010) *Data splitting*. WDS, vol. 10, pp. 31–36.
- [36] Rebala, G.; Ravi, A.; Churiwala, S. (2019) *An Introduction to Machine Learning*. Springer.
- [37] Drass, M.; Kraus, M.A.; Stelzer, I. (2021) *SOUND-LAB AI-Estimator – Machine Learning for Sound Insulation Value Predictions of various Glass Structures*. Glas. Struct. Eng., vol. submitted.
- [38] Kraus, M.A. (2019) *Machine Learning Techniques for the Material Parameter Identification of Laminated Glass in the Intact and Post-Fracture State*. Universität der Bundeswehr München.
- [39] Hastie, T.; Tibshirani, R.; Friedman, J. (2009) *The elements of statistical learning: data mining, inference, and prediction*. Springer Science & Business Media.
- [40] Witten, I.H.; Frank, E.; Hall, M.A.; Pal, C. (2016) *Data Mining: Practical machine learning tools and techniques*. Morgan Kaufmann.
- [41] Lloyd, S. (1982) *Least squares quantization in PCM*. IEEE Trans. Inf. theory, vol. 28, no. 2, pp. 129–137.
- [42] Roweis, S.T.; Saul, L.K. (2000) *Nonlinear dimensionality reduction by locally linear embedding*. Science, vol. 290, no. 5500, pp. 2323–2326.
- [43] Murphy, K.P. (2012) *Machine Learning: A Probabilistic Perspective*. MIT Press.
- [44] Tandia, A.; Onbasli, M.C.; Mauro, J.C. (2019) *Machine Learning for Glass Modeling*, in: Springer Handbooks, pp. 1157–1192.
- [45] Chang, N.-B.; Bai, K. (2018) *Multisensor data fusion and machine learning for environmental remote sensing*. CRC Press.
- [46] Van Veen, F. (2016) *The neural network zoo* [Online]. Available: <https://www.asimovinstitute.org/neural-network-zoo>
- [47] Sun, L.; Shang, Z.; Xia, Y.; Bhowmick, S.; Nagaraiaiah, S. (2020) *Review of Bridge Structural Health Monitoring Aided by Big Data and Artificial Intelligence: From Condition Assessment to Damage Detection*. J. Struct. Eng., vol. 146, no. 5, p. 04020073, [https://doi.org/10.1061/\(asce\)st.1943-541x.0002535](https://doi.org/10.1061/(asce)st.1943-541x.0002535)
- [48] Riedel, H. (2020) *Applications of artificial intelligence for crack detection in concrete structures*, Darmstadt.
- [49] Paluszczek, M.; Thomas, S. (2016) *MATLAB machine learning*. Apress.
- [50] Goodfellow, I.J. et al. (2014) *Generative adversarial nets*. Adv. Neural Inf. Process. Syst., vol. 3, no. January, pp. 2672–2680, https://doi.org/10.3156/jsoft.29.5_177_2
- [51] Leijnen, S.; van Veen, F. (2016) *The Neural Network Zoo*. <https://www.asimovinstitute.org/neural-network-zoo> [accessed Dec. 12, 2019].
- [52] Fink, O.; Wang, Q.; Svensén, M.; Dersin, P.; Lee, W.J.; Ducoffe, M. (2020) *Potential, challenges and future directions for deep learning in prognostics and health management applications*. Eng. Appl. Artif. Intell., vol. 92, p. 103678, Jun. 2020, <https://doi.org/10.1016/j.engappai.2020.103678>
- [53] Graves, A. (2012) *Sequence transduction with recurrent neural networks*. arXiv Prepr. arXiv1211.3711.
- [54] Skansi, S. (2018) *Autoencoders*, in: *Introduction to Deep Learning*, Springer, pp. 153–163.
- [55] Kaufmann, W.; Meier, B. (2015) *Conceptual bridge design beyond signature structures*, in: *IABSE Conference, Geneva 2015: Structural Engineering: Providing Solutions to Global Challenges – Report*, pp. 510–517, <https://doi.org/10.2749/222137815818357520>
- [56] Stamm-Teske, W.; Fisher, K.; Haag, T. (2010) *Raumpilot: Wohnen*. Krämer.
- [57] Sacks, R.; Brilakis, I.; Pikas, E.; Xie, H.S.; Girolami, M. (2020) *Construction with digital twin information systems*, Data-Centric Eng., vol. 1, <https://doi.org/10.1017/dce.2020.16>
- [58] Martin, J. (2022) *Procedural House Generation: A method for dynamically generating floor plans*, ACM Trans. Graph., pp. 1–2, 2006, Accessed: Mar. 13 [Online]. Available: <https://axon.cs.byu.edu/Dan/673/papers/martin.pdf>
- [59] Merrell, P.; Schkufza, E.; Koltun, V. (2010) *Computer-generated residential building layouts*. ACM Transactions on Graphics, vol. 29, no. 6, <https://doi.org/10.1145/1866158.1866203>
- [60] Nauata, N.; Chang, K.-H.; Cheng, C.-Y.; Mori, G.; Furukawa, Y. (2020) *House-GAN: Relational Generative Adversarial Networks for Graph-constrained House Layout Generation*. arXiv Prepr. arXiv2003.06988 [Online]. Available: <http://arxiv.org/abs/2003.06988>
- [61] Nauata, N.; Hosseini, S.; Chang, K.H.; Chu, H.; Cheng, C.Y.; Furukawa, Y. (2021) *House-GAN++: Generative adversarial layout refinement network towards intelligent computational agent for professional architects*. Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, pp. 13627–13636, <https://doi.org/10.1109/CVPR46437.2021.01342>
- [62] Autodesk Inc. (2020) *GENERATIVE DESIGN*. <http://www.autodesk.com/solutions/generative-design>
- [63] Autodesk (2018) *Demystifying Generative Design for Architecture, Engineering and Construction* [Online]. Available:

- [91] Wangler, T.; Roussel, N.; Bos, F.P.; Salet, T.A.M.; Flatt, R.J. (2019) *Digital concrete: a review*. Cem. Concr. Res., vol. 123, p. 105780.
- [92] Mechtcherine, V. et al. (2019) *Alternative reinforcements for digital concrete construction*, in: *RILEM Book-series*, vol. 19, pp. 167–175, https://doi.org/10.1007/978-3-319-99519-9_15
- [93] Asprone, D.; Menna, C.; Bos, F.P.; Salet, T.A.M.; Mata-Falcón, J.; Kaufmann, W. (2018) *Rethinking reinforcement for digital fabrication with concrete*. Cem. Concr. Res., vol. 112, pp. 111–121, <https://doi.org/10.1016/j.cemconres.2018.05.020>
- [94] Li, H.; Chan, N.K.Y.; Huang, T.; Skitmore, M.; Yang, J. (2012) *Virtual prototyping for planning bridge construction*, Autom. Constr., vol. 27, pp. 1–10, <https://doi.org/10.1016/j.autcon.2012.04.009>
- [95] Stumm, S.; Brell-Cokcan, S.; Feldmann, M. (2019) *Robotik im Stahlbau 4.0: Von der digitalen Planung zu Produktion und Bau*, in: Kuhlmann, U. [Hrsg.] *Stahlbau-Kalender 2019*, S. 733–778, <https://doi.org/10.1002/9783433609873.ch12>
- [96] Githens, G. (2007) *Product Lifecycle Management: Driving the Next Generation of Lean Thinking* by Michael Grieves, vol. 24, no. 3. McGraw Hill Professional.
- [97] Hack, N. et al. (2020) *Structural stay-in-place formwork for robotic in situ fabrication of non-standard concrete structures: A real scale architectural demonstrator*. Autom. Constr., vol. 115, p. 103197, <https://doi.org/10.1016/j.autcon.2020.103197>
- [98] Hack, N. et al. (2017) *Mesh Mould: An on Site, Robotically Fabricated, Functional Formwork*. National Museum of Qatar View project Concrete Hinges View project, in: *Second Concrete Innovation Conference (2nd CIC)*, vol. 19, pp. 1–10, [Online]. Available: <https://www.researchgate.net/publication/314952069>
- [99] Kersting, K. (2020) *Rethinking Computer Science Through AI*. KI – Künstliche Intelligenz, vol. 34, no. 4, pp. 435–437, <https://doi.org/10.1007/s13218-020-00692-5>
- [100] Gartner (2021) *Hype-Cycle für emergente Technologien 2021*. <https://www.gartner.de/de/artikel/3-themen-im-hype-cycle-fuer-emerging-technologies-2021>
- [101] Aggarwal, A.; Mittal, M.; Battineni, G. (2021) *Generative adversarial network: An overview of theory and applications*. Int. J. Inf. Manag. Data Insights, p. 100004, <https://doi.org/10.1016/j.jjime.2020.100004>
- [102] Bischof, R.; Kraus, M. (2021) *Multi-Objective Loss Balancing for Physics-Informed Deep Learning*, <https://doi.org/10.13140/RG.2.2.20057.24169>
- [103] Raissi, M.; Perdikaris, P.; Karniadakis, G.E. (2017) *Physics Informed Deep Learning (Part I): Data-driven Solutions of Nonlinear Partial Differential Equations*, Nov. 2017, Accessed: Dec. 08, 2019. [Online]. Available: <http://arxiv.org/abs/1711.10561>
- [104] Raissi, M.; Perdikaris, P.; Karniadakis, G.E. (2017) *Physics Informed Deep Learning (Part II): Data-driven Discovery of Nonlinear Partial Differential Equations*, Nov. 2017, Accessed: Dec. 08, 2019. [Online]. Available: <http://arxiv.org/abs/1711.10566>
- [105] Rui, Y. (2017) *From artificial intelligence to augmented intelligence*. IEEE Multimed., vol. 24, no. 1, pp. 4–5.
- [106] Lui, A.; Lamb, G.W. (2018) *Artificial intelligence and augmented intelligence collaboration: regaining trust and confidence in the financial sector*. Inf. Commun. Technol. Law, vol. 27, no. 3, pp. 267–283.
- [107] Zheng, N. et al. (2017) *Hybrid-augmented intelligence: collaboration and cognition*. Front. Inf. Technol. Electron. Eng., vol. 18, no. 2, pp. 153–179.