

Zürcher Kranbahntag 2023

Planung, Bemessung und Ausführung

13. Juni 2023 • ETH Zürich Hauptgebäude & Online
von 9.30–17 Uhr

Kranbahnen sind die zentralen Lebensadern vieler Industriebetriebe. Fallen sie schadensbedingt aus, kommen Produktion und Logistik zum Erliegen, was unter Umständen hohe Kosten verursachen kann. Kranbahnen müssen daher nicht nur sorgfältig geplant und gebaut werden, sondern müssen über ihren gesamten Nutzungszeitraum funktionstüchtig gehalten werden. Sollen bestehende Kranbahnen von neuen Kranbrücken mit höheren Hublasten befahren werden, oder wird der Kranbetrieb intensiviert und so die Ermüdungsbeanspruchung erhöht, kann dies zu einer anspruchsvollen Aufgabe werden.

Neben den Münchener Kranbahn-Experten Prof. Dr.-Ing Christoph Seeßelberg und Prof. Dr.-Ing Andre Dürr haben folgende Referenten ihre Teilnahme bestätigt: Assoc.Prof. Dipl.-Ing. Dr.techn. Markus Kettler (TU Graz), Prof. Dr. Andreas Taras (ETH Zürich), Frank Götz (Nord-Lock GmbH).

Inhalte des Seminars

- ▣ Typische Fehler bei Planung, Fertigung und Betrieb von Kranbahnträgern und ihre Vermeidung
- ▣ Kranbahnen und Kranhallen im Bestand
- ▣ Untersuchung der lokalen Spannungsfelder in Kranbahnträgerstegen infolge Radlast
- ▣ Praxisvortrag Kranbahnen
- ▣ FEM-basierte Bemessung von Kranbahnen nach EC3-1-14
- ▣ Dauerhaftigkeit und Robustheit von Schraubenverbindungen bei Kranbahnträgern



Teilnahmegebühr

Nicht-Mitglied	CHF 600*
SZS Firmenmitglied	CHF 480*
SZS Einzelmitglied, AM Suisse,	CHF 540*
VSKF, SZFF	
Studierende	CHF 60*
Online-Teilnahme	CHF 400*

Teilnehmende aus dem Ausland erhalten eine Rechnung in Euro (€)

Die Teilnahme an der Veranstaltung in Präsenz schließt das *Stahlbau* Sonderheft Kranbahnen, Kaffeepausen, Mittagessen, Apéro und eine Teilnahmebescheinigung ein.

Zielgruppe

Tragwerksplanende, Konstrukteur:innen, Prüfsingenieur:innen, Baumeister:innen, Richtmeister:innen, Bauleitende sowie Bauverantwortliche in Industriebetrieben mit Krananlagen. Auch Studierende können sich die für ihre Karriere notwendigen Fähigkeiten aneignen.

Online-Anmeldung

szs.ch/steelevent/kranbahntag

www.ernst-und-sohn.de/kranbahnen

* Alle Preise sind Nettopreise. Es gelten die AGBs des Stahlbau Zentrum Schweiz.

Sponsor

NORD-LOCK
GROUP

Kooperationspartner

i b k
Institut für Baustatik und Konstruktion

Organisatoren

SZS

Stahlbau Zentrum Schweiz
Centre suisse de la construction métallique
Centro svizzero per la costruzione in acciaio

Ernst & Sohn
A Wiley Brand

Physik-informierte Künstliche Intelligenz zur Berechnung und Bemessung im Stahlbau

Herrn Prof. Dr.-Ing. Ingbert Mangerig zur Vollendung seines 70. Lebensjahres gewidmet

Die Technologie der Künstlichen Intelligenz (KI) hält derzeit flächendeckend Einzug in Forschung und Praxis aller Branchen. Vorliegender Beitrag greift dies auf, um Hintergründe der KI allgemein sowie speziell für Physik-informierte KI (PIKI) einzuführen. Ausgewählte Beispiele der Berechnungs- und Bemessungspraxis des Stahlbaus veranschaulichen die Anwendung von Physik-informierten Neuronalen Netzen (PINN), wobei spezifische Anforderungen an die Formulierungen des Lernproblems herausgearbeitet werden. PINNs stellen somit eine Alternative zu etablierten numerischen Verfahren unter besonderer Berücksichtigung vorhandener Simulations- und Versuchsdaten dar. Dies erlaubt die Interpretation und Nutzung von PINNs als digitalen Zwilling eines Tragwerks über dessen Lebenszyklus. Die dargestellte PIKI bedingt nicht per se eine Big-Data-Situation und ist damit für die Ingenieurforschung und -praxis interessant. Ein Ausblick auf künftige Anwendungen der KI im Stahlbau rundet diesen Beitrag ab.

Stichworte Physik-informierte Künstliche Intelligenz; digitaler Zwilling; Maschinelles Lernen; Tiefes Lernen; Berechnung; Bemessung

Computation and verification of steel constructions using physics-informed artificial intelligence

Currently the technology of artificial intelligence (AI) spreads into research and industry practice of all branches in diverse forms. Given that situation, this article serves to introduce the reader to theoretical background on AI in general as well as to the specific case of physics-informed AI (PIKI). Selected examples from design and verification practice of steel construction then illustrate the application of physics-informed neural nets (PINN) methods, where the specific requirements for the formulation of the learning problem are highlighted. PINN serves as an alternative to established computational methods for design of steel structures and its components using available experimental and simulation data. This enables the interpretation and use of PINNs being the digital twin of a steel structure over its lifecycle. PIKI as presented here does not per se cause a "big data" situation and is therefore interesting for engineering research and practice. This paper eventually gives perspectives on future applications of AI for steel construction.

Keywords physics-informed artificial intelligence; digital twin; machine learning; deep learning; design; structural verification

1 Einleitung und Motivation

Während sich die meisten Menschen geleitet durch populäre Science-Fiction-Filme wie „Terminator“, „Matrix“ oder „A. I. – Künstliche Intelligenz“ bereits seit den 1980er-Jahren künstliche Intelligenzen in Form menschenähnlicher Androiden vorstellen können, sind die alltäglichen Formen der KI, wie z. B. Spam-Filter, Recommender Systems (Empfehlungssysteme wie Spotify oder Amazon) oder digitale Sprachassistenten wie Alexa (Amazon) bzw. Siri (Apple) weniger spektakulär und humanoid. Die fortschreitende Digitalisierung aller Branchen bei gleichzeitig immer weiter sinkenden Kosten für die Datenverarbeitung und -speicherung bereitet der KI-Technologie den Weg vom Gegenstand akademischer Betrachtungen hinein in den privaten sowie beruflichen Alltag in verschiedensten Formen. Vorreiter ist hier die Automobil- sowie Luft- und Raumfahrtbranche mit den Entwicklungen rund um selbstfahrende Autos und Flugzeuge. Hier zeigen sich bereits heute einige Vor- und Nachteile sowie offene Fragestellungen (z. B. juristische Haftung, Berücksichtigung moralischer Dilemmata) hinsichtlich des Einsatzes von Techniken der KI bezüglich der Formulierung des technischen Problems sowie der Verarbeitung der täglich wachsenden Menge an gesammelten Daten. Speziell für die Ingenieurwissenschaften

bietet der Einsatz von KI zahlreiche neue Modellierungs- und Auswertungsmöglichkeiten für die Forschung, Entwicklung und Praxis, was im Rahmen der in diesem Aufsatz vorgestellten Beispiele für den Spezialfall der Physik-informierten KI (PIKI) aufgezeigt wird.

Die freie und kostenlose Verfügbarkeit von KI-Funktionalitäten in Form von Software-Bibliotheken wie z. B. Tensorflow, Keras oder PyTorch sowie die in der Literatur vielfältig dokumentierten Anwendungen von KI bei verschiedenen Fragestellungen aus Medizin oder Bild- und Sprachverarbeitung stellen keine hinreichenden Bedingungen für die erfolgreiche Anwendung von KI-Modellen und Algorithmen auf technische Probleme der Ingenieurwissenschaften und insbesondere des Stahlbaus dar. Grundsätzlich spielen die Disziplinen Statistik, Numerik und Optimierung eine große Rolle beim Verständnis der Daten, bei der Beschreibung der Eigenschaften eines Datensatzes, beim Auffinden von Beziehungen und Mustern in diesen Daten und in der Auswahl und Anwendung der geeigneten Verfahren der KI. Nach Auffassung der Autoren ist es essenziell, dass nur eine sinnvolle Kombination des Methodenwissens der KI sowie des Expertenwissens des Ingenieurs mit der Leistungsfähigkeit von modernen Computeralgorithmen zu erfolgreichen und sinnvollen Anwendungen der KI im Bauingenieurwesen und insbe-

sondere Stahlbau im Rahmen dieses Aufsatzes führen kann.

Um die Möglichkeiten und Grenzen von KI-Algorithmen einschätzen und geeignete Methoden auswählen zu können, werden im nächsten Abschnitt zunächst die Hintergründe und Definitionen der KI und ihrer Teildisziplinen rekapituliert. In Abschn. 3 schließt sich dann die Vorstellung von zwei konkreten Beispielen zum Einsatz der PIKI im Stahlbau an. In Abschn. 4 werden im Rahmen einer Zukunftsvision potenzielle Anwendungen der KI im Stahlbau elaboriert und bewertet. Schließlich wird in Abschn. 5 eine Zusammenfassung der Erkenntnisse dieses Aufsatzes gegeben.

2 Hintergründe zu Künstlicher Intelligenz (KI) und Physik-informierter KI (PIKI)

In diesem Abschnitt werden die wesentlichen Begrifflichkeiten der Künstlichen Intelligenz (KI) und ihrer im Rahmen dieses Beitrags für den Stahlbau relevanten Subgruppen gegeben. Darüber hinausgehend detailliertere und mathematisch fundierte Grundlagen und Hintergrundklärungen zu den hier vorgestellten Inhalten sind u. a. in [1–6] zu finden.

2.1 Künstliche Intelligenz und ingenieurwissenschaftlich relevante Untergruppen

Die für den Stahlbau im Rahmen dieses Beitrags relevanten Gruppen, welche unter dem Begriff der KI zusammengefasst werden, sind in Bild 1 dargestellt. Der informationswissenschaftlichen Definition folgend, umfasst die KI alle Systeme, die ihre Umgebung wahrnehmen und Maßnahmen ergreifen, sodass die Chance auf das erfolgreiche Erreichen von Zielen maximiert wird. Der Begriff KI spiegelt somit wider, dass eine Maschine bzw. ein Algorithmus „kognitive“ Fähigkeiten wie Lernen und Problemlösen nachahmt. Die spezifischen Aufgaben und Anforderungen der einzelnen KI-Untergruppen in diesem Kontext sind in Bild 1a dargestellt. Für diesen Beitrag ist ausschließlich das Tiefe Lernen (Deep Learning/DL) als Untergruppe des Maschinellen Lernens (Machine Learning/ML) relevant (Bild 1a). KI, ML und DL werden umgangssprachlich oft synonym verwendet, stellen definitionsgemäß aber verschiedene Arten der KI dar und müssen somit unterschieden werden.

Beim Tiefen Lernen handelt es sich um einen aktuell viel betrachteten und thematisch vielfältigen Unterbereich des ML und der KI, welcher sich mit sog. künstlichen Neuronalen Netzen (NN) beschäftigt. Zwei wichtige Modellarten von NN sind in Bild 2 dargestellt. NN bestehen typischerweise aus einem Input- und einem Output-Layer und sog. versteckten (hidden) Layern dazwischen. Definitionsgemäß trifft ab mehr als drei hidden Layern die Nomenklatur des „Tiefen Lernens“ sowie „tiefe Neuronale Netze“ (DNN) zu. Gleichungsmäßig wird innerhalb eines

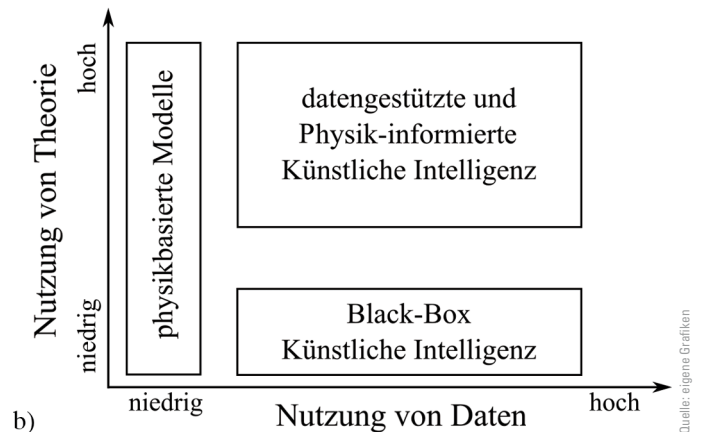
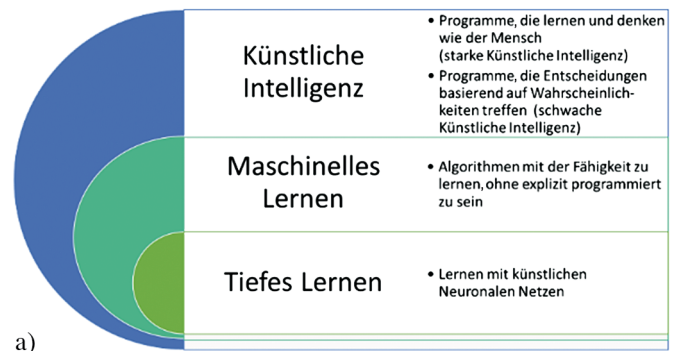


Bild 1 Überblick zu a) Künstlicher Intelligenz, Maschinellern und Tiefem Lernen; b) Black-Box vs. Physik-informierter Künstlicher Intelligenz
Overview: a) artificial intelligence, machine learning and deep learning, b) black-box vs. physics-informed artificial intelligence

NN je Neuron als Ausgangssignal eine gewichtete Summe der K Eingangssignale errechnet und zwischen den L Layern über eine Aktivierungsfunktion weitergereicht (Forward Propagation):

$$b_j^l = g \left(\sum_{j=1}^{K^{l-1}} w_{jk}^l b_j^{l-1} + b_K^{l-1} \right), \quad (1)$$

wobei g eine monotone kontinuierliche Funktion ist und allgemein als Aktivierungsfunktion bezeichnet wird. Die Parameter des NN w_{jk}^l bzw. b_j^{l-1} werden als Gewichte und Schwellenwert (Bias)-Terme bezeichnet. Die Gesamtantwort y des NN für einen Input x wird über eine L -fache Kompositionsoption von Gl. (1) errechnet. Die Komposition von L Layern mithilfe einer nichtlinearen Aktivierungsfunktion ermöglicht dabei einerseits eine gute Erfassbarkeit der Komplexität der Daten und somit Anpassungsfähigkeit des Modells, andererseits kann aber auch der Wertebereich der Antwortvariablen eingeschränkt werden (Abschn. 2.2).

Die Nomenklatur eines NN wird von den vielfältig konstruierbaren Algorithmen (synonym oft als Architekturen bezeichnet) bedingt: während man bei NN nach der Gestalt in Bild 2a und ausschließlich Vorliegen von Layern nach Gl. (1) von einem dichten Feedforward Netz (FFN) spricht, werden Netze mit Faltungslayern als Faltungsnetze (Convolutional Neural Nets/CNN, Bild 2b) bezeichnet.

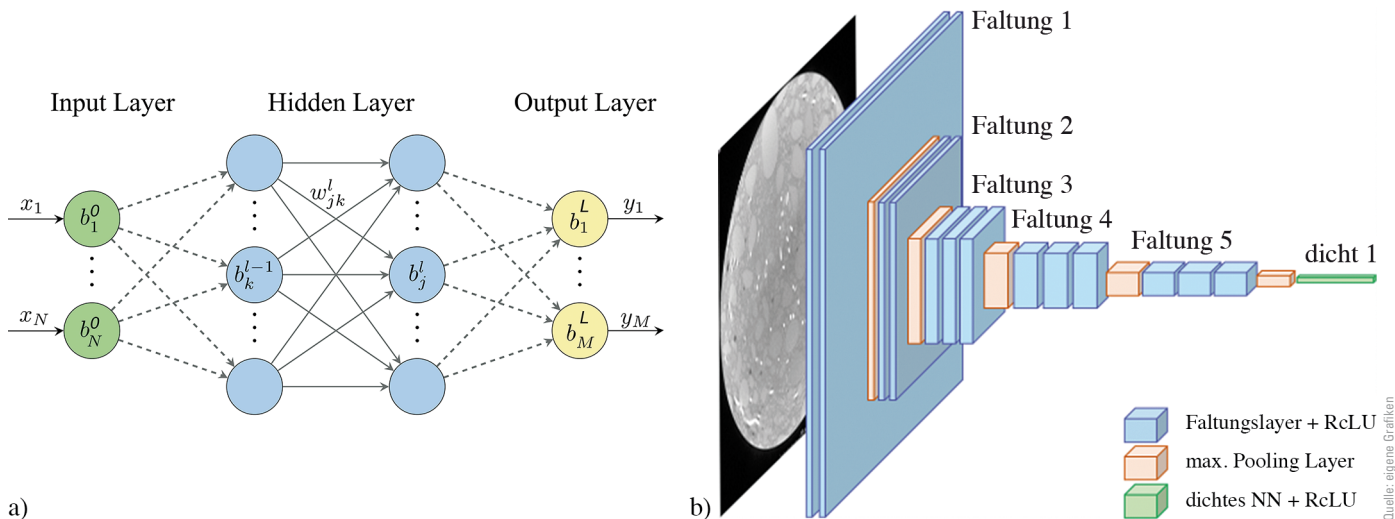


Bild 2 a) (Dichtes) tiefes Neuronales Netz; b) tiefes Faltungsnetz (CNN)
a) (Dense) deep neural network; b) deep folding network (CNN)

Weitere Details zu FFN und CNN sowie deren vielfältige und weitere DL-Untergruppen sind in [1–6] zu finden und nicht weiter relevant für diesen Beitrag. Insbesondere eignen sich NN zur Approximation beliebiger nichtlinearer Funktionen [7], weswegen sie für Aufgaben im Bereich der numerischen Methoden des Stahlbaus geeignet sind (Abschn. 3). Im Gegensatz dazu werden CNN vielfach überwiegend in Anwendungen der KI im Bereich der Bildverarbeitung eingesetzt, Potenziale für den Stahlbau in dieser Hinsicht werden im Abschn. 4 angeführt.

Jüngste Entwicklungen auf dem Gebiet der KI an der Schnittstelle zu den Natur- und Ingenieurwissenschaften führten zur Bildung der Begriffe der „Physik-informierten“ (physics-informed) [8, 9] bzw. „Theorie-geleiteten“ (theory-guided) [10, 11] KI (Bild 1b). Mit diesen speziellen Formulierungen von Modellen der KI sollen zwei Ziele erreicht werden:

- Kompensation des ggf. geringen Datenumfangs zum Training des KI-Modells (Data Sparsity)
- Nutzung vorhandenen theoretischen Wissens der jeweiligen Fachdomäne in formaler Weise

Die angeführten Beispiele im Rahmen dieses Beitrags in Abschn. 3 beschränken sich auf die Formen des Physik-informierten DL mithilfe von Physik-informierten Neuronalen Netzen (PINN) nach Definition von [8] mit eigenen Erweiterungen (Abschn. 2.2). An dieser Stelle sei besonders betont, dass in den Natur- und Ingenieurwissenschaften aus Kosten- und/oder Zeitgründen typischerweise wenig Trainingsdaten für die Anwendung einer KI zur Verfügung stehen, was im Gegensatz zur klassischen Big-Data-Situation in den Informations- und Datenwissenschaften steht. Die PIKI kann dieser Beschränktheit auf kleine Datenmengen Abhilfe im Lernprozess schaffen, da in formaler Weise bereits vorhandenes und theoretisches Wissen (sowohl aus der Wissenschaft als auch von Experten), z. B. in Form der Verlustfunktion [8], oder besondere Regularisierungsausdrücke [12–16] (beides Abschn. 2.2) berücksichtigt werden.

2.2 Formulierung des Lernproblems im Rahmen der Künstlichen Intelligenz

Modelle und Algorithmen sind wesentlich die Bausteine für die Anwendung der KI auf praktische Probleme. Ein Algorithmus ist dabei als ein Satz eindeutiger Regeln definiert, die einem KI-Programm gegeben werden, damit es selbstständig lernen kann. Ein Modell ist das Ergebnis eines trainierten KI-Algorithmus für die Praxisanwendung. Abstrakter definieren [2, 17] ein Computerprogramm (Algorithmus), das „aus der Erfahrung E in Bezug auf eine Klasse von Aufgaben T und das Leistungsmaß P lernt, wenn sich seine Leistung bei Aufgaben in T , gemessen durch P , mit der Erfahrung E verbessert“. Diese Definition lässt eine große Vielfalt von Erfahrungen E , Aufgaben T und Leistungsmaßen P zu. Die Erfahrung E bezeichnet einen ganzen Datensatz D , der für das Training eines KI-Modells zur Verfügung steht. Die Elemente von D heißen Datenpunkte (oder Beispiele) [4] und sein Umfang beträgt N Datenpunkte. Ein Datenpunkt besteht mindestens aus Merkmalen (Features; Einflussvariablen) $x \in \mathbb{R}^n$, wobei ein Merkmal eine einzelne messbare Eigenschaft oder ein beobachtetes Phänomen ist [1, 18]. Weiterhin kann der Datensatz noch aus Antwortvariablen $t \in \mathbb{R}^m$ zusätzlich zu den Features bestehen. Sowohl Einfluss- als auch Antwortvariable können kontinuierlich oder diskret vorliegen. Einen Datensatz $D = \{(x_i, t_i)\}_1^N$ bezeichnet man als „gelabelt“, während man von „ungelabelten“ Daten spricht, wenn nur Features x_i vorliegen. Eine weitere Unterscheidung der Daten kann in Form von strukturierten (z.B. Listen) und unstrukturierten Daten (z.B. Bilder) vorgenommen werden. Die Art des Datensatzes bestimmt wesentlich die Auswahl eines entsprechend geeigneten KI-Algorithmus und den Aufwand der Vorverarbeitung der Daten, bevor eine KI damit überhaupt trainiert werden kann.

Eine Aufgabe T ist die Beschreibung, wie eine KI Datenpunkte verarbeiten soll. Ein Beispiel für eine Aufgabe T




Bild 3 Lernprozess eines KI-/ML-Algorithmus
Learning process of an AI/ML algorithm

ist die Klassifizierung von Bildern eines Prüflings in „intakt“ und „schadhaft“. Das Leistungsmaß P bewertet die Fähigkeiten eines KI-Algorithmus, und oft ist P mit den Besonderheiten der Aufgabe T verbunden. Um das vorherige Klassifikationsbeispiel fortzusetzen, ist ein mögliches Leistungsmaß P die Genauigkeit des Klassifikationsmodells, wobei die Genauigkeit der Anteil der Beispiele ist, für die das Modell den korrekten Output produziert [2, 17, 19]. Die Wahl eines geeigneten Leistungsmaßes ist nicht einfach und objektiv, sondern hängt vom jeweiligen Problem ab und ist daher ein fester Bestandteil der Modellbildung. Da sich dieses Papier ausschließlich mit PIKI-Beispielen aus dem Stahlbau befasst, handelt es sich bei der Aufgabe T um ein mathematisches Modell M zur Beschreibung mechanischer Zusammenhänge. Wenn das Leistungsmaß P zusammen mit dem Begriff des Lernens mathematisch ausgedrückt wird, aktualisiert der KI-Algorithmus ein mathematisches Modell so, dass bei gegebener Erfahrung E eine bessere Leistung P erzielt wird. Diese über P gemessene Verbesserung wird durch (numerische) Optimierung erzielt, in ML- oder DL-Kontexten werden bez. der Nomenklatur von P die Begriffe Fehler-, Ziel-, Verlust- oder Kostenfunktion $E(\mathbf{w}, \mathbf{b})$ synonym verwendet. Die Modellparameter $\{\mathbf{w}, \mathbf{b}\}$ werden über die Minimierung dieser Verlustfunktion bestimmt:

$$\mathbf{w}_o = \arg \min_{\{\mathbf{w}, \mathbf{b}\}} E(\mathbf{w}, \mathbf{b} | D) \quad (2)$$

Die Auswahl der Verlustfunktion selbst stellt, wie bereits erwähnt, einen essenziellen Modellierungsschritt dar und ist je nach Problemstellung ggf. nicht eindeutig, da in der Literatur zu den verschiedenen KI-Aufgaben eine Vielzahl an Verlustfunktionen hergeleitet wurde. Der mittlere quadratische Fehler (Mean Squared Error/MSE) kommt dabei analog den bekannten Modellanpassungen des Ingenieurwesens häufig beim Training von KI-Modellen als Verlustfunktion zur Anwendung. Die Entscheidung bezüglich der Metrik des „Fehlers“ zur Anpassung des KI-Modells an vorhandene Experimental- oder Simulationsdaten ist für den Einzelfall zu diskutieren und ggf. sind mehrere Abstandsmaße gegenüberzustellen. Schließlich können KI-Algorithmen Hyperparameter besitzen, die einstellbare Entitäten eines KI-Algorithmus sind (wie z. B. Regularisierungsstärke in Gl. (2), Validierungsstrategie (Abschn. 3.1) oder Architektur (Anzahl an Layern bzw. Neuronen je Layer, Trainingsepochen, Lernrate etc. [2]) eines neuronalen Netzes (Abschn. 3.1, 3.2)) und während des Trainings untersucht werden müssen, sodass schließlich das geeignetste und statistisch signifikante Modell

ausgewählt werden kann [20]. An dieser Stelle wird noch kurz der Ablauf des Lernprozesses in Bild 3 vorgestellt. Einige der nachfolgend beschriebenen Schritte können wesentliche finanzielle und zeitliche Ressourcen im Rahmen der Anwendung der KI in einem Projekt darstellen und sind somit für den baupraktischen Einsatz von besonderem Interesse und bedürfen einer projektspezifischen Quantifizierung.

Aus Bild 3 ist zu entnehmen, dass für die erfolgreiche Anwendung von Künstlicher Intelligenz in der Praxis der Aufbereitung und Beurteilung des vorhandenen Datenmaterials ein wesentlicher Anteil zukommt. Weitere Details zu den einzelnen Schritten können [1–3, 5, 6, 21, 22] entnommen werden, sodass an dieser Stelle auf eine ausführlichere Darstellung verzichtet werden kann. Weiterhin ist für die Anwendung in der Baupraxis insbesondere festzuhalten, dass nicht jeder Algorithmus der KI aus technischen, organisatorischen oder wirtschaftlichen Gründen uneingeschränkt für beliebige Probleme geeignet ist, vielmehr ist für jede Problemstellung eine Gegenüberstellung der geeignetsten Algorithmen nach den methodischen, ökonomischen und organisatorischen Gesichtspunkten erforderlich. Der Vergleich von Modellen muss über eine gemeinsame Metrik (d. h. identische Verlustfunktionen bei gleichen Trainingsdatenumfängen etc.) gezogen werden, um so in fairer Weise das geeignetste Modell für die jeweilige Problemstellung auszuwählen.

3 Beispielanwendungen Physik-informierter Künstlicher Intelligenz im Stahlbau

Dieser Abschnitt enthält zwei Beispiele zur Anwendung von PIKI in Form von PINNs für den Stahlbau aus dem Bereich der Berechnung und Auslegung von Stahlbauteilen.

3.1 Semi-probabilistischer lokaler Stabilitätsnachweis quadratischer und rechteckiger Stahl-Hohlprofile mit Physik-informiertem Deep Learning

Das hier vorgestellte Beispiel behandelt die versuchs- und simulationsdatengestützte Kalibrierung eines tiefen FFN zur wirklichkeitsnahen Prädiktion der lokalen Stabilitätsversagenslasten von quadratischen und rechteckigen Hohlprofilen (SHS, RHS) unter Axial- und Biegebelas-

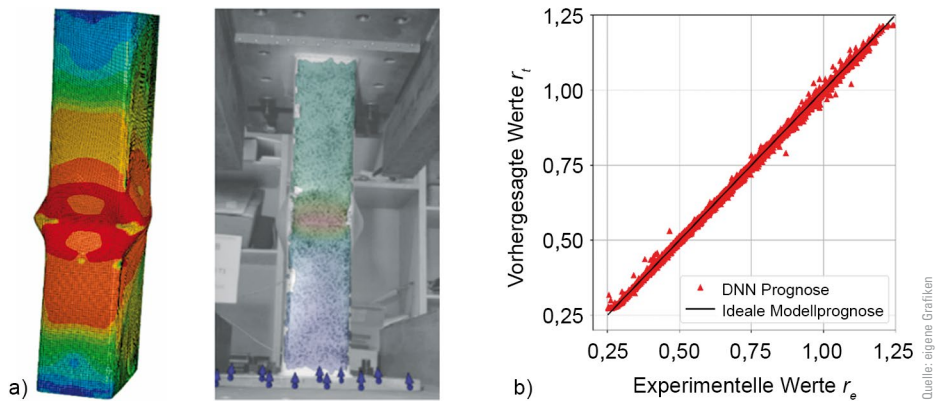


Bild 4 a) Experimente zur lokalen Beulast an einer RHS-Stütze, gemessen mit dem ARAMIS-System, b) FFN-basierte Vorhersage des Stabilitätsversagenslastfaktors r_i vs. experimenteller Wert des Stabilitätsversagenslastfaktors r_e
a) Experiments on buckling load on an RHS support, measured with the ARAMIS system, b) FFN based prediction of the stability failure load factors r_i vs. experimental value of the stability failure load factors r_e

tung. Bisher stellten die aktuell verwendeten konservativen Bemessungsregeln schlanker Querschnitte der Klassen 3 und 4 teilweise ein Hindernis für die weitere Verbreitung der neuen Bauweisen dar. Im Rahmen des von der EU geförderten Forschungsprojekts HOLLOSSTAB wurde dazu einerseits die experimentelle Datenbasis und andererseits eine neue Entwurfsmethode (Generalized Slenderness-based Resistance Method/GSRM) entwickelt [23–25]. Das Projekt und die GSRM zielen dabei darauf ab, zeitaufwendige rechnerische Analysen für die Vorhersage des lokalen Widerstands von SHS und RHS durch den spezifischen Einsatz der Kombination von einfachen numerischen Berechnungsroutinen mit experimentell validierten, analytischen Bemessungsformeln deutlich zu vereinfachen und in den Ergebnissen zu verbessern. In [26] wurde basierend auf der in HOLLOSSTAB erarbeiteten Trainingsdatenmenge ein Physik-informiertes FFN zur Prädiktion der lokalen Stabilitätsversagenslasten von quadratischen und rechteckigen Hohlprofilen erfolgreich kalibriert und mit zuverlässigkeitstheoretischen Methoden untersucht, sodass (nach bestem Wissen der Autoren) hiermit zum ersten Mal im Bauwesen ein Teilsicherheitsfaktor für ein KI-basiertes Modell im Rahmen einer Bemessung bestimmt wurde. Im Rahmen dieses Beitrags erfolgt lediglich eine auszugsweise Darstellung der wichtigsten Ergebnisse, nähere Erläuterungen zu den Modellierungsannahmen und -evaluierungen sind in [23–27] zu finden.

Eine beispielhafte Impression der experimentellen Bauteilversuche an RHS-/SHS-Stützen vermittelt Bild 4a. Wie bereits ausgeführt, umfasst der für die Kalibrierung des DNN benutzte Datensatz sowohl experimentelle Daten als auch die Ergebnisse numerischer Untersuchungen mittels der Finite-Elemente-Methode zu den Stabilitätsversagenslasten. Eingangsparameter waren dabei sowohl geometrische als auch Materialparameter, welche nun auch als Features des DNN dienen. Da die Trainingsdatenmenge im Gegensatz zu einem reinen Modellanpassungsproblem eine Physikkonsistenz sichert, bewegt sich diese Anwendung im Bereich der „Physik-informierten“ DNN. Für diese Studie wurden im Rahmen des Hyper-

parameter-Tunings des FFN verschiedene Netz-Algorithmen sowie Regularisierungsparameter an insgesamt $N_S = 19758$ zur Verfügung stehenden Datensätzen trainiert, getestet und validiert.

Das Training des DNN wurde zur Vermeidung einer Überanpassung des FFN-Modells L2-regularisiert und mittels fünffacher Cross-Validation überprüft, der gesamte Datensatz wurde dabei zum Training des FFN und der Bewertung der Prädiktionsleistung in einem Verhältnis von (70; 20; 10) % von N_S gesplittet. Einen Eindruck von der hohen Genauigkeit des trainierten DNN vermitteln die Bilder 4b, 5. In Bild 4b sind die mit dem DNN vorhergesagten lokalen Stabilitätsversagenslastfaktoren den experimentell bzw. numerisch ermittelten lokalen Stabilitätsversagenslastfaktoren gegenübergestellt (beide Datensätze werden hier als „experimentelle Werte“ bezeichnet), qualitativ ergibt sich eine sehr gute Prädiktion durch das FFN im Mittel (schwarze Winkelhalbierende) bei gleichzeitig sehr geringer Abweichung (geringe Streuung um die Winkelhalbierende) durch das FFN. Eine numerische Cross-Validations-Untersuchung konnte belegen, dass der mittlere quadratische Fehler der Vorhersage der Stabilitätsversagenslasten für SHS und RHS Profile des DNN bei ca. 0,1 % liegt. Die konsekutiv durchgeführte semiprobabilistische Ermittlung des Teilsicherheitsbeiwerts γ_M der mit dem FFN vorhergesagten lokalen Stabilitätsversagenslastfaktoren resultiert in $\gamma_M = 1,00$ für die lokale Stabilitätsbemessung von RHS- und SHS-Stahlprofilen mit diesem Deep-Learning-basierten Modell. Die physikalische Konsistenz und Validität des FFN wird durch die Verwendung der Finite-Elemente-Analyse-basierte Trainingsdatenmenge und deren experimenteller Validierung sowie der spezifischen Formulierung des Trainings mit Stabilitätsversagenslastfaktoren r gewährleistet. Dieselbe Trainingsdatenmenge liegt der GSRM-Methode zugrunde, lediglich die Formulierung und Kalibrierung der Vorhersagemodelle werden im Rahmen dieses Aufsatzes durch die KI ersetzt.

Wie aus Bild 5 klar ersichtlich ist, liefert das hier trainierte DNN eine präzise Vorhersage der Stabilitätsversagens-

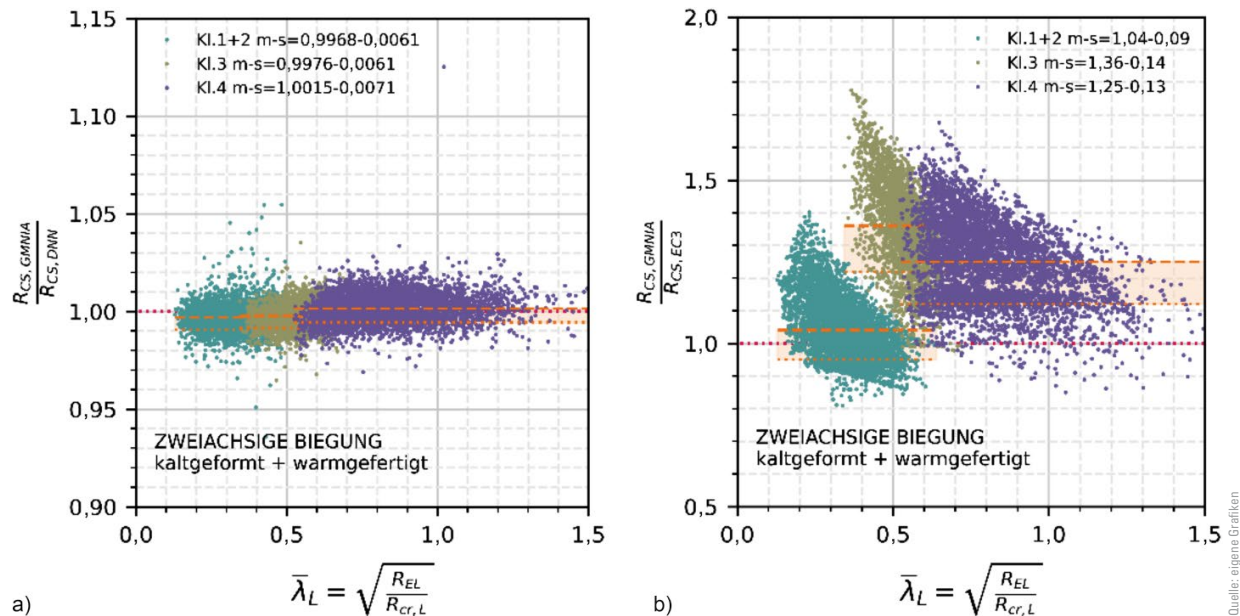


Bild 5 a) Ergebnisse der GMNIA normalisiert mit den Ergebnissen des FFN, b) Ergebnisse der GMNIA normalisiert mit den Ergebnissen nach EC3
a) Results of GMNIA normalized with the results of DNN, b) results of GMNIA normalized with the results of EC3

lastfaktoren über alle Querschnittsklassen des Eurocode 3 (Bild 5a) und zeigt das enorme wirtschaftliche Potenzial dieses KI-Modells gegenüber der aktuellen Bemessung nach EC3 (Bild 5b) für alle Querschnittsklassen auf. Das kalibrierte DNN kann im Rahmen einer semiprobabilistischen Bemessung in der Baupraxis alternativ zu analytischen oder computergestützten Methoden Verwendung finden, da es sich einerseits methodisch in die zuverlässigkeitsbasierte Bemessungsphilosophie der deutschen und europäischen Normung einbettet und andererseits den gleichen geringen numerischen Aufwand wie die Auswertung der analytischen Formeln der GSRM benötigt. Die Praxistauglichkeit des FFN ist somit gegeben. Aufgrund der Kompositions-natur von tiefen FFN (Gl. (1)) ist die Bereitstellung der analytischen Funktion des FFN für die Praxis ungeeignet, daher erarbeiten die Autoren derzeit eine komprimierte analytische Näherungsformel des FFN, welche als Vorschlag in einer künftigen Überarbeitung des EC3 als Bemessungsformel berücksichtigt werden kann.

3.2 Berechnung von Platten nach der Kirchhoff-Theorie mit Physik-informierten Neuronale Netzen

Im Gegensatz zum vorangegangenen Beispiel der Kalibrierung eines DNN an vorhandenen Trainingsdaten wird nun ein Beispiel betrachtet, bei dem ein Physik-informiertes NN (PINN) zur Lösung einer partiellen Differenzialgleichung (PDG) ohne zuvor bereitgestellte Trainingsdaten kalibriert wird. In diesem Kontext bedeutet „Physik-informiert“, dass zwei NN so definiert werden, dass ein FFN die starke (oder schwache) Form der PDG und ein anderes FFN die Rand- und Anfangsbedingungen jeweils als Verlustfunktion zum Training der Parameter des jeweiligen FFN verwendet. Die Methode der PINN ist grundsätzlich in [8, 9] aus mathematischer Sicht eingeführt und

näher beschrieben, sodass an dieser Stelle auf eine vertiefte Darstellung der Hintergründe verzichtet wird.

Bei dem hier angebrachten Beispiel handelt es sich um eine quadratische Platte mit Längsabmessungen $a = b = 1$ sowie Plattensteifigkeit K_0 nach der Kirchhoff-Theorie unter sinusförmiger Belastung p :

$$p(x, y) = \frac{p_0}{K_0} \sin\left(\frac{\pi x}{a}\right) \sin\left(\frac{\pi y}{b}\right) \quad (3)$$

Dieses Problem stellt gewissen Hürden (Hilbert H^2 Lösungsraum) an die Lösung nach der Finite-Elemente-Methode, daneben steht aber auch eine analytische Lösung zur Verfügung. Für isotrop linear-elastisches Materialverhalten liefert die Kirchhoff-Love-Theorie [28] die sog. bi-harmonische Gleichung für die vertikale Verformung der Plattenmittelfläche $w(x, y)$. Im vorliegenden Fall werden die Flächenlast und die Plattensteifigkeit so gewählt, dass eine Verformung mit Stich von 2,5 resultiert, das gesamte analytisch verfügbare Verformungsfeld wird beschrieben durch:

$$w(x, y) = \frac{p_0}{\pi^4 K_0 \left(\frac{1}{a^2} + \frac{1}{b^2}\right)^2} \sin\left(\frac{\pi x}{a}\right) \sin\left(\frac{\pi y}{b}\right) \quad (4)$$

Auch an dieser Stelle erfolgt aufgrund der gebotenen Kürze dieses Beitrags eine auszugsweise Darstellung der Ergebnisse mit dem Verweis auf [29]. Dort werden verschiedene DNN-Algorithmen untersucht, das hier abgebildete PINN zur Lösung der Plattengleichung besitzt einen Hidden Layer mit je 75 Knoten und einer tanh-Aktivierungsfunktion. In Bild 6 sind ausgewählte Ergebnisse der Lösung der Kirchhoff-Plattengleichung mit dem benannten PINN (Bild 6a) für ein Training mit dem ADAM-Algorithmus zum Update der Parameter des PINN,




Bild 6 Verformung einer quadratischen Kirchhoff-Platte unter sinusförmiger Flächenlast: a) analytische Lösung, b) PINN-Lösung, c) Differenz der berechneten Verformungen

Deflection of a square Kirchhoff plate under sinusoidal surface load: a) analytical solution, b) PINN solution, c) difference in computed deflections

50000 Epochen und einer Lernrate von $\lambda = 10^{-3}$ gegen die analytisch verfügbare Lösung (Bild 6b) dargestellt. Es ist erkennbar, dass das hier kalibrierte PINN die Lösung in der Verformung bei ähnlich geringem numerischem Aufwand sehr gut approximieren kann und sich somit zur Lösung der Kirchhoff-Plattengleichung eignet. Weitere Vergleiche zwischen den Ergebnissen der PINN für die starke und schwache Form der partiellen Differenzialgleichung der Kirchhoff-Platte und einer Berechnung nach der Finite-Elemente-Methode (FEM) mit der Software FEniCS sind in [29] dargestellt.

PINNs stellen ein noch junges Gebiet der KI und insbesondere der numerischen Mechanik dar, deswegen sind bisher wenige Arbeiten und Erkenntnisse für Anwendungen im Ingenieurbereich und speziell dem Bauingenieurwesen bzw. Stahlbau vorhanden. Weiterhin liegt derzeit kein allgemeiner Konsens zur Konstruktion der Verlustfunktionen für PINNs vor. Bisher konnte allerdings gezeigt werden, dass sich PINNs zur Lösung der starken Form einer Reihe von PDG sehr gut eignen und sich damit numerisch präzise Lösungsansätze erzielen lassen [8, 9]. Die allgemeinere Formulierung der Verlustfunktion zum Training der PINN zur Lösung der schwachen Form der PDG sowie im Rahmen von gemischten Ansätzen der Lösungsfeldvariablen ist derzeit aktueller Stand der Forschung und wird im Rahmen dieses Beitrags nicht weiter vertieft. Für die Baupraxis ist an dieser Stelle aber besonders zu betonen, dass die PINNs ein sehr gutes Beispiel dafür darstellen, dass gerade in den Ingenieurwissenschaften je nach Problemstellung nicht immer und per se ein Big-Data-Problem mit den Methoden der KI gelöst wird, wenn eine entsprechende Formulierung des Lernproblems hergeleitet und verwendet werden kann. Im Vergleich zum vorangegangenen Beispiel des Abschn. 3.1 wurden hier keine Messdaten zum Training verwendet. Die Erweiterung des Trainings von PINNs zur Berücksichtigung von Messdaten (z. B. in Form von Deformationen oder Verzerrungen an definierten Punkten) im Rahmen baupraktischer Fragestellungen (wie z. B. im Rahmen von Tragwerksbeurteilungen und Zuverlässigkeitsanalysen) ist leicht möglich. In diesen Situationen fungierten PINNs als Alternative zu etablierten numerischen Verfahren wie der Finite-Elemente-Methode (FEM), was ein Novum darstellt, da somit ein PINN als digitaler Zwilling anstelle einer FEM-Software dienen kann.

4 Potenziale und Zukunftstrends von Künstlicher Intelligenz im Stahlbau

In den vorangegangenen Abschnitten dieses Beitrags wurden bereits erfolgreich umgesetzte Beispiele zur Anwendung der Künstlichen Intelligenz im Stahlbau dargestellt. Dieser Abschnitt dient dem Aufzeigen von ökonomisch, ökologisch und methodisch interessanten Potenzialen für eine künftige Anwendung der Künstlichen Intelligenz im Bereich des Stahlbaus und benachbarter Gebiete wie dem Fassaden- und Glasbau (Tab. 1). Insbesondere ist hier herausgestellt, welche Art von Daten in welchem Umfang für das jeweilige Zukunftspotenzial benötigt werden, sodass der Aufwand einer Anwendung dafür für die Baupraxis oder Forschung qualitativ abschätzbar wird.

Wie bereits in den Abschn. 3.1, 3.2 anhand konkreter Beispiele dargestellt wurde, eignen sich die Teildisziplinen des Maschinellen und Tiefen Lernens zur Behandlung von Entwurfs-, Berechnungs- und Bemessungsproblemen des Bauingenieurwesens und insbesondere des Stahlbaus, wobei aufgrund des jungen Alters dieser Disziplin noch erheblicher Forschungsbedarf hinsichtlich der weiteren Methodenentwicklung besteht. Bei den Zukunftspotenzialen sollen hier drei Themenblöcke angeschnitten werden:

- Adaptivität und Individualisierung von Bauteilen/Bauwerken,
- verbesserte Entwurfs-, Berechnungs- und Nachweismöglichkeiten durch/mit KI,
- KI-unterstützte Prüfung und Überwachung von Prozessen.

Zu allen drei genannten Punkten existieren erste Publikationen zur Anwendung von KI oder einer Unterform. Eine glasbauzentrierte Diskussion von Potenzialen zum Einsatz von KI und eine Sammlung spezifischerer Details zu den drei genannten Bereichen ist in [30] zu finden. Es ist allerdings insgesamt festzustellen, dass die heute existierenden Ansätze noch weitere Jahre der Forschung und Zusammenarbeit zwischen den verschiedenen Disziplinen und insbesondere der Praxis und Wissenschaft benötigen, um die benötigte Zuverlässigkeit und Qualität für einen gewinnbringenden Einsatz im Planer- und Bauall-

Tab. 1 Zukunftspotenziale zum Einsatz von Künstlicher Intelligenz im Stahlbau und benachbarten Gebieten
Future potentials for application of artificial intelligence in steel construction and related areas

Zukunftspotenzial	Beschreibung	Datenformat	Daten- inten- sität ¹	Erfolgs- aussicht mit KI ²	Schlussfolgerung
Adaptive Bauwerke/-teile	Bauwerke stellen sich auf die Beanspruchung adaptiv und intelligent durch die Steuerung mittels KI ein	strukturiert unstrukturiert	+++	0 / ✓	Konzepte existieren; derzeit immer noch viele offene Fragen
Nutzerzentriertes Gebäude	Design und Betrieb nutzerzentrierter Gebäude mit maximierter Nachhaltigkeit und Behaglichkeit	strukturiert	+++	0	Konzepte existieren; derzeit immer noch viele offene Fragen
KI-unterstützte Produktentwicklung	Entwicklung neuer Materialien und Fertigungsweisen durch den Einsatz von KI	strukturiert unstrukturiert	+++	✓	möglich und teilweise praktisch umgesetzt
KI-unterstützte Überwachung von Produktion oder Bauwerken	DL-basierte Überwachung der Herstellung von Bauprodukten oder Bauwerken über ihren Lebenszyklus	strukturiert unstrukturiert	+++	✓	möglich und teilweise praktisch umgesetzt
PINNs/KI-basierte Modellierung von Systemen und Materialien	DL-basierte Modellierung von Materialien oder Systemen unter Nutzung Physik-informierter Verlustfunktionen	strukturiert	+	✓	möglich und teilweise praktisch umgesetzt
KI-basierter Bauwerksentwurf	KI-unterstütztes Design von Bauwerken durch Interaktion mit dem Planer	strukturiert unstrukturiert	++	0	Konzepte existieren; derzeit immer noch viele offene Fragen
KI-basierte statische Bemessung und Prüfung	KI-unterstützte Bemessung und/oder Prüfung von Nachweisen in Interaktion mit dem Aufsteller/Prüfingenieur	strukturiert unstrukturiert	++	0 / ✓	teilweise umgesetzt; Konzepte existieren; derzeit immer noch viele offene Fragen

¹ Menge an Trainingsdaten: + klein; ++ moderat; +++ groß² Erfolgsaussicht mit KI: 0 nicht umgesetzt; ✓ vielversprechender Pilot

tag zu erreichen. Zudem ist die handhabbare Umsetzung in bedienerfreundliche Software, welche insbesondere eine Interaktion mit dem nutzenden Ingenieur erlaubt, zu bewältigen.

5 Zusammenfassung und Schlussfolgerungen

In diesem Aufsatz wurden zunächst Hintergründe und Definitionen zur Künstlichen Intelligenz rekapituliert und in einen für das Bauingenieurwesen relevanten Kontext gesetzt. Dieser Beitrag zeigte auf, dass tiefe Physik-informierte Neuronale Netze in der Berechnungs- und Bemessungspraxis (sogar im Rahmen des semiprobabilistischen Sicherheitskonzepts) erfolgreich trainiert und eingesetzt werden können und den etablierten Methoden mindestens gleichwertig oder in der Genauigkeit sogar überlegen sind. Konkret wurde ein FFN für den semiprobabilistischen Nachweis des lokalen Stabilitätsversagens von SHS- und RHS-Profilen kalibriert, wobei eine auszugsweise Darstellung und Diskussion der wesentlichen Schritte des Trainings- und Validierungsprozesses erfolgte. Weiterhin wurden PINNs als Alternative zu etablierten numerischen Verfahren der Mechanik zur Berechnung von Tragwerken, hier am Beispiel der Kirchhoff-Platte, unter sinusför-

miger Belastung eingeführt. Es wurde dabei insbesondere herausgearbeitet, dass mit den PINNs eine neue Art von digitalem Zwilling zur Verfügung steht, welcher innerhalb einer einzigen methodischen sowie softwaretechnischen Umgebung die Berechnung, Auslegung und das Monitoring einer Struktur des Bauwesens erlaubt. Zum Abschluss dieses Beitrags wurden drei wesentliche Bereiche für potenziell vielversprechende Anwendungen von KI im Stahlbau vorgestellt: Adaptivität und Individualisierung von Bauteilen/Bauwerken; verbesserte Entwurfs-, Berechnungs- und Nachweismöglichkeiten durch/mit KI; KI-unterstützte Prüfung und Überwachung von Prozessen. Die Kernthesen zu Beispielen der drei Bereiche wurden stichpunktartig in Tabellenform zusammen mit einer qualitativen Abschätzung zum Bedarf an Daten sowie geeigneten KI-Algorithmen vorgestellt. Dieser Beitrag zeigte auf, dass es vielfältige Anwendungen der KI im Stahlbau schon derzeit und vor allem künftig gibt und ein erfolgreicher Einsatz dieser Technologie nicht per se eine Big-Data-Situation (welche im Stahlbau bzw. Bauwesen häufig nicht vorliegt) bedingt. Einer flächendeckenden und tiefgreifenden Einbindung der KI-Technologie in der Baubranche stehen allerdings die vielen derzeit offenen Forschungsfragen sowie die Abwesenheit bedienerfreundlicher KI-Software gegenüber.

Literatur

- [1] Bishop, C. M. (2006) *Pattern Recognition and Machine Learning*. Berlin: Springer.
- [2] Frochte, J. (2019) *Maschinelles Lernen – Grundlagen und Algorithmen in Python*. München: Carl Hanser Verlag GmbH Co KG.
- [3] Heaton, J.; Goodfellow, J.; Bengio, Y.; Courville, A. (2018) *Deep learning* in: Genet. Program. Evolvable Mach. 19, no. 1–2, pp. 305–307.
- [4] Goodfellow, I.; Bengio, Y.; Courville, A. (2016) *Deep Learning*. Cambridge: The MIT Press.
- [5] Murphy, K. P. (1991) *Machine Learning: A Probabilistic Perspective*. Cambridge: The MIT Press.
- [6] Mohri, M. et al. (2018) *Foundation Machine Learning*. Cambridge: The MIT Press.
- [7] Hornik, K.; Stinchcombe, M.; White, H. (1989) *Multilayer feedforward networks are universal approximators* in: Neural Networks 2, no. 5, pp. 359–366.
- [8] Raissi, M.; Perdikaris, P.; Karniadakis, G. E. (2017) *Physics Informed Deep Learning (Part I): Data-driven Solutions of Nonlinear Partial Differential Equations*. Nov. 2017.
- [9] Raissi, M.; Perdikaris, P.; Karniadakis, G. E. (2017) *Physics Informed Deep Learning (Part II): Data-driven Discovery of Nonlinear Partial Differential Equations*. arxiv.org.
- [10] Faghmous, J. H. et al. (2014) *Theory-guided data science for climate change* in: Computer (Long. Beach. Calif). 47, no. 11, pp. 74–78.
- [11] Karpatne, A. et al. (2017) *Theory-guided data science: A new paradigm for scientific discovery from data* in: IEEE Trans. Knowl. Data Eng. 29, no. 10, pp. 2318–2331.
- [12] Kraus, M. A. (2019) *Machine Learning Techniques for the Material Parameter Identification of Laminated Glass in the Intact and Post-Fracture State* [Dissertation]. Universität der Bundeswehr München.
- [13] Koutsourelakis, P. S. (2016) *Variational Bayesian strategies for high-dimensional, stochastic design problems* in: J. Comput. Phys. 308, pp. 124–152.
- [14] Karpatne, A.; Watkins, W.; Read, J.; Kumar, V. (2017) *Physics-guided Neural Networks (PGNN): An Application in Lake Temperature Modeling*. Oct. 2017.
- [15] Wagner, N.; Rondinelli, J. M. (2016) *Theory-guided machine learning in materials science* in: Front. Mater. 3, Jun. 2016.
- [16] Reichstein, M. et al. (2019) *Deep learning and process understanding for data-driven Earth system science* in: Nature 566, no. 7743, pp. 195–204.
- [17] Mitchell, T. M. (1997) *Machine Learning*. 1st ed. N. Y.: McGraw-Hill.
- [18] Kuhn, M.; Johnson, K. (2013) *Applied Predictive Modeling*, vol. 26. Berlin: Springer.
- [19] Brownlee, J. (2016) *Machine Learning Mastery With Python: Understand Your Data, Create Accurate Models, and Work Projects End-to-End*. Machine Learning Mastery.
- [20] Raschka, S. (2018) *Model evaluation, model selection, and algorithm selection in machine learning*. arXiv Prepr. arXiv1811.12808.
- [21] Goulet, J. A. (2020) *Probabilistic machine learning for civil engineers*. Cambridge: The MIT Press.
- [22] LeCun, Y.; Bengio, Y.; Hinton, G. (2015) *Deep learning* in: Nature 521, no. 7553, pp. 436–444.
- [23] Taras, A.; Toffolon, A. (2020) *Neuartige Bemessungsmethode für Hohlprofilquerschnitte und -stäbe* in: Stahlbau 89, H. 7, S. 570–584. doi.org/10.1002/stab.202000052
- [24] Taras, A.; Toffolon, A. (2019) *Development of an OIC-Type local buckling design approach for cold-formed unstiffened and groove-stiffened hollow sections* in: Thin-Walled Struct. 144.
- [25] Meng, X.; Toffolon, A.; Gardner, L.; Taras, A. (2019) *The generalised slenderness-based resistance method for the design of CHS and EHS* in: Steel Constr. 12, no. 4, pp. 342–353.
- [26] Toffolon, A.; Kraus, M. A.; Taras, A. (2020) *Deep Learning based method for the prediction of the buckling resistance of SHS and RHS* (Paper). Eurosteel 2020 – the 9th European Conference on Steel and Composite Structures. Sheffield, 1.–3. Sept. 2021.
- [27] Kraus, M. A.; Toffolon, A.; Taras, A. (2020) *Physics-Informed Deep Learning for semi-probabilistic buckling resistance design of SHS and RHS* in: Eng. Struct. (submitted).
- [28] Reddy, J. N. (2015) *An Introduction to Nonlinear Finite Element Analysis*. 2nd ed. Oxford: Oxford University Press.
- [29] Kraus, M. A.; Linder, C. (2020) *Sobolev-Type Loss Function Construction for Physics-Informed Deep Learning in Computational Mechanics – Derivation and Examples* in: Comput. Mech. 66 (submitted).
- [30] Kraus, M. A.; Drass, M. (2020) *Artificial Intelligence for Structural Glass Engineering Applications – overview, case studies and future potentials* in: Glas. Struct. Eng. 5.

Autoren

Dr.-Ing. Michael A. Kraus, M.Sc.(hons) (Korrespondenzautor)
makraus@stanford.edu
Stanford University – CEE
Y2E2, 473 Via Ortega
Stanford, CA 94305, USA

Prof. Dr. Andreas Taras
taras@ibk-baug.ethz.ch
ETH Zürich – Departement BAUG
Institut für Baustatik und Konstruktion (IBK)
Professur für Stahlbau und Verbundbau
Stefano-Francini-Platz 5
8093 Zürich, Schweiz

Zitieren Sie diesen Beitrag

Kraus, M. A.; Taras, A. (2020) *Physik-informierte Künstliche Intelligenz zur Berechnung und Bemessung im Stahlbau*. Stahlbau 89, H. 10, S. 824–832. <https://doi.org/10.1002/stab.202000074>

Dieser Aufsatz wurde in einem Peer-Review-Verfahren begutachtet.
Eingereicht: 11. August 2020; angenommen: 24. August 2020.